



激光与光电子学进展  
*Laser & Optoelectronics Progress*  
ISSN 1006-4125, CN 31-1690/TN

## 《激光与光电子学进展》网络首发论文

题目: SGW-YOLO: 多尺度融合优化的 PCB 缺陷检测算法  
作者: 毛坤, 朱学军, 赖惠鸽, 余坼操, 熊垒垒, 杨明, 彭达  
收稿日期: 2025-01-09  
网络首发日期: 2025-02-13  
引用格式: 毛坤, 朱学军, 赖惠鸽, 余坼操, 熊垒垒, 杨明, 彭达. SGW-YOLO: 多尺度融合优化的 PCB 缺陷检测算法[J/OL]. 激光与光电子学进展.  
<https://link.cnki.net/urlid/31.1690.tn.20250212.1723.004>



**网络首发:** 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

**出版确认:** 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

# SGW-YOLO：多尺度融合优化的 PCB 缺陷检测算法

毛坤，朱学军\*，赖惠鸽，余圻操，熊垒垒，杨明，彭达

宁夏大学 机械工程学院，宁夏 银川 750021

**摘要** 针对印刷电路板（Printed circuit board,PCB）表面缺陷小且与背景特征相似导致传统检测算法准确度低等问题，提出了一种 SWG-YOLO 的 PCB 缺陷检测算法。该算法在 YOLOv8 基础上，在主干网络特征融合层末端引入 Swin Transformer 模块捕捉全局信息，增强细节与整体特征理解；其次在 backbone 中嵌入全局注意力机制（GAM）聚焦目标区域，降低背景干扰；最后，采用 WIoU 损失函数代替原来 CIoU，通过差异化加权，增强了模型在小目标及复杂背景下的回归性能。在 PCB\_DATASET 和 DeepPCB 两个数据集上，对不同算法进行对比实验，该算法在 PCB\_DATASET 和 DeepPCB 数据集上检测精度分别较 YOLOv8 提高 3.64% 和 2.42%，显著提升了缺陷识别的准确性。

**关键词** 缺陷检测；注意力机制；损失函数；差异化加权

**中图分类号** TP391.4；TN41 **文献标志码** A

## Multi scale fusion algorithm for PCB defect detection based on SGW-YOLO

Mao Kun, Zhu Xuejun, Lai Huige, Yu Checao, Xiong Leilei, Yang Ming, Peng Da

*School of Mechanical Engineering, Ningxia Univ, Yinchuan 750021, China;*

**Abstract** Aiming at the problem of low accuracy in traditional detection algorithms caused by the small size and similar background features of defects on the surface of printed circuit boards (PCB), a PCB defect detection algorithm named SWG-YOLO is proposed. Based on YOLOv8, this algorithm introduces a Swin Transformer module at the end of the backbone network's feature fusion layer to capture global information and enhance the understanding of both details and overall features. It embeds a Global Attention Mechanism (GAM) in the backbone to focus on target areas and reduce background interference. Additionally, it replaces the original CIoU loss function with a WIoU loss function, which improves the regression performance for small targets and complex backgrounds through differential weighting. Comparative experiments on the PCB\_DATASET and DeepPCB datasets demonstrate that the proposed algorithm increases detection accuracy by 3.64% and 2.42% on the two datasets, respectively, significantly enhancing the accuracy of defect identification.

**Key words** Defect detection; Attention mechanism; Loss function; Differentiated weighting

## 1 引言

近年来，随着 5G 通信、物联网、汽车电子等新兴领域的发展，PCB 的需求量急剧增加

[1], 然而, PCB 的高密度、多层堆叠和微型化趋势, 显著增加了缺陷检测的难度, 对传统检测技术构成了重大挑战。传统的 PCB 缺陷检测手段主要有人工目视检测, 飞针测试, 自动光学检测<sup>[2][3]</sup> (Automated Optical Inspection, AOI) 等, 但这些方法存在效率低下, 成本高, 检测速度慢等问题。

基于深度学习的图像处理技术发展为 PCB 缺陷检测提供了新途径<sup>[4]</sup>。不少研究人员纷纷将它应用于 PCB 缺陷检测以突破传统检测方式带来的不便。ZHANG 等<sup>[5]</sup>针对目前的 PCB 缺陷检测模型难以平衡精度和计算成本, 无法满足实际应用的要求, 设计了一种轻量级的特征提取网络 LFEN 和集成了高效注意力模块的多尺度聚合网络 MAN。采用高效的下采样方法提取特征, MAN 网络以抑制背景干扰, 促进不同尺度特征图之间的信息共享。郭艳<sup>[6]</sup>等人结合部分卷积<sup>[7]</sup> (PConv), 设计了 POD-CSP 和 POD-MP 跨阶段网络模块, 并提出了 OD-Neck 结构去进一步优化特征提取, 并将 AlphaIoU<sup>[8]</sup>与 SIoU 结合, 通过 Alpha-SIoU 损失对网络改进。宋涛等<sup>[9]</sup>在小样本条件下的 PCB 缺陷检测任务中, 针对漏检问题, 引入了基于 Meta R-CNN<sup>[10]</sup>的元特征增强的 PCB 缺陷检测算法, 该算法结合了元学习和微调策略, 在元测试阶段仅微调检测器头部, 以改善知识迁移过程中的分类模糊问题。HU 等在绝缘体公共数据集<sup>[11]</sup>和新的合成雾化绝缘子数据集<sup>[12]</sup>做缺陷检测任务中, 运用了可变性卷积, 加权交并比 (Weighted Intersection over Union, WIoU) 等方法进行 YOLOV8 网络训练, 训练后模型在精度上拥有提升。张莹<sup>[13]</sup>提出了一种基于多通道特征融合学习的小目标缺陷检测网络 YOLOPCB, 自建了一个 AOI 图像采集装置获取图像, 制作了 Self-PCB 缺陷数据集。基于 YOLOV7 做了改进, 删除了 YOLOv7 主干网络中最后一组 MPConv 层与 E-ELAN 层, 去掉融合层的 ECU 模块与  $20 \times 20$  的预测头, 使用跨通道信息连接模块串联精简后的主干和融合网络, 该方法在公开数据集以及 Self-PCB 缺陷数据集中检测精度与检测速度有了很大的提升。

基于深度学习的检测方法通过深层网络结构, 对输入图像进行卷积以提升检测精度。然而, 在实际应用中, PCB 微小缺陷在图像中占比小, 缺陷特征与背景信息相似, 导致深层网络学习到的缺陷特征不足。

为此, 本研究提出了一种改进的 SWG-YOLO 算法, 用于 PCB 缺陷检测。该算法通过在主干网络特征融合层末端引入 Swin Transformer 模块和全局注意力机制 (GAM), 增强了模型对全局特征的提取能力和对目标区域的关注度, 减轻了背景干扰。此外, 采用 WIoU-v2 损失函数替代传统的 IoU 损失函数, 通过差异化加权提升了模型在小目标和复杂背景下的回归性能, 显著提高了微小缺陷的检测精度。

## 2 YOLOv8 网络模型

YOLOv8 是一种先进的目标检测模型，它在继承前代优势的基础上进行了多项改进。该模型将目标检测简化为一个回归问题，能够通过端到端的预测直接确定图像中目标的定位和分类，从而实现高效率的目标检测<sup>[14]</sup>。

YOLOv8 的网络结构由输入、骨干网络、颈部网络和检测头四个部分组成。输入阶段使用“马赛克”数据增强技术，通过组合四张图片来提升模型对复杂场景的适应性。此外，YOLOv8 采用了 YOLOX<sup>[15]</sup>中提出的概念，在训练的最后十轮会关闭数据增强功能，以增强模型对特征的专注学习，提高泛化和鲁棒性。

YOLOv8 在其骨干网络中整合了卷积块、C2f 和 SPPF 模块，以优化特征提取。卷积块结合了卷积、BN 和 SiLU 激活函数，后者相较于 ReLU，提供了更平滑的导数，有助于缓解梯度消失问题。C2f 模块在前代基础上进行了改进，强化了特征提取和梯度传递，提升了训练的稳定性与效率。SPPF 模块则通过空间金字塔池化，统一了多尺度特征图的尺寸，减少了信息损失，提高了性能。在颈部网络方面，YOLOv8 采用了 PAN-FPN 设计，这一结构通过 FPN 和 PAN 的结合，实现了多尺度特征的有效融合，提升了检测精度。与 YOLOv5 相比，YOLOv8 在上采样时直接利用了 C2f 模块，省去  $1\times 1$  卷积结构，直接将 Backbone 的特征用于上采样，增强了对不同目标的检测能力。

总体来说，YOLOv8 模型通过有效的特征提取、多尺度特征融合以及解耦的检测头，实现了高效准确的目标检测<sup>[16]</sup>。这种网络结构设计使得 YOLOv8 在速度和性能之间取得了很好的平衡，在实际应用中得到了广泛的应用。

## 3 SGW-YOLO 网络结构

本文提出的 SGW-YOLO 算法整体结构如图 1 所示。该模型通过在主干网络特征融合层末端融合 Swin Transformer 模块来提升特征识别能力。模型在主干网络后端应用 Swin Transformer 的窗口注意力机制，以捕获图像全局特征，增强对细节与整体特征的理解。在特征融合阶段，引入 GAM 注意力机制，提高对缺陷目标的识别能力，降低背景干扰。此外，为提高小目标检测的准确性，采用 Wise-IoU 损失函数，其动态非单调聚焦机制有助于模型



关注难检测样本，从而提升整体检测性能。这些改进使得模型在 PCB 缺陷检测任务中表现优异，增强了特征的完整性和检测的准确性。

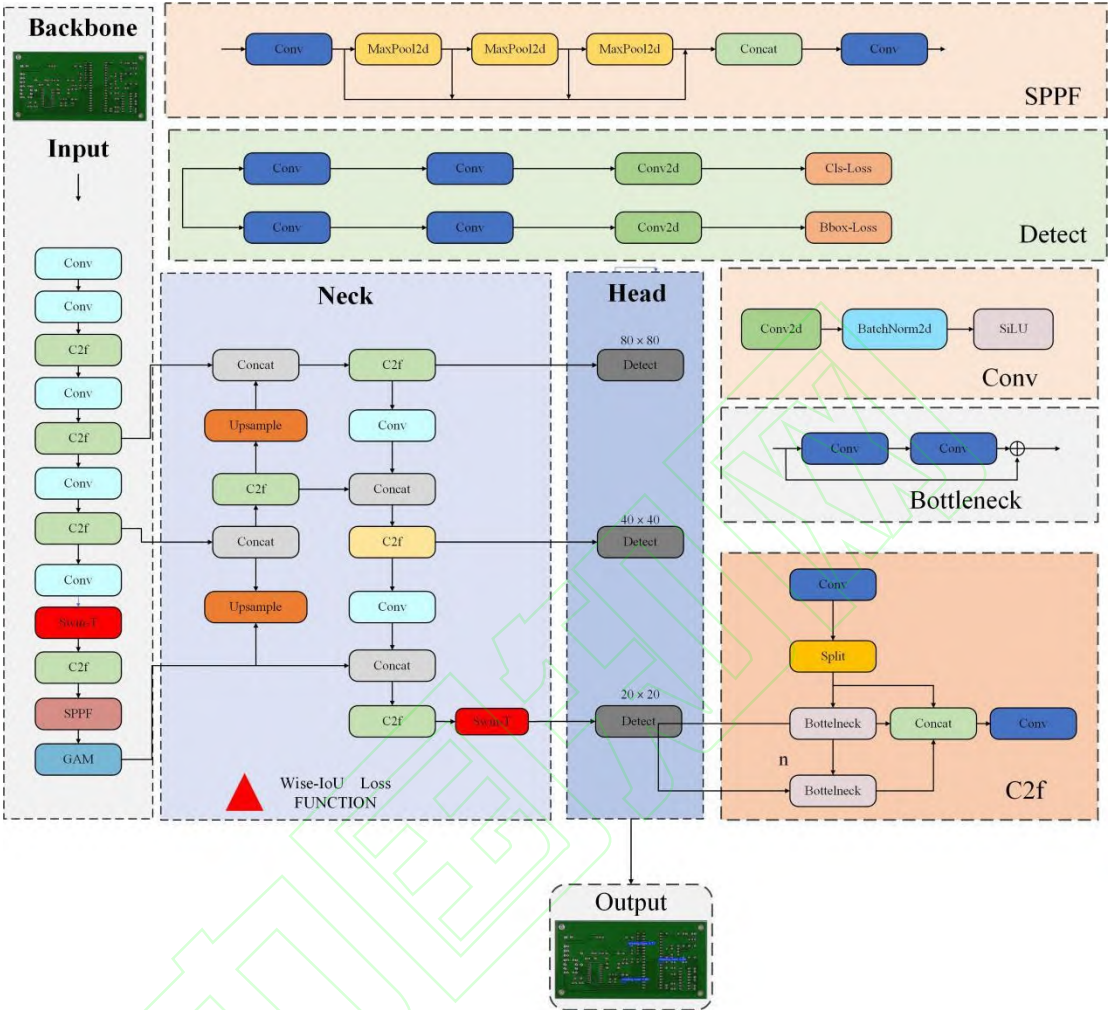


图 1 SGW-YOLO 网络模型结构图

Fig. 1. SGW-YOLO Network Model Structure

3.1 融合 Swin Transformer

Swin Transformer 是微软公司基于 Transformer 架构的改良<sup>[17]</sup>。相较于传统卷积神经网络，它采用窗口注意力机制更有效地捕捉全局信息。通过移动窗口增强窗口间的信息交互，Swin Transformer 扩大了感受野，实现了不同窗口特征的有效关联，从而提升了模型对图像细节和全局信息的理解能力。本文将 Swin Transformer 模块集成于改进 YOLOv8 网络的主干层末端和特征融合层末端。此位置的特征图已经过多层卷积处理,具有丰富的语义信息，且网络末端特征图尺度较小，此模块对计算量的影响有限，能够在控制计算成本的同时，充分利用 CNN 的高分辨率空间信息与 Swin Transformer 的全局语义信息，有效处理不同区域间的信

息交互,提升小目标检测的定位能力。Swin Transformer 的基本结构由 Patch Embedding、Swin Transformer Block 和 Patch Merging<sup>3</sup> 个模块构成。如图 2 所示。




图 2 分层特征表示结构

Fig. 2. Hierarchical feature representation structure

Swin Transformer 接收一个  $H \times W$  像素的 RGB 图像作为输入,并将其划分成  $4 \times 4$  像素的小块,减少特征维度到  $h/4 \times h/4$ 。在第一阶段,使用线性嵌入将特征维度扩展到  $C$ ,然后送入 Transformer Block。接下来的阶段,即第二至第四阶段,通过将相邻的  $2 \times 2$  图像块合并,再通过卷积操作降低特征维度,逐步将维度细化到  $h/8 \times h/8$ 、 $h/16 \times h/16$  和  $h/32 \times h/32$ ,同时将特征通道数加倍到  $2C$ 、 $4C$  和  $8C$ 。每个阶段都重复特定次数,以逐步提高特征的精细度和通道数。

Swin Transformer 的结构相比标准的 transformer 将多头注意力计算部分 (MSA) 替换为窗口注意力机制 (W-MSA) 模块和滑动窗口自注意力机制 (SW-MSA) 模块,其结构如图所示。每个子模块由归一化层、注意力模块、规范化层和多层传感器 (MLP) 层组成,并将每个模块通过残差连接进行连接<sup>[18]</sup>。其中 W-MSA 是具有规则窗口配置的多头自注意模块,SW-MSA 是移位窗口配置。Swin Transformer Block 结构如图 3 所示。

在模块 1,特征图  $z^{l-1}$  首先经过 LN 层计算,再经过 W-MSA,然后经过残差结构相加得到  $\hat{z}^l$ ,之后特征图再经过一个 LN 层,使用全连接层 (MLP) 并将其添加到剩余结构中得到  $z^l$ 。输入到模块 2 中重复之前操作最后得到  $z^{l+1}$ ,计算过程如式 (3) — (6) 所示。




图3 Swin Transformer Block 结构

Fig. 3. Swin Transformer Block Structure

### 3.1.1 非重叠窗口的自注意力

为了能够高效建模，计算局部窗口内的自我注意力，窗口通过以不重叠的方式将图像平均地分割。假设每个窗口包含  $M \times M$  个 patches(像素)，全局 MSA 模块和基于  $h \times w$  个 patches 图像的窗口的计算复杂度为：

$$\Omega(MSA) = 4hwC^2 + 2(hw)^2C \quad (1)$$

$$\Omega(W-MSA) = 4hwC^2 + 2M^2hwC \quad (2)$$

其中，MSA 是 patches 数量的  $h \times w$  的二次方而基于窗口的 MSA 在  $M$  固定时是线性的。全局自注意 MSA 计算较大的  $h \times w$ （高分辨率）的图像来说通常是无法处理的，而基于窗口的自注意 W-MSA 复杂度是线性的，减少了很大的计算量。

### 3.1.2 连续块内的移动窗口划分

基于窗口的自注意模块缺乏跨窗口的连接，这导致不同窗口之间的信息不能交互，限制了它的建模能力。为了引入跨窗口连接，同时保持非重叠窗口的有效计算，所以提出了一种移位窗口分区的方法，这种方法在连续 Swin Transformer 块中交替使用两种分区配置。

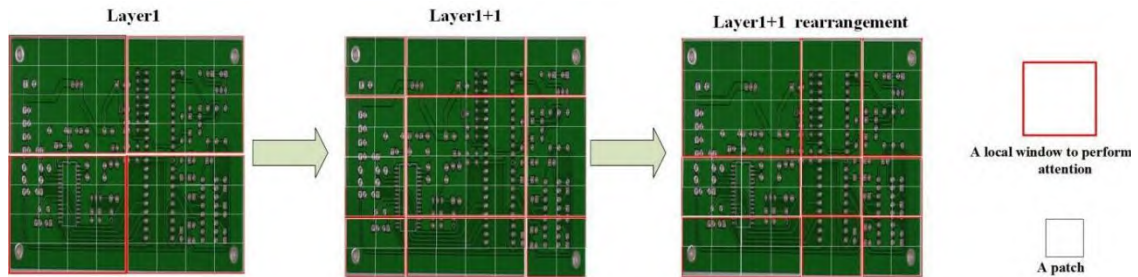


图 4 滑动窗口自注意力机制

Fig.4. Shifted Window Self-Attention Mechanism

通过引入滑动窗口的方式，在注意力机制中实现了不同窗口间的信息交互，如图所示，W-MSA 模块在第 1 层将模型划分为  $2 \times 2$  个等大小的  $4 \times 4$  ( $M=4$ ) 的窗口；1 层经过 SW-MSA 模块处理后，窗口线以  $(M/2, M/2) = (2, 2)$  向下和向右各移动了两个像素单位，如图第  $l+1$  层所示，为了减少计算量，将其重新排列，得到间接类似新的四块，以保证与 W-MSA 模块相同计算量。通过这样的处理解决了传统自注意力机制中不同窗口间特征信息不交互的问题。连续的 Swin Transformer 块的计算公式如下：

$$\hat{z}^l = W - \text{MSA}(\text{LN}(z^{l-1})) + z^{l-1} \quad (3)$$

$$z^l = \text{MLP}(\text{LN}(\hat{z}^l)) + \hat{z}^l \quad (4)$$

$$\hat{z}^{l+1} = \text{SW} - \text{MSA}(\text{LN}(z^l)) + z^l \quad (5)$$

$$z^{l+1} = \text{MLP}(\text{LN}(\hat{z}^{l+1})) + \hat{z}^{l+1} \quad (6)$$

### 3.2 GAM注意力机制

注意力机制<sup>[19]</sup>是机器学习中的一种数据处理方法，广泛应用于自然语言处理（NLP）、图像处理和语音识别等领域。它使算法能够专注于特定区域，从而提取更详细的信息，提升表达能力。最近的研究表明，将注意力模块纳入目标检测算法可以有效减少来自不相关目标的干扰，从而提高检测精度<sup>[20]</sup>。为减少背景信息对模型的影响并提升对 PCB 板小目标特征的提取能力，本文在 YOLOv8 的骨干网络中嵌入了全局注意力机制（GAM），是继 CBAM 注意力机制后全新的注意力模块<sup>[21]</sup>，它结合了 CA（Channel Attention Mechanism）<sup>[22]</sup>和 SA（Spatial Attention Mechanism）的优势以提高不同深度学习网络架构下的性能。此外，GAM 通过强化对目标的关注和减少不必要的信息处理，改进了全局特征的交互，如图 5 所示，GAM 由通道注意力和空间注意力两个模块组成，通过这两个模块处理输出特征，以获得更优的新特征。

Global Attention Mechanism (GAM)

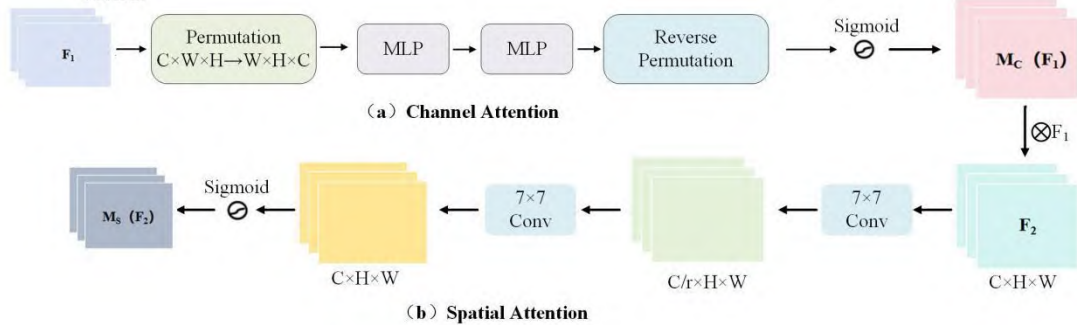




图 5 GAM 注意力模块结构

Fig. 5. Structure of GAM.

为了在传入特征中保留通道信息,通道注意力机制将原始特征的尺寸从  $C \times W \times H$  重新排列为  $W \times H \times C$ 。这种重排允许通过两层连续的 MLP 结构放大多维通道相关性,该结构是具有参数  $r$  的编码器-解码器结构,最终通过 S 形函数激活以推导出通道注意力系数。生成的通道注意力特征通过应用式(7)来获得。

$$\begin{aligned} F_2 &= M_c(F_1) \otimes F_1 = \text{sigmoid}[K_1 \cdot \text{ReLU}(w_2 y + b_2)^T] \\ y &= w_1 K_1^T + b_1 \end{aligned} \quad (7)$$

为了提取派生的通道注意力特征的空间信息,采用了两步过程。首先,通过使用两个  $7 \times 7$  卷积实现空间信息融合;其次,使用参数  $r$  压缩通道维度,并去除池化层以保证特征图的生成。得到的空间注意力系数表示为  $M_s(F_2)$  是通过 sigmoid 函数的激活获得的。然后,可以通过应用式(8)来推导出空间注意力特征。

$$F_3 = M_s(F_2) \otimes F_2 = \text{sigmoid}[\text{ConvBN}(\text{ConvBNReLU}(K_2))] \quad (8)$$

由两部分组成的注意力机制可生成同时考虑通道和空间特征的输出特征。此特征组合可增强算法检测缺陷 PCB 的有效性。

### 3.3改进损失函数

在 PCB 缺陷检测任务中,由于缺陷目标小,边界框与真实缺陷区域的重叠通常较小,导致 IoU 值低,从而影响损失计算。因此,设计合理的损失函数对提升模型的检测性能至关重要。尽管 YOLOV8 中采用 DFL 与 CIoU 计算边界框回归损失<sup>[23][24]</sup>。但是,CIoU 在 PCB 小目标缺陷检测方面存在明显缺陷。一方面,CIoU 不仅会考虑重叠面积,还关注边界框的中心点距离和长宽比。这使得边框形状不理想时损失过于敏感,干扰学习效果。另一方面,对于占比较小的缺陷类别,CIoU 难以有效引导模型关注,导致特征学习困难。此外,CIoU 的计算涉及反三角函数,这会大大增大模型的计算复杂程度。CIoU<sup>[25]</sup>公式如式(9)所示。式中引入了 IoU 的概念,它表示预测框和真实框之间的交集与并集的比率。该指标是衡量预测框和真实框之间重叠程度的关键参数,如图 6 所示。

$$L_{CIoU} = 1 - IoU + \frac{\rho^2(b, b^{gt})}{(c_w)^2 + (c_h)^2} + \frac{4}{\pi^2} \left( \tan^{-1} \frac{w_{gt}}{h_{gt}} - \tan^{-1} \frac{w}{h} \right) \quad (9)$$




图 6 损失函数示意图

Figure 6: Schematic diagram of loss function

其中,  $h$  和  $w$  表示预测框的高度和宽度, 而  $h^{gt}$  和  $w^{gt}$  表示真实框的高度和宽度。这些参数共同描述了预测框和真实框的大小信息。最后,  $c_h$  和  $c_w$  表示由预测框和真实框形成的最小包围框的高度和宽度, 为计算 IoU 提供必要的边界信息。这些参数的精确定义和计算对于后续的目标检测任务至关重要, 使我们能够更准确地评估模型的性能。

EIoU 为 CIoU 的改进, 将长度和宽度作为单独的罚项, 反映了真实框和预测框之间的宽度和高度差异, 使其罚项与 CIoU 相比更加合理。EIoU<sup>[26]</sup>的公式如式 (10) 所示:

$$L_{EIoU} = 1 - IoU + \frac{\rho^2(b, b^{gt})}{(c_w)^2 + (c_h)^2} + \frac{\rho^2(w, w^{gt})}{(c_w)^2} + \frac{\rho^2(h, h^{gt})}{(c_h)^2} \quad (10)$$

其中,  $\rho(w, w^{gt})$  和  $\rho(h, h^{gt})$  分别表示真实框和预测框之间的宽度和高度的欧几里得距离,  $\rho(b, b^{gt})$  表示预测框和真实框中心之间的欧几里得距离。

针对 PCB 缺陷检测中小目标难检、定位精度不足, 并解决因 YOLOv8 中过渡到无锚点方法而导致的函数回归的更高挑战, 本文采用 wise-IoU(WIoU)损失函数替代原损失函数 CIoU。

WIoU 利用合理的梯度增益分配策略来评估锚框的质量<sup>[27]</sup>。Tong 等<sup>[28]</sup>提出了 WIoU 的三个版本: WIoU-v1, 它采用基于注意力的设计来预测边界框损失, WIoU-v2 和 WIoU-v3 则是在此基础上通过构造梯度增益(聚焦系数)的计算方法来附加聚焦机制。

### 3.3.1 Wise-IoU v1

对于训练集中的低质量图片, 当使用几何度量时, 损失函数的泛化性能会大大降低。为

了解决该问题，提高模型的泛化能力，构建了基于距离变量的两层注意力机制的 **WIoU v1** 模型，如式 (11) - (13) 所示。

$$\mathcal{L}_{IoU} = 1 - IoU = 1 - \frac{W_i H_i}{S_u} \quad (11)$$

$$\mathcal{R}_{WIoU} = \exp \left( \frac{(x - x_{gt})^2 + (y - y_{gt})^2}{(W_g^2 + H_g^2)^*} \right) \quad (12)$$

$$\mathcal{L}_{WIoUv1} = \mathcal{R}_{WIoU} \mathcal{L}_{IoU} \quad (13)$$

其中， $W_g$ ， $H_g$ 为最小封闭框大小。为防止 $\mathcal{R}_{WIoU}$ 产生阻碍收敛的梯度， $W_g$ ， $H_g$ 从计算图中分离出来（上标为\*代表此操作）因为其有效地消除了阻碍收敛的因素，所以没有引入新的度量，比如宽高比。

### 3.3.2 Wise-IoU v2

**Focal Loss** 设计了一种针对交叉熵的单调聚焦机制，有效降低了简单示例对损失的贡献。这使得模型能够聚焦于困难示例，获得分类性能的提升。

与焦点损失<sup>[29]</sup>为交叉熵开发的单调聚焦机制类似，**WIoU v2** 利用单调聚焦系数来提高模型在具有挑战性的示例中的性能。

$$\mathcal{L}_{WIoUv2} = \mathcal{L}_{IoU}^{\gamma^*} \mathcal{L}_{WIoUv1}, \gamma > 0 \quad (14)$$

由于增加了聚焦系数，**WIoU v2** 的反向传播梯度也发生了变化。

单调聚焦系数 $\mathcal{L}_{IoU}^{\gamma^*}$ 是为 $\mathcal{L}_{WIoUv1}$ 和 $\mathcal{L}_{IoU}$ 作为归一化因子引入，以提高梯度增益。

$$\frac{\partial \mathcal{L}_{WIoUv2}}{\partial \mathcal{L}_{IoU}} = \mathcal{L}_{IoU}^{\gamma^*} \frac{\partial \mathcal{L}_{WIoUv1}}{\partial \mathcal{L}_{IoU}}, \gamma > 0 \quad (15)$$

梯度增益为 $r = \mathcal{L}_{IoU}^{\gamma^*} \in [0, 1]$ 。在模型训练过程中，梯度增益随着 $\mathcal{L}_{IoU}$ 的减小而减小，导致训练后期收敛速度较慢，因此，引入 $\mathcal{L}_{IoU}$ 均值作为归一化因子。

$$\mathcal{L}_{WIoUv2} = \left( \frac{\mathcal{L}_{IoU}^*}{\overline{\mathcal{L}_{IoU}}} \right)^{\gamma} \mathcal{L}_{WIoUv1} \quad (16)$$

其中， $\overline{\mathcal{L}_{IoU}}$ 是具有动量  $m$  的指数移动平均值。动态更新归一化因子使梯度增益  $r = \left( \frac{\mathcal{L}_{IoU}^*}{\overline{\mathcal{L}_{IoU}}} \right)^{\gamma}$  总体保持在高水平，解决了训练后期收敛缓慢的问题。

### 3.3.3 Wise-IoU v3

$$\beta = \frac{\mathcal{L}_{IoU}^*}{\overline{\mathcal{L}_{IoU}}} \in [0, +\infty) \quad (17)$$

动态非单调 FM: 锚框的离群度用 $\mathcal{L}_{IoU}$ 与 $\overline{\mathcal{L}_{IoU}}$ 的比值表示：

锚框的质量与异常值的大小直接相关。据此，我们为那些异常值较小的锚框赋予较低的梯度增益，相反，对于异常值较大的锚框，则赋予较高的梯度增益。这样的分配策略旨在优化模型对锚框质量的整体评估<sup>[30]</sup>。

$$\mathcal{L}_{WIoUv3} = r\mathcal{L}_{WIoUv1}, r = \frac{\beta}{\delta\alpha^{\beta-\delta}} \quad (18)$$

离群度 $\beta$ 和梯增益 $r$ 的映射，由超参数 $\alpha$ ， $\delta$ 控制。

## 4 实验结果与分析

### 4.1 数据集

本文所用的数据集为北京大学智能机器人开放实验室公开的 PCB 缺陷数据集 (PCB\_DATASET)，共有 6 种 PCB 缺陷，有缺失孔(missing\_hole)、鼠咬(mouse\_bite)、开路(open\_circuit)、短路(short)、毛刺(spur) 和杂铜(spurious\_copper)，共计 693 张图像<sup>[31]</sup>。由于样本较少，因此通过调整亮度、cutout、随机旋转、裁剪、镜像、加噪声等操作扩充数据集，扩充后有 9250 张图像，按照 8:1:1 的比例划分训练集、验证集和测试集。此外，本文还选择了 DeepPCB 数据集验证本文所提出算法在 PCB 缺陷检测任务上的有效性。DeepPCB 数据集是由上海交通大学图像处理与模式识别研究所公开的 PCB 缺陷数据集，该数据集也包含缺失孔(missing\_hole)、鼠咬(mouse\_bite)、开路(open\_circuit)、短路 (short)、毛刺(spur)和杂铜(spurious\_copper)6 类 PCB 缺陷图像，且每张缺陷图上包含若干个不同种类缺陷<sup>[32]</sup>。虽然两数据集的缺陷类型相似，但 DeepPCB 数据集中的所有图像都是从线性扫描 CCD 获得的，由图 7 所示，两者图像背景区别较大，图像颜色不同。




图 7 数据集背景对比

Fig.7: Comparison of Dataset Background

### 4.2 实验环境与评价指标

本实验训练模型平台硬件配置为 Intel(R) Core(TM)i5-8300H CPU，Nvidia Geforce RTX 4060 GPU，实验环境为 64 位 win11 系统；Pycharm 编译软件，Python 版本 3.9，PyTorch



版本 2.3.1, CUDA 版本 12.1, 使用 PyTorch 深度学习框架搭建、训练以及测试网络模型。

训练参数设置如下: 训练周期 (epochs) 为 300, 批处理量 (batchsize) 为 16, 进程数 (works) 为 4, 输入图像尺寸为 640\*640。采用 SGD 优化策略进行学习率调整, 设置学习率初始值为  $1 \times 10^{-3}$ 。

模型的评价指标包括: 准确率 P、召回率 R、平均精度 AP、均值平均精度 mAP、F1 得分和每秒帧数 FPS。准确率和召回率计算方法如 (19-20) 所示。

$$\text{Precision} = \frac{TP}{TP + FP} \quad (19)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (20)$$

$$\text{mAP} = \frac{\sum_{i=1}^N AP_i}{N} \quad (21)$$

$$AP = \int_0^1 P(R) d(R) \quad (22)$$

式中: TP 为被正确划分为正样本的个数; FP 被错误划分为负样本的个数; FN 为被错误划分为负样本的个数。AP 为 P-R 曲线下方区域的面积, 各类目标的平均精度。mAP 是多个类别 AP 的平均值, mAP 的大小一定在 [0,1] 区间, 且越大越好。

F1 综合考虑了精确率和召回率, 是精确率和召回率的调和平均数, 是衡量模型在精确性和召回性之间平衡的指标。

$$F_1 = \frac{2P \cdot R}{P + R} \quad (23)$$

帧数 FPS 的公式为:

$$\text{FPS} = \frac{F_n}{T} \quad (24)$$

式中:  $F_n$  为检测图片的个数;  $T$  为检测图片所用的总时间。

#### 4.3 改进损失函数实验

在目标检测任务中, 损失函数的选取对于模型训练效果和性能具有显著影响。为增强 YOLOv8 模型在目标定位方面的精确度, 本研究对比了三种优化版本的 WIoU 损失函数 (WIoU-v1、WIoU-v2、WIoU-v3) 与 YOLOv8 模型原用的 CIoU 损失函数。

实验过程中, 我们采用了统一化的实验配置和标准化数据集, 确保了对不同损失函数影响的公正评估。实验中, 我们将这四种损失函数分别应用于 YOLOv8 模型的训练, 并在固定迭代次数下记录了性能表现。如图 8 所示, 损失函数曲线反映了训练过程中的变化趋势。值得注意的是, 在训练的最后阶段, 即第 90 轮之后, 由于 YOLOv8 模型中停止了 MOSIC 数据增强, 可以观察到损失曲线的显著下降。

实验结果表明, WIoU-v2 在模型收敛性方面表现突出。相较于其他损失函数版本, 采用 WIoU-v2 的 YOLOv8 模型展现出了更少的过拟合现象和更高的识别准确率。因此, 本研究选择 WIoU-v2 损失函数来替代原有的 CIoU 损失函数, 以期达到更佳的目标检测性能。

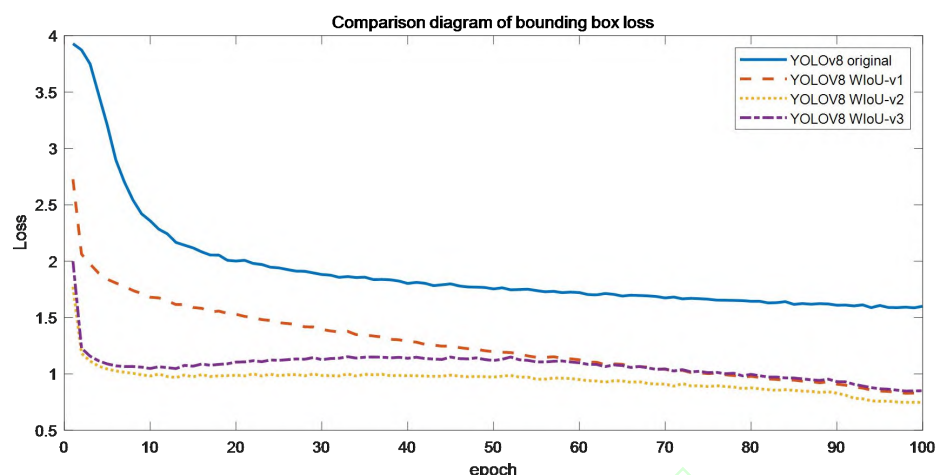


图 8 边界框损失对比图

Fig.8: Comparison diagram of bounding box loss

#### 4.4 消融实验

为了验证集成 Swin Transformer 模块、添加的 GAM 注意力模块以及改进损失函数给 PCB 缺陷检测算法带来的性能增益,将集成 Swin Transformer 模块的模型命名为 S-YOLOv8、将在此基础上添加 GAM 模块的模型命名为 SG-YOLOv8、将在前两者基础上添加改进损失函数的模型命名为 SGW-YOLOv8,对该算法进行消融实验,消融实验在 PCB\_DATASET 数据集上完成,实验结果如表 1 所示,√表示模型有该模块。

表 1 消融实验结果对比

Table 1. Comparison of ablation experiment Results

S	G	W	mAP/%	Increased percentage	Recalls/%	mP/%	F1	FPS
			94.88		92.15	95.38	0.92	75.19
√			96.23	1.35	92.35	95.64	0.94	60.83
	√		96.17	1.29	91.67	95.73	0.95	70.30
		√	96.98	2.1	92.56	95.93	0.95	72.54
√	√		97.56	2.68	94.59	96.37	0.95	58.45
	√	√	97.95	3.07	95.36	97.13	0.96	65.30
√	√	√	98.52	3.64	96.66	98.39	0.98	50.51

表 1 证实了本文中提出的三项关键改进对于 PCB 缺陷检测性能的显著提升。特别是, WIoU 损失函数的引入,通过差异化加权策略优化了小目标及复杂背景中的边界框回归,显著提高了预测精度,相较于基线 YOLOV8 算法, mAP 提升了 2.1%, mP 提升至 95.93%,F1 得分达到 0.95,且维持了较高的 72.54FPS。同时, Swin Transformer 模块和 GAM 注意力机制的集成,虽造成一定的速度损耗,但它们强化了特征提取的深度和目标区域的聚焦,进一步提升了检测性能,使得最终的 SGW-YOLO 模型相较于 YOLOV8,整体精度提升了 3.64%,

召回率提升了 4.51%，mP 提升至 98.39%，F1 值达到 0.98。同时保持了 50.51FPS 的检测速度，满足工业实时检测需求<sup>[33]</sup>。实验结果证明了所提改进策略在提升 PCB 缺陷检测精度的同时，仍然保持了良好的应用性。

4.5 对比实验与分析

在 PCB\_DATASET 数据集上，将 SGW-YOLOV8 与 Fast-RCNN<sup>[34]</sup>、SSD<sup>[35]</sup>、YOLOX<sup>[36]</sup>、YOLOV3<sup>[37]</sup>、YOLOV7<sup>[38]</sup>、PCB-YOLO<sup>[39]</sup>、YOLO-MBBi<sup>[40]</sup>、YOLOV5s、YOLOV8s 九种目标检测算法在相同实验环境下进行性能对比实验，以 AP、mAP 作为模型性能的评价指标，AP、mAP 值越高，检测性能越好。实验结果如表 2 所示。

表 2 PCB\_DATASET 数据集本文算法与其他算法结果对比

Table 2. Comparison of the Algorithm in This Paper with Other Algorithms on the PCB_DATASET							
Method	AP/%						MAP/%
	missing_hole	Mouse_bite	Open_circuit	Short	Spurious_copper	spur	
Fast-RCNN	81.67	79.23	80.6	85.68	76.24	74.8	79.7
SSD	75.57	56.28	54.62	80.04	73.24	67.82	67.92
YOLOX	98.6	95.26	95.35	94.1	96.77	98.44	96.42
YOLOV3	99.5	97.2	97.68	96.54	94.31	97.82	97.18
YOLOV7	98.88	97.25	96.52	95.52	97.26	98.34	97.3
PCB-YOLO	99.8	96.25	93.25	94.1	98.31	96.05	96.3
YOLO-MBBi	98.4	92.7	97.56	98.2	96.36	95.9	96.52
YOLOV5s	98.95	95.74	93.25	90.23	93.41	88.98	93.43
YOLOV8s	96.1	94	92.5	93.8	98.58	94.3	94.88
(ours)	99.46	98.44	98.78	98.2	98.42	97.82	98.52

从表 2 可知，本文提出的 SGW-YOLO 算法相比现有方法具有显著优势。PCB-YOLO 虽然通过 K-means+算法优化了 anchor 设计，并引入深度可分离卷积(DwConv)压缩模型体积，同时使用 EIoU 损失函数优化边界框回归，使得在 missing\_hole 类别上取得了 99.8%的高精度，但在 open\_circuit 和 short 类别上表现相对较弱（分别为 93.25%和 94.1%），表明其在不同类型缺陷的检测能力上存在不平衡。YOLOV7 通过采用 ELAN 特征提取结构和更深的网络层次，在整体 mAP 上达到了 97.3%的较好效果。然而，其过深的网络结构反而不利于小目标特征的保留，这一点从其在小尺寸缺陷（如 mouse\_bite 的 97.25%和 short 的 95.52%）的检测效果上可以得到验证。YOLO-MBBi 创新性地结合了 MBConv 骨干网络和 BiFPN 特征融合网络，整体 mAP 达到 96.52%。但由于 missing\_hole 和 spurious\_copper 这两类缺陷在形态特征上的相似性，导致在这两个类别上分别出现了 98.4%和 96.36%的检测结果，说明其特征区分能力还有提升空间。a

相比之下，本文提出的 SGW-YOLO 算法通过引入 Swin Transformer 增强特征提取能力，结合 GAM 注意力机制突出目标区域特征，以及采用 WIoU 损失函数优化边界框回归，在整体 mAP 上达到了 98.52%的最优性能。特别值得注意的是，对于形态相似、易混淆的 missing\_hole 和 spurious\_copper 两类缺陷，SGW-YOLO 分别实现了 99.46%和 98.42%的高精度检测，表明其具有出色的特征区分能力。在其他各类缺陷上，如 mouse\_bite（98.44%）、open\_circuit（98.78%）、short（98.2%）和 spur（97.82%），也都达到了较高的检测精度，展现出了优异的通用性能。

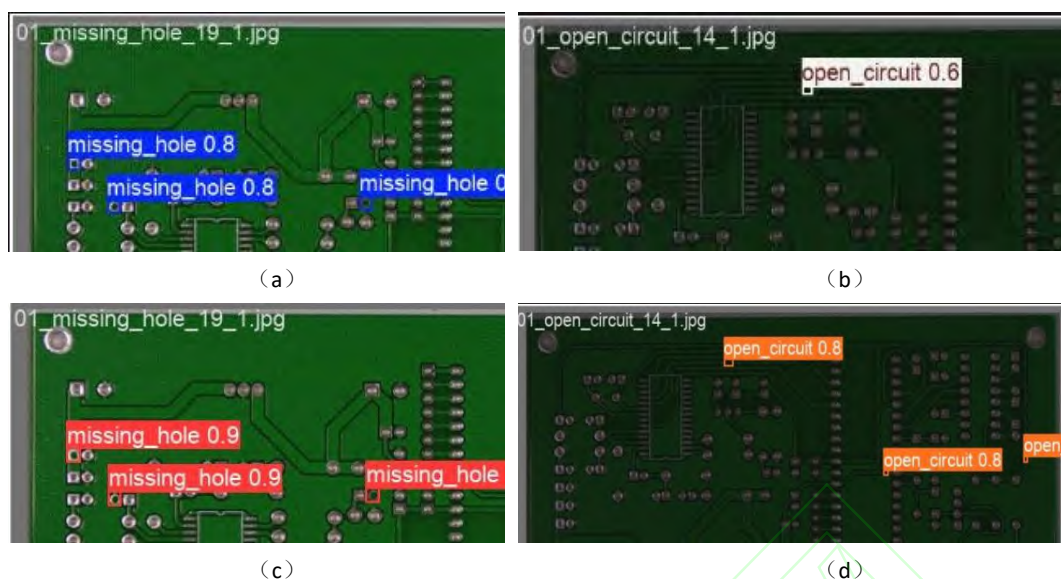


图9 PCB\_DATASET 数据集检测效果可视图对比

(a) (b) 为 YOLOV8s 检测效果图, (c) (d) 为 SGW-YOLO 检测效果图

Fig. 9: Comparison of Detection Effect Visualizations on the PCB\_DATASET Dataset(a) (b) Detection effect images for YOLOV8s, (c) (d) Detection effect images for SGW-YOLO.

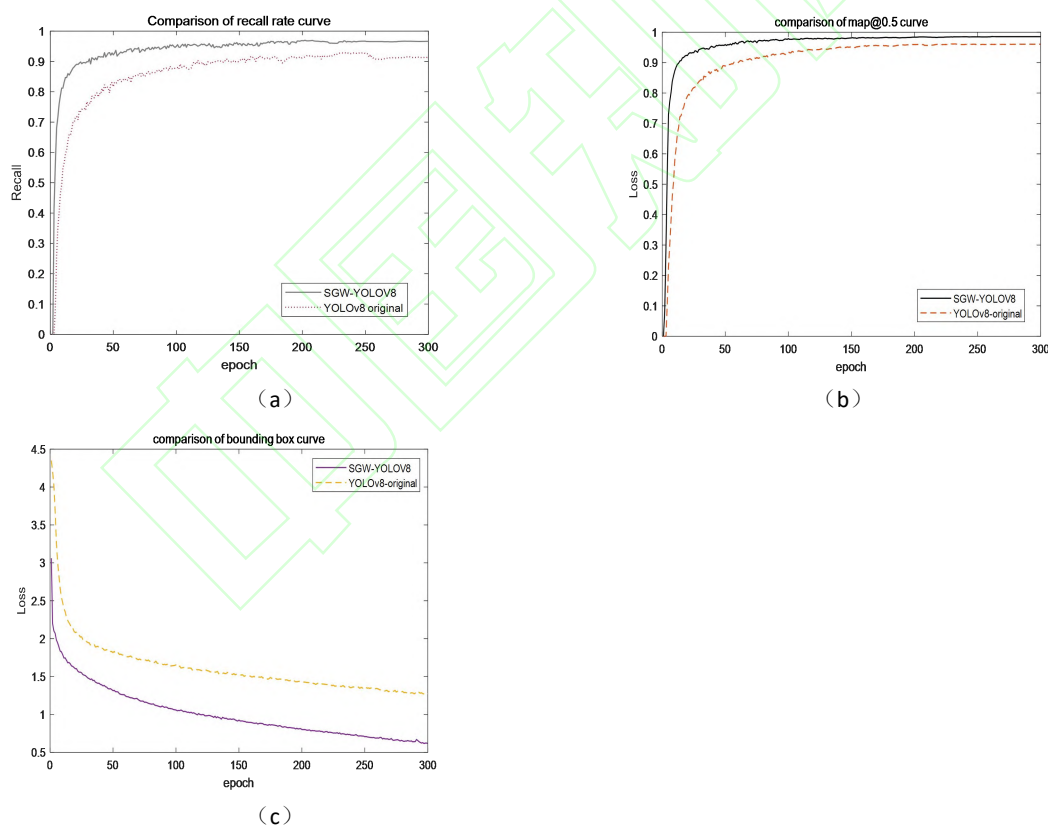


图10 改进前后性能指标结果对比

Figure 10: Comparison of performance indicators before and after improvement; (a) The diagram of Comparison of Recall curve; (b) The diagram of Comparison of map@0.5curve; (c) The diagram of Comparison of Loss curve

由图9与图10的实验结果可知, SGW-YOLO 算法在 PCB 缺陷检测任务上相较于基线 YOLOV8s 算法有显著的性能提升。具体来说, SGW-YOLO 算法的平均精度 (mAP) 达到



了 98.52%，比 YOLOV8s 的检测精度高出 3.64%。此外，SGW-YOLO 在 F1 值、不同缺陷种类的平均召回率（mR）和不同缺陷种类的平均精确率（mAP）方面也分别也得到了提升，这验证了 SGW-YOLO 优化策略的有效性。

另外，通过引入 Swin Transformer 模块和 GAM 注意力机制的优化策略，SGW-YOLO 算法在特征提取和目标关注方面表现出色。Swin Transformer 模块通过其窗口注意力机制有效捕捉图像的全局信息，增强了模型对细节和全局特征的理解能力，显著提升了对微小缺陷的检测精度。而 GAM 注意力机制通过自适应地增加和减少有用的特征信息和冗余的背景信息，显著提升了对鼠咬和毛刺缺陷的检测精度，这两种优化策略相辅相成。改进的 WIoU 损失函数进一步增强了模型在小目标及复杂背景下的回归性能，使得特征融合层末端的边界框预测更加准确，尤其是在微小缺陷的 PCB 检测中，此方法显著提升了检测精度。

综上所述，SGW-YOLO 算法在 PCB 缺陷检测任务中展现出了卓越的性能，在检测精度上有所提升的同时,也保持了较高的检测速度，证明了其在实际工业应用中的潜力和价值。

为验证 SGW-YOLO 在 PCB 缺陷检测任务中的适用性，选择 DeepPCB 数据集进行实验，由于初始数据集只有 1500 张图片，将其扩充至 4500 张图片后，按 9: 1 随机划分为训练集与验证集。实验结果如表 3 所示。SGW-YOLO 在 DeepPCB 数据集上的精度为 97.11%，相较一些主流算法都有较大的提升。图 11 为本文算法在 DeepPCB 数据集的检测可视图。

表 3 DeepPCB 数据集本文算法与其他算法结果对比

Table 3. Comparison of Results between Our Algorithm and Other Algorithms on DeepPCB

Method	AP/%						MAP/%
	missing_hole	Mouse_bite	Open_circuit	Short	Spurious_copper	spur	
YOLOV3	97.69	92.28	93.62	91.5	94.36	88.68	93.02
YOLOV7	95.68	96.08	95.12	95.85	86.22	92.16	93.52
YOLOV5s	94.62	94.82	93.84	95.16	93.72	96.26	94.74
YOLOV8s	97.38	94.82	96.24	94.18	94.2	94.32	95.19
(ours)	98.62	97.86	96.28	96.36	98.72	97.82	97.61

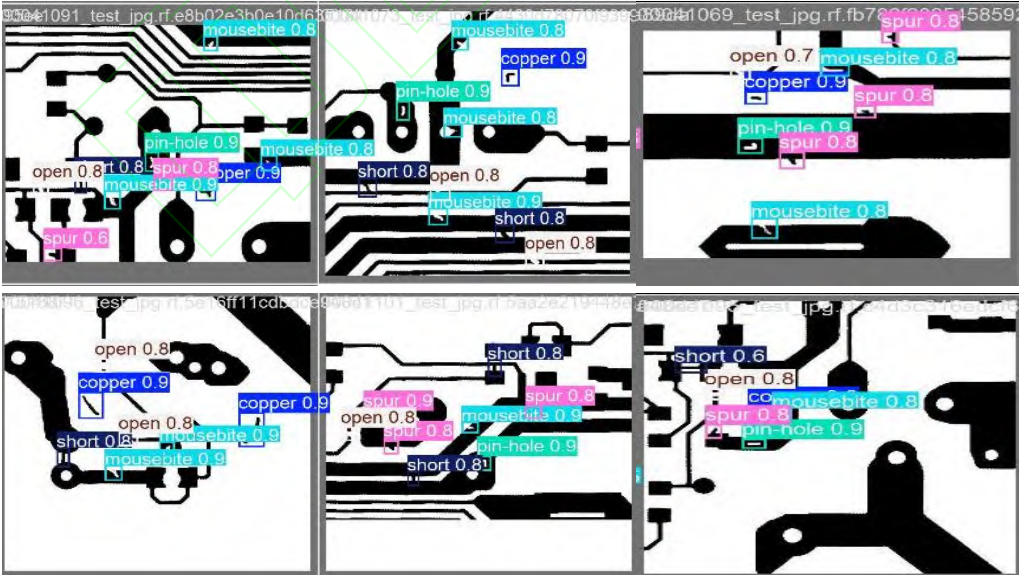


图 11 DeepPCB 数据集检测效果可视图

Figure 11 : Visual representation of detection effect on DeepPCB dataset

由表 3 与图 11 可知, SGW-YOLOV8 可以在小缺陷检测任务中发挥其良好的检测性能的同时保持精确的定位以及较高的精度, 表明了本文所提出的算法在面向 PCB 工业缺陷检测任务时能保证优秀的检测效果。

## 5 总结

本研究针对印刷电路板 (PCB) 表面缺陷检测的难题, 提出了一种深度学习算法—SGW-YOLOV8, 该算法基于 YOLOv8 的改进版本。通过集成 Swin Transformer 模块、全局注意力机制 (GAM), 以及优化的 WIoU 损失函数显著提升了 PCB 缺陷检测的准确性和效率。实验表明, SGW-YOLO 在两个公开数据集上的平均精度 (mAP) 达到 98.52%, 较基线 YOLOv8s 算法提升了 3.64%。此外, 在 F1 得分、平均召回率 (mR) 和平均精确率 (mP) 方面均有显著提高。这些结果证实了 SGW-YOLO 在提高检测精度方面的有效性。总体而言, SGW-YOLO 通过创新的网络结构和损失函数优化, 在 PCB 缺陷检测任务中实现了高精度和高效率。然而, 为了本文方法能够更好地应用于工业场景, 在未来的研究中, 将重点致力于在保证不降低精准度的前提下, 通过模型压缩、剪枝等技术去减少模型的计算量以适应资源受限的计算设备。

## 参考文献

- [1] Wang F, Yue Z, Liu J, et al. Quantitative imaging of printed circuit board (PCB) delamination defects using laser-induced ultrasound scanning imaging[J]. Journal of Applied Physics, 2022(5):131.
- [2] Hecht, Oded, Giora Dishon. "Automatic optical inspection (AOI)[C]. International Electronic Manufacturing Technology Symposium.. IEEE, 1990.
- [3] 黄璇. PCB 元器件自动光学检测技术研究[J]. 华东科技, 2022, (09): 51-53.  
Huang X. Research on Automatic Optical Inspection Technology for PCB Components [J]. Huadong Science and Technology, 2022, (09): 51-53
- [4] PARK JH, KIM YS, SEO H, et al. Analysis of training deep learning models for PCB defect detection[J]. Sensors, 2023, 23(5): 2766.
- [5] Zhang, L X, Chen J S, et al. LDD-Net: Lightweight printed circuit board defect detection network fusing multi-scale features[J]. Engineering Applications of Artificial Intelligence 129 (2024): 107628.
- [6] 郭艳, 王智文, 赵润星. YOLO-POD: 基于多维注意力机制的高精度 PCB 微小缺陷检测算法[J]. 电子学报, 2024, 52(07): 2515-2528.  
Guo Y, Wang Z, Zhao R X. YOLO-POD: High precision PCB micro defect detection algorithm based on multidimensional attention mechanism [J]. Acta Sinica, 2024, 52 (07): 2515-2528
- [7] 王莹, 王晶, 高岚, 等. 一种注意力机制优化方法及硬件加速设计[J]. 电子学报, 2023, 51(4): 1021-1029  
Wang Y, Wang J, Gao L, et al. An Optimization Method for Attention Mechanism and Hardware Acceleration Design [J]. Acta Sinica, 2023, 51 (4): 1021-1029

- [8] HE J B, ERFANI S, MA X J, et al. Alpha-IoU: A family of power intersection over union losses for bounding box regression[EB/OL].(2021-10-26)[2023-08-01]. <http://arxiv.org/abs/2110.13675>
- [9] 宋涛,李程,熊海龙,等.基于元特征增强的小样本PCB缺陷检测[J].计算机集成制造系统,1-17[2025-01-08].  
Song T, Li Ch, Xiong H l, et al.Small sample PCB defect detection based on meta feature enhancement [J]. Computer Integrated Manufacturing System, 1-17 [2020-01-08]
- [10] YAN X P, CHEN Z L, XUA, et al. Meta r-cnn: Towards general solver for instance-level low-shot learning[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 9577-9
- [11] Andrei, V.S.: Unifying public datasets for insulator detection and fault classification in electrical power lines. <https://github.com/heitorcfelix/public-insulator-datasets> (2020). Accessed Sept 2022
- [12] Zhang, Z.-D.,Zhang, B., Lan, Z.-C.,Liu, H.-C.,Li, D.-Y.,Pei, L., et al.:FINet: an insulator dataset and detection benchmark based on synthetic fog and improved YOLOv5. IE EE Trans. Instrum. Meas. 71, 1–8 (2022)
- [13] 张莹, 邓华宣, 王耀南, 吴成中, 吴琳. 基于多通道特征融合学习的印制电路板小目标缺陷检测[J]. 仪器仪表学报.  
Zhang Ying, Deng Huaxuan, Wang Yaonan, Wu Chengzhong, Wu Lin. Small target defect detection of printed circuit boards based on multi-channel feature fusion learning [J]. Journal of Instrumentation
- [14] D. W, W. H, L. D, et al. YOLOv8 Improved Network for Remote Sensing Video Small Target Detection: 2023 11th International Conference on Information Systems and Computing Technology (ISCTech), 2023[C].2023.
- [15] Ge, Z.,Liu, S.,Wang, F.,Li, Z.,Yolox, S.J.:Exceeding YOLO series in 2021. arXiv:2107.08430 (2021)
- [16] Terven J, Cordova-Esparza D. A Comprehensive Review of YOLO Architectures in Computer Vision: From YOLOv1 to YOLOv8 and YOLO-NAS[J]. Mach. Learn. Knowl. Extr., 2023.
- [17] Lu S, Liu X, He Z, et al. Swin-Transformer-YOLOv5 for Real-Time Wine Grape Bunch Detection[J]. Remote Sensing in ViticultureII, 2022,14(22).
- [18] Z. L, Y. L, Y. C, et al. Swin Transformer: Hierarchical Vision Transformer using Shifted Windows: 2021 IEEE/CVF International Conference on Computer Vision (ICCV), 2021[C].2021.
- [19] Niu, Z., Zhong, G., Yu, H.: A review on the attention mechanism of deep learning. Neurocomputing 452, 48–62 (2021)
- [20] 谢国波,梁立辉,林志毅,等.改进YOLOv8n的轻量级水下目标检测算法[J].激光与光电子学进展,2024,61(24):384-395.  
Xie G B, Liang L G, Lin Zh Y, et al. Improved lightweight underwater target detection algorithm for YOLOv8n [J]. Laser and Optoelectronics Progress, 2024, 61 (24): 384-395
- [21] Liu Y, Shao Z, Hoffmann N. Global Attention Mechanism: Retain Information to Enhance Channel-Spatial Interactions[J]. 2021.
- [22] Sun, H., Li, B., Dan, Z., Wei, H., et al.: Multi-level feature interaction and efficient non-local

- information enhanced channel attention for image dehazing. *Neural Networks* 163, 10–27 (2023)
- [23] Khaw, Z.J.; Tan, Y.F.; Karim, H.A.; Rashid, H.A.A. Improved YOLOv8 Model for a Comprehensive Approach to Object Detection and Distance Estimation. *IEEE Access* 2024, 12, 63754–63767.
- [24] Gao, Y.; Liu, W.; Chui, H.-C.; Chen, X. Large Span Sizes and Irregular Shapes Target Detection Methods Using Variable Convolution-Improved YOLOv8. *Sensors* 2024, 24, 2560.
- [25] Zheng, Z.; Wang, P.; Liu, W.; Li, J.; Ye, R.; Ren, D. Distance-IoU Loss: Faster and Better Learning for Bounding Box Regression. *arXiv* 2019, arXiv:1911.08287.
- [26] Zhang, Y.F.; Ren, W.; Zhang, Z.; Jia, Z.; Wang, L.; Tan, T. Focal and Efficient IOU Loss for Accurate Bounding Box Regression. *Neurocomputing* 2022, 506, 146–157.
- [27] 吴磊, 储钰昆, 杨洪刚, 等. 面向铝合金焊缝DR图像缺陷的Sim-YOLOv8 目标检测模型[J]. *中国激光*, 2024, 51(16):29-38.
- Wu L, Chu Y K, Yang H G, et al Sim-YOLOv8 object detection model for DR image defects of aluminum alloy welds [J]. *Chinese Journal of Lasers*, 2024, 51 (16): 29-38
- [28] Tong, Z.; Chen, Y.; Xu, Z.; Yu, R. Wise-IoU: Bounding Box Regression Loss with Dynamic Focusing Mechanism. *arXiv* 2023, arXiv:2301.10051.
- [29] Lin, T.-Y., Goyal, P., Girshick, R., He, K., Dollár, P.: Focus loss for dense object detection. Included in: *Proceedings of IEEE International Conference on Computer Vision*, pages 2999-3007.
- [30] 胡琪涛, 邹启杰. 基于轻量化 ADS-YOLOv8n 的印刷电路板缺陷检测[J]. *激光与光电子学进展*.
- Hu Q T, Zou Q J. Defect detection of printed circuit boards based on lightweight ADS-YOLOv8n [J]. *Laser and Optoelectronics Progress*
- [31] Ding R, Dai L, Li G, et al. TDD-net: a tiny defect detection network for printed circuit boards[J]. *CAAI*
- [32] *Transactions on Intelligence Technology*, 2019, 4(2): 110-116.
- [33] Silva L H D, Azevedo, G O D, Fernandes, B J T, et al. Automatic Optical Inspection for Defective PCB Detection Using Transfer Learning[C]//2019 IEEE Latin American Conference on Computational Intelligence (LA-CCI), Guayaquil, Ecuador, 2019, pp. 1-6
- [34] Ren S Q, He K M, Girshick R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2017, 39(6): 1137-1149.
- [35] Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C]//Computer Vision – ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11 – 14, 2016, Proceedings, Part I 14. Springer International Publishing, 2016: 21-37.
- [36] Ge Z, Liu S, Wang F, et al. YOLOX: Exceeding yolo series in 2021[J]. *arxiv preprint arxiv:2107.08430*, 2021.
- [37] RDEMONJ, FARHADIA. YOLOv3: An incremental improvement[EB/OL]. (2018-04-08)[2022-12-14]. <https://arxiv.org/pdf/1804.02767>.
- [38] Wang C Y, Bochkovskiy A, Liao H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 7464-7475.
- [39] Tang J, Liu S, Zhao D, et al. PCB-YOLO: An improved detection algorithm of PCB surface



defects based on YOLOv5[J]. Sustainability, 2023, 15(7): 5963.

- [40] Du B W, Wan F, Lei G B, et al. YOLO-MBBi: PCB surface defect detection method based on enhanced YOLOv5[J]. Electronics, 2023, 12(13): 2821.



## 网络首发:

**标题:** SGW-YOLO: 多尺度融合优化的PCB缺陷检测算法

**作者:** 毛坤, 朱学军, 赖惠鸽, 余圻操, 熊垒垒, 杨明, 彭达

**收稿日期:** 2025-01-09

**录用日期:** 2025-02-10

**DOI:** 10.3788/LOP250474

## 引用格式:

毛坤, 朱学军, 赖惠鸽, 余圻操, 熊垒垒, 杨明, 彭达. SGW-YOLO: 多尺度融合优化的PCB缺陷检测算法[J]. 激光与光电子学进展, 2025, 62(10): 1012004.

网络首发文章内容与正式出版的有细微差别, 请以正式出版文件为准!

---

## 您感兴趣的其他相关论文:

### 融合多尺度特征与注意力机制的眼底图像血管分割

马光岑 周金治 贺浩洋 李赛凤

西南科技大学信息工程学院, 四川 绵阳 621000

激光与光电子学进展, 2025, 62(4): 0417001

### 无监督领域自适应的管状容器表面缺陷检测

张广志 李慧敏 宋旭宁

东华大学机械工程学院, 上海 201620

激光与光电子学进展, 2025, 62(2): 0212007

### 基于改进U-Net网络的树种精细分类

蔡玉林 高洪振 范晓乐 徐慧宇 刘正军 张赓

山东科技大学测绘与空间信息学院, 山东 青岛 266590

激光与光电子学进展, 2025, 62(2): 0228002

### 基于改进DETR3D的环视图像三维目标检测

张钰涵 黄妙华 陈庚尧 李延洲 吴一鸣

武汉理工大学现代汽车零部件技术湖北省重点实验室, 湖北 武汉 430070

激光与光电子学进展, 2025, 62(2): 0212001

### 基于深度学习的太阳能电池板表面缺陷检测及分类

涂俊博 曾佳林 唐越新 吴晨曦 刘晓宇

四川大学机械工程学院, 四川 成都 610065

激光与光电子学进展, 2025, 62(2): 0237013