



计算机科学与探索

Journal of Frontiers of Computer Science and Technology

ISSN 1673-9418, CN 11-5602/TP

## 《计算机科学与探索》网络首发论文

题目：基于机器视觉的 PCB 缺陷检测算法研究综述  
作者：杨思念，曹立佳，杨洋，郭川东  
网络首发日期：2024-12-05  
引用格式：杨思念，曹立佳，杨洋，郭川东. 基于机器视觉的 PCB 缺陷检测算法研究综述[J/OL]. 计算机科学与探索.  
<https://link.cnki.net/urlid/11.5602.TP.20241204.1549.008>



**网络首发：**在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

**出版确认：**纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

# 基于机器视觉的 PCB 缺陷检测算法研究综述

杨思念<sup>1</sup>, 曹立佳<sup>1,2,3</sup>, 杨洋<sup>4</sup>, 郭川东<sup>2,3,4+</sup>

1. 四川轻化工大学 计算机科学与工程学院, 四川 宜宾 644000

2. 人工智能四川省重点实验室, 四川 宜宾 644000

3. 企业信息化与物联网测控技术四川省高校重点实验室, 四川 宜宾 644000

4. 四川轻化工大学 自动化与信息工程学院, 四川 宜宾 644000

+ 通信作者 E-mail: guochuandong@suse.edu.cn

**摘要：**印刷电路板（Printed Circuit Board, PCB）作为电子产品的核心组成部分，其质量直接影响产品的可靠性。随着电子产品朝着更轻、更薄、更精密的方向发展，基于机器视觉的 PCB 缺陷检测面临诸如微小缺陷难以检测等挑战。为深入研究 PCB 缺陷检测技术，根据其发展历程对各阶段的算法进行了详细探讨。首先，指出了该领域面临的主要挑战，并介绍了传统 PCB 缺陷检测方法及其局限性。接着，从传统机器学习和深度学习两个角度系统回顾了近几年 PCB 缺陷检测所采用的方法及其优缺点。随后，对 PCB 缺陷检测算法常用的评价指标和主流数据集进行了归纳，并对近三年在 PCB Defect、DeepPCB 和 HRIPCB 三个数据集上的最新研究方法进行了性能比较，分析了产生差异化的原因。最后，基于当前现状和亟待解决的问题，对未来的发展趋势进行了展望，旨在为后续相关研究提供参考。

**关键词：**PCB；缺陷检测；机器视觉；机器学习；深度学习

**文献标志码：**A **中图分类号：**TP391

## Review of PCB Defect Detection Algorithm Based on Machine Vision

YANG Sinian<sup>1</sup>, CAO Lijia<sup>1,2,3</sup>, YANG Yang<sup>4</sup>, GUO Chuandong<sup>2,3,4+</sup>

1. School of Computing Science and Engineering, Sichuan University of Science & Engineering, Yibin, Sichuan 644000, China

2. Artificial Intelligence Key Laboratory of Sichuan Province, Yibin, Sichuan 644000, China

3. Key Laboratory of Higher Education of Sichuan Province for Enterprise Informationalization and Internet of Things, Yibin, Sichuan 644000, China

4. School of Automation and Information Engineering, Sichuan University of Science & Engineering, Yibin, Sichuan 644000, China

**基金项目：**中国高校产学研创新基金（2021ZYA11002）；四川轻化工大学科研创新团队计划（SUSE652A011）；四川轻化工大学自然科学基金（2024RC03）；四川轻化工大学研究生创新基金（Y2024119）；企业信息化与物联网测控技术四川省高校重点实验室开放基金（2024WZY01）。

This work was supported by the Industry-University-Research Innovation Fund for Chinese Universities (2021ZYA11002), Sichuan University of Science & Engineering Research Innovation Team Program (SUSE652A011), Sichuan University of Science & Engineering Natural Science Fund (2024RC03), and Sichuan University of Science & Engineering Graduate Innovation Fund (Y2024119), Supported by the Opening Fund of Key Laboratory of Higher Education of Sichuan Province for Enterprise Informationalization and Internet of Things(2024WZY01).

**Abstract:** Printed Circuit Board (PCB) as a core component of electronic products, its quality directly affects the reliability of the product. As electronics move toward lighter, thinner, and more sophisticated products, machine vision-based PCB defect detection faces challenges such as the difficulty of detecting tiny defects. In order to further study the PCB defect detection technology, the algorithms of each stage are discussed in detail according to the development history. First, the main challenges in the field are pointed out, and traditional PCB defect detection methods and their limitations are introduced. Then, from the perspective of traditional machine learning and deep learning, we systematically reviewed the PCB defect detection methods and their advantages and disadvantages in recent years. Then, we summarize the commonly used evaluation indicators and mainstream data sets of PCB Defect detection algorithms, and compare the performance of the latest research methods on PCB defect, DeepPCB and HRIPCB data sets in the past three years, and analyze the reasons for the differences. Finally, based on the current situation and the problems to be solved, the future development trend is prospected, aiming at providing reference for the subsequent relevant research.

**Key words:** PCB; defect detection; machine vision; machine learning; deep learning

印刷电路板 (Printed Circuit Board, PCB) 作为电子产品的核心组成部分, 承载着电子元器件之间的连接和信号传输功能, 且产品的性能和稳定性高度依赖 PCB 的质量和可靠性<sup>[1]</sup>。随着人工智能、5G、云计算、数字化等新一代信息技术的不断发展和普及, 电子产品的尺寸变得越来越小, PCB 也日益向智能化、轻量化、高密度化和高集成度化方向发展<sup>[2]</sup>。工艺复杂的同时, 难以避免地导致了 PCB 质量问题。因此, 为了保障电子产品的性能, 对 PCB 进行缺陷检测至关重要。

PCB 元件尺寸的持续缩小、元件密度的增加以及制造过程的复杂性和多样性, 使在印制 PCB 时易受机械摩擦、静电干扰和化学腐蚀等多种因素影响<sup>[3]</sup>。这些因素容易导致 PCB 存在诸多缺陷。图 1 展示了几种常见的 PCB 缺陷类型, 如缺孔、鼠咬、开路、短路、杂散和伪铜等<sup>[4]</sup>。这些缺陷严重损害了 PCB 的质量和性能, 如果不能及时发现和解决这些问题, 可能会直接影响到电子设备的正常运行和使

用寿命。因此, 在制造过程中需要快速准确地检测和定位出 PCB 缺陷。

随着技术的进步和应用场景的多样化, PCB 缺陷检测算法经历了从传统目视检测到基于深度学习的逐步演变<sup>[5]</sup>。传统目视方法是一种主观判断方式, 主要依赖于经验和感知评估, 容易受到人为因素的影响, 因此逐渐被淘汰<sup>[6]</sup>。传统机器视觉检测算法通常依赖特征提取和模式识别技术, 如边缘检测、形状匹配、模板匹配等<sup>[7]</sup>, 适用于较为简单和结构化的检测任务, 具有较高的精确性和稳定性。相较而言, 基于深度学习的检测算法利用深度神经网络进行端到端的学习和特征提取, 从大量数据中学习并提升检测的准确性和泛化能力, 在识别复杂缺陷模式和多样化 PCB 设计方面表现出色<sup>[8]</sup>。这两种算法各有优势: 传统机器视觉算法在简单场景和特定问题上效果显著, 而深度学习算法更适合处理复杂、多变的检测任务, 能够提高检测的自动化程度和整体效率<sup>[9]</sup>。




图 1 PCB 中常见的缺陷：(a)缺孔；(b)鼠咬；(c)开路；(d)短路；(e)杂散；(f)伪铜

Fig.1 Common defects in PCBs:(a) Missing\_hole;(b) Mouse\_bite;(c) Open\_circuit;(d) Short;(e) Spur;(f) Spurious copper

本文围绕 PCB 缺陷检测算法设计相关问题进行深入研究，并对现有的算法进行评估分析，具体贡献如下：

1) 调研了近年来最新的 PCB 缺陷检测技术进展，并按其发展分为基于传统机器学习和基于深度学习两大类，着重讨论了深度学习技术在 PCB 缺陷检测领域的广泛应用，并深入分析这些方法的优势和局限性，以帮助读者更清晰地区分和理解不同的 PCB 缺陷检测算法。

2) 调研了 PCB 缺陷检测领域常用的评价指标和数据集，同时探讨了每种指标评估的侧重点以及不同数据集的特点，这将有助于读者更有针对性地提升算法性能，为后续的研究提供参考。

3) 对近三年 PCB 缺陷检测算法在多种主要数据集上的表现进行了统计分析，并初步探讨了导致性能差异的原因。

4) 对当前尚未解决的问题及未来的研究方向进行了预测和展望，旨在吸引科研人员关注并推动 PCB 缺陷检测算法的实际应用进程。

## 1 问题与挑战

### 1.1 PCB 缺陷检测面临的主要挑战

PCB 上的缺陷形式繁多，包括开路、短路、鼠咬等，每种缺陷都有不同的特征，因此检测系统必须具备准确识别和分类的能力。同时，缺陷的尺寸可能微小至微米级，这要求检测系统具有极高的分辨率和精度。此外，生产环境中的光照变化、灰尘等干扰因素可能影响检测效果，系统需要具备强大的抗干扰能力。在高速生产线上，检测系统还需实时处理大量数据，平衡检测精度和处理速度是一大挑战。最后，由于高质量标注数据集稀缺，模型的训练和泛化能力受到限制，需要大量多样化的数据来提升系统在实际应用中的表现性和鲁棒性。总的来说，PCB 缺陷检测面临的主要挑战包括以下几个方面：

1) 电路板复杂性带来的问题：体现在结构复杂、背景复杂和材质多样性上。复杂的结构导致了多样化的缺陷类型和形状，这对算法的准确性提出了挑战，需要系统能够有效识别并区分这些不同类型的缺陷。复杂的背景则容易引入如光照变化、阴影等噪声干扰，因此检测系统需要具备



强大的抗干扰能力,能够从复杂背景中准确提取关键信息。此外,电路板的材质多样,包括陶瓷、柔性材料等,也增加了检测的复杂度。

2)微小缺陷难以检测问题:检测微小缺陷是PCB缺陷检测技术中长期以来面临的重要挑战。PCB上如开路 and 裂纹等缺陷通常只有十几微米大小,且这些微小缺陷往往与背景噪声混合在一起,然而检测系统很难达到足够高的分辨率。

3)数据集稀少问题:目前的公共数据集大多是人工合成的,且缺陷类型有限,无法完全涵盖实际生产过程中可能出现的各种PCB缺陷,这使得基于公共数据集训练的检测网络不能很好的应用于实际的工业现场。

4)检测精度和速度平衡问题:在PCB缺陷检测中,确保高精度的同时又要保持快速的检测速度是一项挑战。现有的检测算法通常需要在精确性和实时性之间进行权衡。提高检测精度往往需要更复杂的算法和更多的计算资源,这可能导致检测速度的降低。因此,设计能够在保证高精度的同时实现快速检测的算法和系统,是PCB缺陷检测技术持续优化的方向之一。

5)在线检测的实时性性能问题:在实际的工业生产环境中,需要能够实时检测PCB板的缺陷,以确保生产效率和质量。然而,实现在线实时检测面临着多重挑战。首先,实时性要求算法能够在短时间内处理大量数据,并且快速准确地识别和分类缺陷。这要求检测系统具备高效的计算能力和优秀的算法设计。其次,在线检测还需要考虑到设备的实际部署和操作环境。例如,工业生产线上的光照、背景噪声等因素会影响检测系统的性能稳定性和准确性。

## 1.2 传统PCB缺陷检测算法及其不足之处

早期的PCB缺陷检测方法包括人工目测法、电气检测法和红外检测法<sup>[10]</sup>。人工目测法通过对PCB板进行目测的方式来检测缺陷,受一定主观因素的影响。存在判断标准难以统一、人员成本投入高、检测效率低下、数据集合困难等诸多问题<sup>[11]</sup>,难以满足企业的生产需求。电气检测法和红外检测法对设备要求高且能检测出的缺陷种类有限<sup>[12]</sup>,所以在现代化PCB检测行业中受限。

随着传统目标缺陷检测方法的缺点日益明显,机器视觉开始应用于半导体行业<sup>[13]</sup>。为了提高PCB焊点检测效率,Wang等<sup>[14]</sup>开始关注自动阈值分割方法,该方法将图像划分为许多小块(区域),分别计算每个小块的阈值,然后使用计算出的阈值对小块进行分割,以实现细节的准确获取。在此基础上,Fang等<sup>[15]</sup>为了解决现有阈值方法的局限性,提出了新颖的基于有限差分的阈值分割方法,并设计了基于三角形图像网格模型和有限差分离散方法的最佳阈值计算公式,以寻求适用于PCB分割的最优阈值。但所用三角形图像网格模型的实用性较低,只能用于电路图像分割。接着,Zhu等<sup>[16]</sup>改进了基本的梯度算子,开发出先进的梯度检测算子,并结合Canny算子优秀的最小响应和定位能力,实现了自动生成PCB边缘图,从而显著提升了PCB缺陷检测的效能。为了给后续识别和分类提供数据辅助,Raihan等<sup>[17]</sup>提出了一种基于图像减法的裸板缺陷检测方法,通过检测减影后图像上的残留特征,能以非常快的速度检测出有缺陷的PCB板。但图像的分辨率会直接影响到检测的准确性。Annaby等<sup>[18]</sup>通过将匹配过程中的二维图像转换为一维特征描述符,并采用改进的低复杂度归一化互相关方案,成功实现了对PCB中缺失集成电路(Integrated Circuit, IC)位置的准确识别。表1对基于传统图像处理的方法进行了分析总结。

表 1 基于传统图像处理的 PCB 缺陷检测主要方法对比

Table 1 Comparison of main methods for PCB defect detection based on traditional image processing			
文献	方法	优点	缺点
[14]	基于自动阈值分割算法和计算机形态学的焊点图像处理法	效率高、精度高，能够满足 PCB 焊点检测的要求	对缺陷尺度和旋转变化不敏感
[15]	有限差分的阈值分割法	提高了阈值法的抗噪性能、灰度精度、分割精度，保证灰度范围不重叠	实用性较低，只能用于电路图图像分割
[16]	边缘检测法	改进了基本梯度算子，获得了先进的检测梯度算子，提供了快速准确地检测 PCB 上圆孔的方法	需先验知识
[17]	图像相减法	检测速度快	检测准确度受图像分辨率的影响较大
[18]	低复杂度 NCC 法	在变换域实现 NCC,对噪声具有鲁棒性	计算量较大

上述传统图像处理方法通常依赖于预先定义的规则和阈值来识别缺陷，虽然在某些特定的环境下取得了良好的效果，但面对复杂的 PCB 板上电路变化和缺陷类型多样时，这些规则往往不能涵盖所有情况。例如，不同的光照条件、背景噪声或器件的几何变化都可能影响检测的准确性和鲁棒性。此外，随着 PCB 制造技术的进步和电子器件的微小化，传统方法往往无法有效处理越来越小、越来越复杂的缺陷。相比之下，机器学习作为一种自动化学习和模式识别技术，自 20 世纪 80 年代开始出现。与传统方法相比，机器学习通过数据驱动的方法可以自动学习和优化检测策略，而无需依赖预设的规则<sup>[19]</sup>。

2 基于机器学习的 PCB 缺陷检测

近些年，机器学习技术在 PCB 缺陷检测领域得到了广泛应用。采用机器学习进行 PCB 缺陷检测的方法主要可以分为传统机器学习和深度学习两种方式。

2.1 基于传统机器学习的 PCB 缺陷检测

基于传统机器学习的 PCB 缺陷检测通常依赖于特征提取、分类和模式识别技术<sup>[20]</sup>。这些方法首先通过图像处理技术提取 PCB 图像中的关键特征，如纹理、颜色和形状，然后应用传统机器学习算法，如支持向量机（Support Vector Machine, SVM）、决策树和 k 近邻（k-Nearest Neighbors, k-NN）<sup>[21]</sup>等，对这些特征进行分类和分析。

对于那些外观上没有规律、无法分类的缺陷，

Liao 等<sup>[22]</sup>开发了一种基于统计学习策略的 PCB 自动检测系统。该系统通过使用部分 Hausdorff 距离来确定缺陷的位置，并利用 SVM 分类器对缺陷模式进行分类，最终通过比较块状概率分布能有效识别区域性缺陷。但前期工作比较复杂，需要大量标注良好的训练数据。随后，Yuk 等<sup>[23]</sup>针对同样的问题设计了一种新型的非参照方法，该方法通过学习故障模式并生成加权核密度估计（Weighted Kernel Density Estimation, WKDE）图，能够在 PCB 检测中学习各种故障模式，而不需要考虑特定的故障类型。然而，在工业应用中，收集和标记大量缺陷样本通常既困难又不切实际。

为了进一步实现自动化，Ur Rehman 等<sup>[24]</sup>提出了一种新方法，即在进行 PCB 类型识别之前启动缺陷检测过程。该方法利用局部特征检测器 SURF 和 ORB，并结合方向数据，将 PCB 图像转换为适用于缺陷检查的参考图像，从而实现 PCB 的识别。然而，该方法也有一定局限性，主要体现在缺陷检测过程需要改进，因为它仅依赖于检测 PCB 中缺失的组件或组件表面上的划痕。Song 等<sup>[25]</sup>提出了一种用于 PCB 自动光学检测的焊点缺陷分类方法。该方法包括两个阶段：离线阶段和在线阶段。离线阶段使用遗传算法优化特征提取区域；在线阶段则在获得元件图像后，利用这些特征提取区域对焊点图像进行分割，并从中提取颜色特征，最后通过 SVM 分类焊点缺陷类型。但所提出的方法仍存在一些问题。

首先,用于缺陷类型分类的元件仅限于电容器和电阻器。其次,仅使用 RGB 照明下获得的分量图像进行缺陷类型分类,这一局限性也影响了方法的适用性。

为了满足 IC 焊点检测的需求, Cai 等<sup>[26]</sup>基于鲁棒主成分分析 (Robust Principal Component Analysis, RPCA) 的思想提出了一种新型的 IC 焊点检测

方法,用于评估 IC 焊点的质量,并基于外观模型定义缺陷评分。Alaoui 等<sup>[27]</sup>也采用主成分分析法 (Principal Component Analysis, PCA) 和离群值识别算法精确检测 PCB 板上的电容缺陷,实现鲁棒性检测。虽然以上两种方法都取得了较好的结果,但它们在检测时间方面均存在一定的局限性。表 2 对基于传统机器学习的方法进行了分析总结。

表 2 传统机器学习方法在 PCB 缺陷检测中的对比

Table 2 Comparison of traditional machine learning methods in PCB defect detection

文献	介绍	优点	缺点
[22]	基于统计学习策略的 PCB 自动检测系统	可识别外观上没有规则性的缺陷,方便扩展到未来 PCB 检测任务中未知缺陷的处理	前期需要大量标注良好的训练数据
[23]	新型非参照方法	可以学习 PCB 检测中各种故障模式,无需考虑特定的故障类型	用来训练的缺陷类型太少
[24]	模式识别方法	具有较好的速度和精度	能检测到的缺陷种类较单一
[25]	SMT 缺陷类型分类方法	在特征提取区域的设置上取得了比同时期方法更好的分类性能	缺陷类型分类的元件仅限于电容器和电阻器
[26]	鲁棒主成分分析 (RPCA) 法	有先验知识,检测性能好	耗时较长
[27]	主成分分析法 (PCA)	能检测特定组件级缺陷并减少传统测试点的数量	耗时较长

由上可看出,传统机器学习在 PCB 缺陷检测领域取得了一定成果,研究者们探索了统计学习、非参照方法和无缺陷样本学习等策略,以提升检测效率和模型的泛化能力,但这些方法也存在各自的局限性。

首先,传统机器学习方法依赖人工设计的特征,因而对不同缺陷类型的泛化能力较弱。尽管统计学习和非参照等方法在一定程度上有所改进,但这些方法仍需要预先设计特征或通过复杂的统计模型分析图像的特征分布,且难以应对复杂、不规则的缺陷类型。其次,传统机器学习方法往往需要大量高质量的缺陷样本,且标注成本高昂,实际应用中缺陷样本的收集较为困难,这就极大地限制了模型的性能和推广。无缺陷样本学习为此提供了一种解决思路,即通过正常样本的异常检测或重建误差来识别缺陷,减少了对缺陷样本的依赖,但在检测细微缺陷或不明显缺陷时的表现可能不足。此外,传统机器学习方法在复杂性与效率之间存在矛盾。尽管有些方法提高了检测精度,但计算开销大,难以

在工业生产中实现实时应用。即便是采用主成分分析等方法来提升检测精度,仍难以满足生产实时性的需求。最后,许多传统机器学习方法的效果往往依赖于特定缺陷类型(如焊点或电容缺陷)。这些方法在面对其他缺陷类型时需要重新设计特征或调整模型,适用性受到限制。

综上所述,尽管传统机器学习方法在 PCB 缺陷检测领域有所发展,但在自动化、泛化性、实时性和适用性方面仍面临诸多挑战。例如,传统机器学习方法在处理复杂和非线性缺陷时的能力有限,对数据质量要求较高,容易在样本分布不均匀时出现过拟合。此外,传统机器学习方法对特征工程的过度依赖也限制了其在实时检测和大规模应用中的实现。而基于深度学习的 PCB 缺陷检测方法的出现则一定程度上改善了这些问题,提供了更强的特征自动提取能力和更好的泛化性能,同时减少了对数据预处理的依赖,从而显著提升了检测的准确性和效率。



## 2.2 基于深度学习的 PCB 缺陷检测

深度学习作为机器学习和人工智能的子领域,被认为是工业 4.0 的核心技术之一<sup>[28]</sup>。2012 年,深度神经网络 AlexNet 在 ImageNet 竞赛中取得了显著的成绩,推动了深度学习在计算机视觉领域的广泛应用<sup>[29]</sup>。随后,人们开始将深度学习技术应用于工业缺陷检测领域,这也成为 PCB 缺陷检测领域中最重要研究热点之一。

针对传统缺陷检测方法依赖模板和计算量大的局限性,You 等<sup>[30]</sup>提出了一种基于生成对抗网络 (Generative Adversarial Network, GAN) 的 PCB 缺陷检测方案,采用遥感领域的边缘增强超分辨率 GAN (EESRGAN)<sup>[31]</sup>算法对 PCB 图像进行增强,并通过超分辨率检测对重构图像进行分析。该方法使用不同预处理模型处理 PCB 图像,并通过端到端的方式比较训练后的 PCB 缺陷识别效果。接着,Liu 等<sup>[32]</sup>通过改进 SRGAN<sup>[33]</sup>网络,并提出了一种基于模型感知场改进和特征融合原理的高效 PCB 缺陷图像超分辨率重建<sup>[34]</sup>算法,以获得更高分辨率的 PCB 缺陷图像。改进的算法不仅提升了图像重建效果,还降低了模型的空间复杂度。An 等<sup>[35]</sup>提出了一种基于 LPPViT 原理的新型 ViT 模型。该模型优先考虑鲁棒性,同时充分利用 PCB 图像中不同区域的跨关系。此外,还引入了随机屏蔽或替换某些块的策略,以增强不同图像区域之间的相互理解。最终,该模型通过标签平滑策略进行训练,以提高其鲁棒性。虽然以上三种方法都提升了检测性能,但它们仍然存在数据集不够丰富的局限性。针对裸 PCB 缺陷检测领域存在的问题,Han 等<sup>[36]</sup>提出了一种基于高斯金字塔的多尺度特征提取方法,该方法包括多尺度灰度共现矩阵特征、多尺度方向投影特征和多尺度梯度方向信息熵特征,并建立了一种针对裸 PCB 图像的灰度、纹理和深层语义等各种特征的描述方法。虽然该算法对裸板缺陷的识别率较高,准确率达到 99% 以上,但所提出的方法尚不适用于所有复杂的生产环境。Yu 等<sup>[37]</sup>针对图像不确定性的数据集的问题提出了一种基于内在特征分解和多级

融合的 PCB 缺陷检测分类模型。该模型在真实光照物理模型的基础上,利用深度学习算法改进了 Retinex 图像分解算法,能够生成更符合物体特征的光照和着色图。此外,通过分级稀疏编码器和双边滤波器根据反射图和阴影图的不同特性来去除噪声,从而获得缺陷细节特征。

为了实现 PCB 缺陷的机器视觉检测,解决 PCB 缺陷检测模型稳定性差、精度低的问题,Li 等<sup>[38]</sup>提出了一种基于 VGG16 的 Faster R-CNN 算法。该算法结合了数据扩展和 RGB 数据增强技术,从而提高了检测准确性,但也导致了检测速度的降低。Chen 等<sup>[39]</sup>提出一种 Transformer-YOLO 网络检测模型。该模型摒弃了传统的利用卷积神经网络提取图像特征的方法,而是采用 Swin Transformer 作为特征提取网络,能够有效地建立图像特征之间的依赖关系。为了调整特征图中通道的顺序,使网络更有效地关注具有更大价值的信息,在特征检测网络组件中添加了卷积和注意力机制模块,在 PCB 公共数据集上实现了最佳检测精度,优于目前的主流技术。2022 年,Liu 等<sup>[40]</sup>训练了一个拥有 30 亿个参数的 Swin Transformer V2 模型,并引入了后归一化技术和缩放余弦注意力方法。这种方法在多个视觉任务上实现了最先进的结果(SOTA)。截至 2023 年,Swin Transformer V2 作为骨干网络持续成为广泛研究的焦点,展现出卓越的性能。随后,由于 PCB 缺陷检测难度大,易出现误检、漏检,庾冰等<sup>[41]</sup>就提出一种基于 YOLOX-WSC 的 PCB 缺陷检测算法,在主干网络中,引入了无参数注意力模块 SimAM,通过能量函数评估有效特征,增强了算法的特征提取和定位能力,同时没有增加额外的模型参数。在特征融合网络方面,采用 CSPHB 模块替代传统的 CSPLayer 结构,以获取更高阶的语义信息,从而提高分辨能力,这一改进还增强了特征融合网络的交互能力,进一步提升了模型的检测性能。苏佳等<sup>[42]</sup>在近期的研究中提出了一种基于改进 YOLOv8 的工业表面缺陷检测算法 EML-YOLO。该算法通过引入高效卷积模块 ELK,提升了模型在特征提取方面



的能力，并设计了一种高效的特征融合模块来捕捉更丰富的特征和全局上下文信息。此外，还对现有的 Neck 模块进行了结构优化，从而有效降低了模型的参数量和计算量。但面对细微模糊特征时可能存在误检问题。Yu 等<sup>[43]</sup>提出了一种新的深度神经网络，即自适应关键点定位网络（AKPLNet），利用 ResNet50\_FPN 和热力学机制（Thermodynamic Mechanism，TM）构建了残差金字塔热图网络（RFHNet），用于多尺度特征提取和缺陷定位。此外，还提出了一种基于树结构 Parzen 估计的自适应树结构区域提议网络（AT-RPN）来获取目标的预测区域，从而减少了对大量先验知识的依赖。

为了解决在 PCB 复杂背景下检测小缺陷的挑战，Zhang 等<sup>[44]</sup>提出了一种基于双重注意机制和路径聚合特征金字塔网络（Path Aggregation Feature Pyramid Network，PAFPN）的轻量级单级缺陷检测网络，该网络在保持低内存占用和强实时性的同时，提高了在复杂 PCB 背景下检测小尺寸缺陷的能力。尽管如此，该模型仍有优化空间，特别是在特征增强模块的优化和模型结构的简化方面，以进一步缩短检测时间。Li 等<sup>[45]</sup>创建了一个用于 PCB 组装场景对象检测的数据集，解决了锚框尺寸相关的检测问题。对整个输出层的有效接收场(Effective Receptive Field,ERF)进行了详细分析,并确定了其范围。为了解决锚框大小的问题,引入了基于 ERF 的锚框分配规则。此外，还设计了一种改进的属性空间金字塔池（Atrous Spatial Pyramid Pooling，ASPP），并整合了通道注意力模块，增加了上下文信息，以

解决小而难以检测的缺陷带来的挑战。针对检测效率、内存消耗以及对小缺陷敏感性相关问题，Xuan 等<sup>[46]</sup>提出了一种新的基于深度学习的轻量级缺陷检测网络 YOLOX-MC-CA，其重构全新的轻量级骨干网络并嵌入高效的通道注意力机制（Channel Attention，CA）。修正后的主干网络由多个反向残差块组成，并将协调注意力纳入网络架构，显著提高了模型检测小缺陷的能力。然而，检测速度仍有进一步提升的空间。2023 年，杨永跃等<sup>[47]</sup>对 YOLOv5x 网络模型进行改进。针对 PCB 缺陷尺寸较小的问题，增加了适配小尺寸缺陷的 P2 检测头，从而提升了模型对微小 PCB 缺陷的检测能力。同时，设计全新的 PANet 多特征融合结构,实现了高效的双向跨尺度连接和加权特征层融合，增强了同一特征层之间的信息融合能力，优化了模型性能。对于微小缺陷的检测，Liu 等<sup>[48]</sup>设计了一种采用可变形变压器和金字塔特征融合的精细化缺陷检测器（RDTor）来精确捕获 PCB 微小缺陷，其中 RDTor 由三部分组成：多头非局部变压器（Multi-head Non-local Transformer，MNT）模块、多尺度金字塔特征融合（Multi-scale Pyramid Feature Fusion，MPFF）模块和自适应缺陷检测(Adaptive Defect Detection, ADD)模块。最后，一系列实验表明，该方法的性能优于最先进的方法,这进一步表明它可以作为检测 PCB 缺陷的快速有效的检测工具。但其局限性在于对类间相似性缺陷的识别能力较弱。

综上，基于深度学习的 PCB 缺陷检测主要方法对比如表 3 所示。

表 3 基于深度学习方式的 PCB 缺陷检测主要方法对比

Table 3 Comparison of main methods of PCB defect detection based on deep learning			
文献	介绍	优点	缺点
[30]	基于 GAN 的 PCB 缺陷检测方案	减少了训练迭代次数和训练时间	数据集不够丰富
[32]	PCB 缺陷图像超分辨率重建算法 SRVIT	降低了空间复杂度，减少了模型参数量和空间尺寸	数据集不够丰富
[35]	基于 Transformer 的模型 LPViT	提高了准确性	数据集不够丰富
[36]	基于高斯金字塔的多尺度特征提取方法	对裸 PCB 缺陷具有较高的识别率，准确率 达到 99%以上	不适合复杂的生产环境

[37]	基于内在特征分解和多级融合的 PCB 缺陷检测分类模型	对不同亮度比的数据集表现出较好的性能	训练需大量标记数据样本且计算成本较高
[38]	基于 VGG16 的 Faster R-CNN 算法	提高检测准确性	降低了检测速度
[39]	Transformer-YOLO 网络检测模型	在 PCB 公共数据集上实现了最佳检测精度，优于目前的主流技术	延长了推理时间
[40]	Swin Transformer V2 模型	缩小了视觉和语言模型之间的能力差距，在 4 个代表性视觉基准上创下了新记录	参数量较大
[41]	基于 YOLOX-WSC 的 PCB 缺陷检测算法	有效解决了 PCB 图像背景相似、纹理复杂导致特征提取困难、网络传播特征信息损失较大的问题	个别缺陷的检测效果不佳
[42]	EML-YOLO 模型	增强了模型的特征提取能力，以更低的参数量和计算量实现了更高的 mAP	对细微模糊特征可能存在误检问题
[43]	自适应关键点定位网络 (AKPLNet)	与 11 种典型模型相比，AKPLNet 具有良好的检测性能	网络结构有待改进
[44]	基于双重注意力机制和 PAFPN 的轻量级缺陷检测网络	内存占用低	检测时间较长
[45]	基于 ERF 的锚点分配规则	解决了小而难以检测的缺陷	未能有效减少锚点的密度
[46]	轻量级缺陷检测网络 YOLOX-MC-CA	增强了小缺陷检测能力，为嵌入式系统提供了轻量级网络	检测速度较慢
[47]	基于 YOLOv5 的 PCB 缺陷检测算法	解决了缺陷尺寸小和背景复杂的问题	没有和其他网络结构进行对比
[48]	精细化缺陷检测器 RDTor	在小缺陷检测方面优于其他方法	难以识别高度相似的类间特征

从上述研究可以看出，近年来基于深度学习的 PCB 缺陷检测方法取得了显著进展，涵盖了 Faster R-CNN、YOLO 及 Transformer 等架构。具体而言，深度学习模型的引入有效克服了传统方法在特征提取和检测精度方面的诸多局限，使得缺陷检测能够更好地适应复杂和动态的工业环境。在特征提取方面，从早期的卷积神经网络（如 VGG、Faster R-CNN）到近年流行的 Transformer 架构，深度学习方法逐步实现了对 PCB 图像特征的自动提取和多尺度分析。这些方法通过不同的特征提取模块（如 Attention 机制、多特征融合、金字塔结构）不断增强模型对微小缺陷的检测能力，同时在高分辨率图像重建和增强方面也发挥了重要作用。然而，模型的复杂性和对数据的高度依赖，使其在实际工业环境中的应用仍面临一定挑战。

虽然 Attention 机制和 Transformer 架构显著提升了模型的检测精度，但它们通常伴随较高的计算

开销和内存消耗，难以满足实时性要求。因此，轻量化网络设计逐渐受到关注，如 YOLOX-MC-CA 等，通过精简网络结构并引入高效 Attention 模块，在检测性能与计算效率之间寻求平衡。然而，轻量化设计在保持检测精度的同时，仍需要简化模型结构，这对小缺陷的检测敏感性提出了更高的要求。另一方面，虽然许多检测方法在通用 PCB 缺陷检测任务中表现良好，但在背景复杂或缺陷样本不均的情况下，依然存在误检或漏检问题。对此，当前研究中采用了多种预处理技术（如超分辨率重建、光照模型分解）以优化输入图像质量，但这些方法通常依赖于高质量的缺陷样本，且在区分类间相似性缺陷方面仍有待提升。

此外，如何提升模型在小样本条件下的泛化能力以及对复杂背景的鲁棒性，仍是亟待解决的难题。为此，一些研究引入了增强学习机制，通过多尺度特征融合、数据扩展等方式增强模型的适应性，甚

至在无监督条件下进行缺陷检测,以减少对标注数据的依赖。然而,这些方法的实际效果仍需进一步验证和优化。因此,可以通过优化特征增强模块和多级网络结构,进一步提升模型在多样化工业环境中的实时性和适用性。

总体而言,基于深度学习的 PCB 缺陷检测在检测精度和自动化方面已展现出显著优势,但在数据效率 and 鲁棒性方面仍有优化空间。未来的研究应进一步融合跨领域的先进算法,开发更加轻量、高效且鲁棒的 PCB 缺陷检测系统,逐步实现工业生产中的实时高效检测。

### 3 性能评价指标和数据集

#### 3.1 PCB 性能评价指标

##### (1) 检测精度

PCB 缺陷检测需要解决 3 个问题,即确定是否存在缺陷、确定缺陷的类型、确定缺陷的位置。而对缺陷检测方法质量的评价,是通过将检测结果与实际结果进行对比来实现。目标检测领域常用评价指标主要有精确度(Precision, P)<sup>[49]</sup>、召回率(Recall, R)<sup>[50]</sup>和全类别平均正确率(mean Average Precision, mAP)<sup>[51]</sup>。P 是指模型正确预测的缺陷样品与总预测结果的比率,如式(1)所示。R 表示正确预测的缺陷样品与总实际结果的比率,如式(2)所示。mAP 是评估目标检测模型性能的关键指标,是各类预测正确的结果占总样本数的平均值,如式(4)所示。

$$P = \frac{TP}{TP + FN} \quad (1)$$

$$R = \frac{TP}{TP + FP} \quad (2)$$

$$AP = \frac{\sum PPV}{n} \quad (3)$$

$$mAP = \frac{\sum AP}{m+1} \quad (4)$$

式中 TP、FP 分别表示标签被正确或者错误地划分为正例的个数;FN 表示被错误地划分为负例的个数。n 为总样本数,m 为类别数。

PCB 缺陷检测过程中缺陷的定位精度是反映检测算法精度的另一个直接评价指标。在缺陷检测过程中,交并比(Intersection over Union, IoU)是

一种用于评估目标检测算法中预测边界框(Bounding Box, BB)和真实边界框(Ground Truth, GT)之间重叠程度的指标,它计算两个边界框的交集区域与它们的并集区域之间的比率,用于衡量预测的边界框与真实边界框的匹配度,如式(5)所示。IoU 值越大,检测算法的定位就越准确。在检测过程中,通常采用非最大值抑制(Non-Maximum Suppression, NMS)和阈值设置来筛选最佳预测框,最终实现目标定位。对于实际的 PCB 生产线,可以通过将上述指标与实际的检测结果进行比较来评估检测系统的性能。

$$IoU = \frac{A \cap B}{A \cup B} \quad (5)$$

式中, A 表示预测边界框, B 表示真实边界框。

除了这些指标外,还使用受试者工作特征(Receiver Operating Characteristic, ROC)和曲线下面积(Area Under the Curve, AUC)来评估检测模型的性能。ROC 曲线由真正例率(True Positive Rate, TPR)和假正例率(False Positive Rate, FPR)绘制。TPR 指在所有真正例中,模型正确预测为正例的比例;FPR 则是模型错误地将实际为负例的样本预测为正例的比例。它们分别作为 ROC 曲线的纵轴和横轴,通过不同的分类阈值绘制,用以评估分类器在不同操作点下的性能表现。AUC 值是 ROC 曲线下的面积,用于评估模型的性能。

##### (2) 检测速度

由于对生产 PCB 有着高速和大批量的需求,检测速度成为评估 PCB 缺陷检测算法和系统有效性的关键指标。对于缺陷检测算法,其检测速度主要体现在模型的训练时间、验证时间和测试时间上。对于检测系统,除了模型加载时间之外,检测速度还反映在检测帧率(每秒帧数(Frames Per Second, FPS)<sup>[52]</sup>)和检测系统的响应时间上。帧率为系统每秒可以处理的图像帧数,检测帧率应足够高,以确保实时检测结果;响应时间是指系统从接收到检测任务到输出检测结果之间的时间。

#### 3.2 PCB 缺陷数据集

数据集在 PCB 缺陷检测中充当着至关重要的作用,它不仅能作为衡量不同算法优劣的指标之一,



还能为解决方案设定目标。现有一些关于 PCB 的主流数据集包括 FICS-PCB<sup>[53]</sup>、PCB DSLR<sup>[54]</sup>、PCB-METAL<sup>[55]</sup>、DEEP-PCB<sup>[56]</sup>、HRIPCB<sup>[57]</sup>、PCB Defect<sup>[58]</sup>等，具体如表 4 所示。

表 4 PCB 缺陷数据集

Table 4 PCB defect datasets

数据集	介绍	下载链接
FICS-PCB	该数据集由佛罗里达大学的安全与保证实验室收集,由 31 个 PCB 样品的 9912 张图像组成,包含 77347 个带注释的 PCB 组件。	<a href="https://www.kaggle.com/datasets/dhruvmak/fics-pcb">https://www.kaggle.com/datasets/dhruvmak/fics-pcb</a>
PCB DSLR	该数据集包含 748 张来自回收设施的 PCB 图像,所有图像都带有准确的 PCB 分割信息,并为所有集成电路(IC)芯片(9313 个样本)提供了边界框信息。该数据集可用于设计和测试各种 PCB 分析方法,从 PCB 分类到 IC 芯片定位再到特定芯片的检测。	<a href="http://www.caa.tuwien.ac.at/cvl/research/cvl-databases/pcb-dslr-dataset/">http://www.caa.tuwien.ac.at/cvl/research/cvl-databases/pcb-dslr-dataset/</a>
PCB-METAL	该数据集由 123 种 PCB 样本采集而来,共有 984 张高分辨率图像,包含 IC(5844 件)、电容器(3175 件)、电阻器(2670 件)和电感器(542 件)。该数据集可用于基于图像的 PCB 分析,如元件检测、PCB 分类、电路设计提取等。	未公开
DEEP-PCB	该数据集包含 1500 个带有注释的 PCB 图像对,包含有 6 种常见缺陷(Pin-hole、Mousebite、Open、Short、Spur、Spurious copper),且每对图像包含一个 640×640 的无缺陷模板和有缺陷的待测图像。	<a href="https://github.com/tang-sanli5201/DeepPCB">https://github.com/tang-sanli5201/DeepPCB</a>
HRIPCB	该数据集包含 1386 张图像,有 6 种常见缺陷,包括 missing hole、mouse bite、open circuit、short、spur、spurious copper。一半的图像用于测试 PCB 正确放置的情况,而另一半则用于模拟测试板在工作台中随机定向的情况。	<a href="http://robotics.pkusz.edu.cn/resources/dataset/">http://robotics.pkusz.edu.cn/resources/dataset/</a>
PCB Defect	该数据集由北京大学人机交互开放实验室发布,包含 1386 合成 PCB 图像,含有 6 种缺陷(missing hole、mouse bite、open circuit、short、spur、spurious copper),可用于检测、分类和配准任务。	<a href="http://robotics.Pkusz.edu.cn/ resources/dataset/">http://robotics.Pkusz.edu.cn/ resources/dataset/</a>
PCB	该数据集包含 693 张 PCB 图像,含有 6 种缺陷(Missing hole、Mouse bite、Open circuit、Short、Spur、Spurious copper),按照 7:1:2 的比例进行了划分,同时包含 COCO 和 VOC 两种不同的标签。	<a href="https://aistudio.baidu.com/aistudio/datasetdetail/127210">https://aistudio.baidu.com/aistudio/datasetdetail/127210</a>
Micro-PCB	该数据集包含由 13 个微型 PCB 样本采样而来 8125 张 PCB 图像,每个样本在相对于相机的 25 个不同位置进行采集,且每个位置进行了 5 次不同的旋转。	<a href="https://www.kaggle.com/datasets/fretapper/micropcb-images">https://www.kaggle.com/datasets/fretapper/micropcb-images</a>
PCB Defect-Augmented	该数据集是 PCB Defect 数据集的增强版,共有 10668 张图像和相应的注释文件,将原始数据集的高分辨率图像裁剪为 600×600 个子图像,划分为训练集(9920 张)和测试集(2508 张)。	<a href="https://www.dropbox.com/s/h0f39nyotddibsb/VOC_PCB.zip?dl=0">https://www.dropbox.com/s/h0f39nyotddibsb/VOC_PCB.zip?dl=0</a>
PCB_Component_Detection	该数据集包含有 1410 张 PCB 图像,含有多种组件,即电容、电阻、变压器、线路滤波器等,可用于检测组件的缺	<a href="https://www.kaggle.com/datasets/animeshkumarnayak/pcb-fault-detection">https://www.kaggle.com/datasets/animeshkumarnayak/pcb-fault-detection</a>

失以及组件的方向错误。

3.3 PCB 缺陷检测算法性能分析

近几年来,基于深度学习的方法在 PCB 缺陷检测领域展现出了卓越的性能。为了更好地比较分析基于深度学习的 PCB 缺陷检测算法,本文直接采用了近年来相关研究中的实验数据,并在 PCB Defect、

DeepPCB、HRIPCB 三个主流数据集上,汇总了近三年内新方法的实验结果。表 5 展示了一些算法在 PCB Defect 数据集上的检测结果,表 6 和表 7 分别展示了一些算法在 PCB Defect 数据集、DeepPCB 数据集和 HRIPCB 数据集上的检测结果。

表 5 PCB Defect 数据集上的测试结果比较  
Table 5 Comparison of test results on the PCB defect dataset

方法	Backbone	主要技术指标								
		Params	FFPS	mAP	Miss- ing hole	Mouse_bit e	Open_ci rcuit	Short	Spur	Spurious copper
Transformer-YOLO <sup>[39]</sup>	CSPDark-net53	93.95M	21	97.04%	98%	96%	97%	98%	95%	95%
ES-Net <sup>[59]</sup>	CSPDark-net53	147.98M	53	97.5%	99.5%	98.1%	99.5%	96.8%	95.9%	95.2%
MSD-YOLO <sup>[60]</sup>	CSPDark-net53	3.8M	88.40	99.37%	99.4%	99.2%	99.3%	99.5%	98.1%	99.5%
FPFM <sup>[61]</sup>	Darknet-53	-	-	78.86%	82.51%	70.69%	60.25%	64.50%	55.42%	83.75%
YOLOX-WSC <sup>[41]</sup>	Focus+Dark-net53+SPP	9.17M	56.18	96.65%	100.00%	90.91%	90.91%	99.87%	100.00%	90.65%
LDD-Net <sup>[62]</sup>	DarkNet	5.13M	78.13	95.90%	-	-	-	-	-	-
Extended FPN <sup>[63]</sup>	ResNet-101+FPN	137M	2.17	96.2%	97.1%	95.2%	93.2%	98.4%	95.6%	96.3%
GOD <sup>[64]</sup>	ResNet18	11.65M	46.1	99.6%	99.7%	99.6%	99.7%	99.6%	99.4%	99.3%
DCR-FRNet <sup>[65]</sup>	Resnet101	-	-	94.7%	93.8%	95.2%	94.5%	94.3%	94.7%	95.6%
GCC-YOLO <sup>[66]</sup>	FPN	14.5M	68.0	98.2%	99.5%	98.3%	98.6%	99.2%	97.3%	96.1%
ESDDNet <sup>[67]</sup>	Mo-bileNetV3	4.53M	45	99.23%	99.77%	99.32%	99.36%	98.70%	98.79%	99.45%
Light-YOLOv5 <sup>[68]</sup>	VoV-GSCSP+GSConv	12.5M	-	93.4%	99.5%	90.8%	95.9%	92.2%	95.4%	83.9%
SWS-Yolov8n <sup>[69]</sup>	SPD-Conv	-	-	96.94%	97.67%	98.98%	98.33%	95.80%	95.07%	95.83%
YOLOX-CAS <sup>[70]</sup>	CSP	10.5M	51	98.4%	98.8%	97.8%	98.7%	98.3%	98.5%	98.3%
TD-Net <sup>[71]</sup>	DD+CSP	7.06M	-	96.2%	-	-	-	-	-	-
DSASPP <sup>[72]</sup>	CSPNet + DSASPP	9.03M	101.67	98.62%	-	-	-	-	-	-
EEMNet <sup>[73]</sup>	Modified CSP	3.57M	77	99.1%	-	-	-	-	-	-
YOLOX-MulPViT <sup>[74]</sup>	MulPViT	-	25.97	99.13%	100.00%	97.88%	98.20%	99.61%	99.22%	99.89%
TDD-YOLO <sup>[75]</sup>	Four-ME	78.5M	36.01	96.8%	99.4%	96.4%	95.5%	99.1%	92.9%	97.4%
CDI-YOLO <sup>[76]</sup>	YOLOv7-tiny	5.76M	128	98.3%	98.9%	97.8%	98.3%	97.6%	98.3%	98.6%

YOLOX-MC-CA <sup>[77]</sup>	MC+CA	3.79M	47.6	99.13%	-	-	-	-	-	-
PCB-YOLO <sup>[78]</sup>	Swin Trans- former	92.3M	92.5	95.97%	99.5%	90.7%	99.5%	98.5%	90.9%	96.7%
LW-YOLO <sup>[79]</sup>	FasterNet	6.5M	141.5	96.4%	99.5%	92.0%	97.4%	99.3%	97.1%	98.5%
LEDD-Net <sup>[80]</sup>	DFP-Net	69.3M	61	98.9%	-	-	-	-	-	-

表 6 DeeP PCB 数据集上的测试结果比较

Table 6 Comparison of test results on the DeeP PCB dataset

方法	Backbone	主要技术指标								
		Params	FPS	mAP	Open	Short	Mouse Bite	Spur	Copper	Pin-Hole
DE-SSD <sup>[81]</sup>	BA-SSL	-	-	98.7%	-	-	-	-	-	-
YOLO-MBBi <sup>[82]</sup>	MBConv+ CBAM	-	69.5	99.0%	99.4%	98.8%	99.1%	98.9%	98.3%	99.5%
DDTR <sup>[83]</sup>	Res- net+Swin Trans- former	-	-	78.62%	95.24%	64.75%	78.25%	75.79%	89.11%	68.60%
FE-YOLO <sup>[84]</sup>	CSPDark- net53	10.36M	83	98.9%	99.9%	98.3%	99.4%	98.4%	98.7%	99.5%
YOLOv3-FPGA <sup>[85]</sup>	Darknet- 53	-	99.7	78.9%	84.3%	85.7%	70.0%	68.1%	82.3%	83.0%
YOLOv5-TDD <sup>[12]</sup>	Fo- cus+Conv +CSP_X+ SPPblock	-	43.22	97.63%	98.55%	93.05%	99.96%	97.09%	98.75%	98.39%
U2D2PCB <sup>[86]</sup>	U-Net	-	-	95.78%	95.12%	96.51%	94.42%	94.93%	96.72%	96.96%
YOLOPCB <sup>[87]</sup>	CBS+ELAN	23.6M	48.7	98.6%	-	-	-	-	-	-
AKPLNet <sup>[43]</sup>	Res- Net50_FP N+TM	-	8.3	99.0%	97.7%	99.2%	98.8%	98.7%	99.5%	99.9%
YOLOv8s <sup>[88]</sup>	ASC2f+C AFM	46.9M	44.6	89.1%	-	-	-	-	-	-

表 7 HRIPCB 数据集上的测试结果比较

Table 7 Comparison of test results on the HRIPCB dataset

方法	Backbone	主要技术指标								
		Params	FPS	mAP	Miss- ing_hole	Mouse_bite	Open_cir- cuit	Short	Spur	Spurious copper
PANet <sup>[89]</sup>	CSP	7.02M	-	98.1%	98.4%	97.2%	99.5%	99.5%	96.9%	96.8%
Proposed <sup>[90]</sup>	HDN	1.77M	200.30	95.5%	96.2%	96.2%	95.5%	94.8%	95.6%	94.5%
YOLOv5 + new FPN + modified CIoU Loss <sup>[91]</sup>	C3	-	90	99.17%	-	-	-	-	-	-
LGCL- CenterNet <sup>[92]</sup>	Darknet53- PANet	0.542M	51.18	98.95%	100.00%	96.75%	97.96%	99.30%	99.72%	97.96%
Valid-IoU <sup>[93]</sup>	CSPDark- net53	-	33.78	98.3%	100.00%	99.52%	100.00%	97.93%	99.73%	94.79%
YOLOv8- FCW <sup>[94]</sup>	FasterNet	-	-	94.4%	99.5%	89.7%	91.7%	96.5%	92.3%	96.7%
BEW-YOLO <sup>[95]</sup>	YOLOv7+EV C+BRA	-	-	98.8%	-	-	-	-	-	-



TD-YOLO <sup>[96]</sup>	YOLOv5-nano+ShuffleNetV	1.33M	37	99.5%	-	-	-	-	-
YOLO-HMC <sup>[97]</sup>	YOLOv5+D H+MCBAM+CARAFE+H orNet	5.94M	22.4	98.6%	99.5%	97.6%	98.1%	99.0%	97.9%
								98.9%	

据各个算法在三个数据集上的测试结果,可知参与对比的 PCB Defect、DeepPCB、HRIPCB 三个数据集在缺陷形式、样本数量和难度上各有侧重。PCB Defect 数据集包含较多的标准化缺陷类型,如缺孔、短路、鼠咬等,适合检测常见缺陷。DeepPCB 数据集则侧重于较为复杂的小目标缺陷检测。而 HRIPCB 数据集更复杂,图像中的缺陷比例更小,更专注于高分辨率图像的复杂缺陷且检测模型的整体准确性略有下降。例如在共同使用 CSPDarknet53 作为主干网络的情况下,MSD-YOLO<sup>[60]</sup>在 PCB Defect 数据集上表现最佳,mAP 高达 99%;FE-YOLO<sup>[84]</sup>在 DeepPCB 数据集上的表现次之;而 Valid-IOU<sup>[93]</sup>在 HRIPCB 数据集上的表现最低。三种数据集在缺陷类型上都有 6 种不同的缺陷类别,其中“Missing hole”类别相对容易检测,YOLOX-WSC<sup>[41]</sup>、LGCL-CenterNet<sup>[92]</sup>等方法在这一类别上的 AP 高达 100%,而相比之下,其他类别的特征相对较难捕捉。

通过对比各种骨干网络,可以发现近三年来在 PCB 缺陷检测算法中,主要采用了 YOLO 系列的深度学习方法,YOLO 系列因其快速和高效的实时目标检测能力而备受欢迎。表中显示,LW-YOLO<sup>[79]</sup>和 CDI-YOLO<sup>[76]</sup>表现出较高的推理速度,分别为 141.5FPS 和 128FPS,且参数数量较少,适合实时检测应用。其中 LW-YOLO 基于 YOLOv7-tiny 框架,而 CDI-YOLO 则使用 YOLOv8 框架。在精度方面,MSD-YOLO<sup>[60]</sup>和 TD-YOLO<sup>[96]</sup>对各类缺陷检测均表现出色,其 mAP 分别达到 99.37%和 99.5%,且均采用 YOLOv5 框架。

根据表中数据可以观察到在三类数据集上 mAP 达到了 99%以上的包括 GOD<sup>[64]</sup>、ESDDNet<sup>[67]</sup>、YOLO-MBBi<sup>[82]</sup>和 AKPLNet<sup>[43]</sup>等方法。其中文献[64]中使用的对象检测(GOD)方法表现最佳,mAP 高达 99.6%,其使用 ResNet 18 作为骨干网络,并引入

BRM 技术来获取缺陷的形状信息,从而实现了更准确的预测结果。另外,从表中还可以观察到,GOD 模型在 mAP 和各类缺陷检测方面均表现出色,适用于高精度需求的场景。文献[90]设计了一种基于多尺度卷积的概率分类器,该方法的推理速度最快,达到 200.30FPS,非常适合需要实时检测的应用场景。而 DSASPP<sup>[72]</sup>和 LW-YOLO<sup>[79]</sup>等模型在参数数量和推理速度上均表现较优,适用于资源受限的环境。Transformer 架构所展现的性能较优越,但计算成本高。例如 PCB-YOLO<sup>[78]</sup>使用 Swin Transformer 作为骨干网络,在 PCB Defect 数据集上能达到 95.97%的 mAP,能够有效检测缺陷。然而,其计算复杂度和参数量较大,导致了推理速度较慢,限制了其在实时性要求较高的工业生产线中的广泛应用。

4 待解决的问题与未来研究方向

目前基于机器视觉的 PCB 缺陷检测算法虽然发展迅速,但其检测效果良莠不齐,仍有不少改进之处:

1)设计优化 PCB 图像质量的成像和处理策略:使用高性能成像设备和合理的成像方案,如 3D 视觉、微热传感器和激光扫描热成像,来获得高质量的 PCB 图像。然后,通过充分利用数据增强、图像去噪等图像处理算法,以及多尺度融合策略,可以有效消除复杂背景的干扰,从而获得低噪声、高质量的图像数据。

2)改进对小目标的检测技术:综合利用多尺度分析和信息融合技术以提高检测的灵敏度和准确性;引入深度学习或机器学习技术训练模型,以识别微小缺陷的特征,进一步提升检测效率;建立实时反馈机制,调整成像和算法参数,有助于适应不同 PCB 板的变化和工作环境的影响。

3)减少对训练样本的依赖:利用各种学习方法,如无监督学习、半监督学习和迁移学习,来减

少网络对大量训练样本的依赖。即使在少量训练样本的情况下,网络模型也能通过从单个实例中推断出来的知识快速识别出未见过的缺陷。此外,数据增强算法也可用于扩展样本数据集。

4) 平衡实时应用中的精度与速度:通过设置自适应平衡参数,根据实时数据和应用需求来平衡精度和速度。选择轻量级网络模型如 MobileNet 或 EfficientNet,这些模型能够在保持良好性能的同时降低计算和内存需求,从而提高推理速度。此外,优化硬件性能也是关键,例如利用 GPU、TPU 或专用 ASIC 来加速深度学习推理过程,有效缩短响应时间。

5) 增强模型适应性与提升数据处理效率:通过快速识别最有用的样本,并在模型训练过程中利用局部 PCB 缺陷数据来增强模型的适应性。此外,学习更有效的数据处理和分析方法也是提高模型性能、执行效率和实时响应能力的关键策略之一。

## 5 结束语

本文总结了近年来基于机器视觉的 PCB 缺陷检测算法。首先回顾了该领域面临的主要挑战,介绍了传统 PCB 缺陷检测方法及其局限性。接着引出了基于机器学习的 PCB 缺陷检测方法,包括传统机器学习和深度学习方法,分别对其算法进行了总结,并讨论了优缺点。然后介绍了主要的性能评估方法和流行的缺陷数据集,并对比分析了近三年在 PCB Defect、DeepPCB 和 HRIPCB 三种公共数据集下最新方法的性能。最后,展望了 PCB 缺陷检测的未来研究趋势,提出了优化图像质量的成像和处理策略、改进小目标检测技术、降低训练样本依赖性、平衡检测精度与速度、提升模型适应性等改进方向,希望为相关研究提供有价值的参考。

## 参考文献:

- [1] PARK J H, KIM Y S, SEO H, et al. Analysis of Training Deep Learning Models for PCB Defect Detection[J]. Sensors, 2023, 23(5): 2766.
- [2] LING Q, ISA N A M. Printed Circuit Board Defect Detection Methods Based on Image Processing, Machine Learning and Deep Learning: A Survey[J]. IEEE Access, 2023, 11: 15921-15944.
- [3] CHEN X, WU Y, HE X, et al. A Comprehensive Review of Deep Learning-Based PCB Defect Detection[J]. IEEE Access, 2023, 11: 139017-139038.
- [4] SANKAR V U, LAKSHMI G, SANKAR Y S. A Review of Various Defects in PCB[J]. Journal of Electronic Testing, 2022, 38(5): 481-491.
- [5] 吴一全, 赵朗月, 苑玉彬, 等. 基于机器视觉的 PCB 缺陷检测算法研究现状及展望[J]. 仪器仪表学报, 2022, 43(8): 1-17.  
WU Y Q, ZHAO L Y, YUAN Y B, et al. Research status and the prospect of PCB defect detection algorithm based on machine vision[J]. Chinese Journal of Scientific Instrument, 2022, 43(8): 1-17.
- [6] CHEN I C, HWANG R C, HUANG H C. PCB Defect Detection Based on Deep Learning Algorithm[J]. Processes, 2023, 11(3): 775.
- [7] ZHOU Y, YUAN M, ZHANG J, et al. Review of vision-based defect detection research and its perspectives for printed circuit board[J]. Journal of Manufacturing Systems, 2023, 70: 557-578.
- [8] TULBURE A A, TULBURE A A, DULF E H. A review on modern defect detection models using DCNNs – Deep convolutional neural networks[J]. Journal of Advanced Research, 2022, 35: 33-48.
- [9] LAKSHMI G, SANKAR V U, SANKAR Y S. A Survey of PCB Defect Detection Algorithms[J]. Journal of Electronic Testing, 2023, 39(5): 541-554.
- [10] ZHANG F, QIAO N, LI J. A PCB photoelectric image edge information detection method[J]. Optik, 2017, 144: 642-646.
- [11] 温悦欣. 基于机器视觉的 PCB 表面缺陷检测方法研究与系统实现[D]. 成都: 电子科技大学, 2020: 84.  
WEN Y X. Research and System Implementation of PCB Surface Defect Inspection Based on Machine Vision[D]. Chengdu: University of Electronic Science and Technology of China, 2020: 84.
- [12] 廖鑫婷, 张洁, 吕盛坪. 融合浅层特征和注意力机制的 PCB 缺陷检测方法[J]. 计算机集成制造系统, 2024, 2024(3): 1092-1104.  
LIAO X T, ZHANG H, LV S P. Defect detection for PCB by combining shallow features and attention mechanism[J]. Computer Integrated Manufacturing Systems, 2024, 2024(3): 1092-1104.
- [13] LI Y, LI S. Defect detection of bare printed circuit boards based on gradient direction information entropy and uniform local binary patterns[J]. Circuit World, 2017, 43(4): 145-151.
- [14] WANG S Y, ZHAO Y, WEN L. PCB welding spot detection with image processing method based on automatic threshold image segmentation algorithm and mathematical morphology[J]. Circuit World, 2016, 42(3): 97-103.

- [15] FANG K. Threshold segmentation of PCB defect image grid based on finite difference dispersion for providing accuracy in the IoT based data of smart cities[J]. International Journal of System Assurance Engineering and Management, 2022, 13(1): 121-131.
- [16] ZHU W, GU H, SU W. A fast PCB hole detection method based on geometric features[J]. Measurement Science and Technology, 2020, 31(9): 095402.
- [17] RAIHAN F, CE W. PCB defect detection USING OPENCV with image subtraction method[C]//2017 International Conference on Information Management and Technology (ICIMTech). 2017: 204-209.
- [18] ANNABY M H, FOU DA Y M, RUSHDI M A. Improved Normalized Cross-Correlation for Defect Detection in Printed-Circuit Boards[J]. IEEE Transactions on Semiconductor Manufacturing, 2019, 32(2): 199-211.
- [19] REN Z, FANG F, YAN N, et al. State of the Art in Defect Detection Based on Machine Vision[J]. International Journal of Precision Engineering and Manufacturing- Green Technology, 2022, 9(2): 661-691.
- [20] WU H. Solder joint defect classification based on ensemble learning[J]. Soldering & Surface Mount Technology, 2017, 29(3): 164-170.
- [21] BANSAL M, GOYAL A, CHOUDHARY A. A comparative analysis of K-Nearest Neighbor, Genetic, Support Vector Machine, Decision Tree, and Long Short Term Memory algorithms in machine learning[J]. Decision Analytics Journal, 2022, 3: 100071.
- [22] LIAO C T, LEE W H, LAI S H. A Flexible PCB Inspection System Based on Statistical Learning[J]. Journal of Signal Processing Systems, 2012, 67(3): 279-290.
- [23] YUK E H, PARK S H, PARK C S, et al. Feature-Learning-Based Printed Circuit Board Inspection via Speeded-Up Robust Features and Random Forest[J]. Applied Sciences, 2018, 8(6): 932.
- [24] UR REHMAN S, THANG K F, LAI N S. Automated PCB identification and defect-detection system (APIDS)[J]. International Journal of Electrical and Computer Engineering (IJECE), 2019, 9(1): 297.
- [25] SONG J D, KIM Y G, PARK T H. SMT defect classification by feature extraction region optimization and machine learning[J]. The International Journal of Advanced Manufacturing Technology, 2019, 101(5): 1303-1313.
- [26] CAI N, ZHOU Y, YE Q, et al. IC Solder Joint Inspection via Robust Principle Component Analysis[J]. IEEE Transactions on Components, Packaging and Manufacturing Technology, 2017, 7(2): 300-309.
- [27] ALAOUI N E B, CASSOU A, TOUNSI P, et al. Using infrared thermal responses for PCBA production tests: Feasibility study[J]. Microelectronics Reliability, 2019, 100-101: 113354.
- [28] SARKER I H. Deep Learning: A Comprehensive Overview on Techniques, Taxonomy, Applications and Research Directions[J]. SN Computer Science, 2021, 2(6): 420.
- [29] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet Classification with Deep Convolutional Neural Networks[C]//Advances in Neural Information Processing Systems: Vol. 25. Curran Associates, Inc., 2012.
- [30] YOU S. PCB Defect Detection based on Generative Adversarial Network[C]//2022 2nd International Conference on Consumer Electronics and Computer Engineering (ICCECE). 2022: 557-560.
- [31] TSAI A C, TSOU C H, WANG J F. EESRGAN: Efficient & Effective Super-Resolution Generative Adversarial Network[J]. IETE Technical Review, 2024, 41(2): 200-211.
- [32] LIU Z, HE P, WANG F. PCB Defect Images Super-Resolution Reconstruction Based on Improved SRGAN[J]. Applied Sciences, 2023, 13(11): 6786.
- [33] LEDIG C, THEIS L, HUSZAR F, et al. Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 4681-4690.
- [34] ZIWEI L, CHENG DONG W, DONGYUE C, et al. Overview on image super resolution reconstruction[C]// The 26th Chinese Control and Decision Conference (2014 CCDC). 2014: 2009-2014.
- [35] AN K, ZHANG Y. LPViT: A Transformer Based Model for PCB Image Classification and Defect Detection[J]. IEEE Access, 2022, 10: 42542-42553.
- [36] HAN X, LI R, WANG B, et al. Defect identification of bare printed circuit boards based on Bayesian fusion of multi-scale features[J]. PeerJ Computer Science, 2024, 10: e1900.
- [37] YU X, HAN-XIONG L, YANG H. PCB Defect Detection Model Based on Intrinsic Feature Decomposition and Multilevel Fusion Against Image Uncertainty[J]. IEEE Sensors Journal, 2024, 24(12): 19497-19505.
- [38] LI Y T, GUO J I. A VGG-16 Based Faster RCNN Model for PCB Error Inspection in Industrial AOI Applications[C]//2018 IEEE International Conference on Consumer Electronics-Taiwan (ICCE-TW). 2018: 1-2.
- [39] CHEN W, HUANG Z, MU Q, et al. PCB Defect Detection Method Based on Transformer-YOLO[J]. IEEE Access, 2022, 10: 129480-129489.
- [40] LIU Z, HU H, LIN Y, et al. Swin Transformer V2: Scaling Up Capacity and Resolution[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 12009-12019.
- [41] 庚冰, 黄丽雯, 唐鑫, 等. 基于YOLOX-WSC的PCB缺陷检测算法研究[J]. 计算机工程与应用, 2023, 59(10): 236-243.
- TUO B, HUANG L W, TANG X, et al. Research on PCB Defect Detection Algorithm Based on YOLOX-WSC[J].



- Computer Engineering and Applications, 2023, 59(10): 236-243.
- [42] 苏佳, 贾泽, 秦一畅, 等. 面向工业表面缺陷检测的改进 YOLOv8 算法[J]. 计算机工程与应用, 2024, 60(14): 187-196.
- SU J, JIA Z, QIN Y C, et al. Improved YOLOv8 Algorithm for Industrial Surface Defect Detection[J]. Computer Engineering and Applications, 2024, 60(14): 187-196.
- [43] YU J, ZHAO L, WANG Y, et al. Defect detection of printed circuit board based on adaptive key-points localization network[J]. Computers & Industrial Engineering, 2024, 193: 110258.
- [44] ZHANG Y, XIE F, HUANG L, et al. A Lightweight One-Stage Defect Detection Network for Small Object Based on Dual Attention Mechanism and PAFPN[J]. Frontiers in Physics, 2021, 9:708097.
- [45] LI J, LI W, CHEN Y, et al. Research on Object Detection of PCB Assembly Scene Based on Effective Receptive Field Anchor Allocation[J]. Computational Intelligence and Neuroscience, 2022, 2022(1): 7536711.
- [46] XUAN W, JIAN-SHE G, BO-JIE H, et al. A Lightweight Modified YOLOX Network Using Coordinate Attention Mechanism for PCB Surface Defect Detection[J]. IEEE Sensors Journal, 2022, 22(21): 20910-20920.
- [47] 杨永跃, 夏远超. PCB 缺陷检测深度学习算法的精度改进[J]. 电子测量与仪器学报, 2023, 37(5): 11-19.
- YANG Y Y, XIA Y C. Accuracy improvement of deep learning algorithm for PCB defect detection[J]. Journal of Electronic Measurement and Instrumentation, 2023, 37(5): 11-19.
- [48] LIU T, CAO G Z, HE Z, et al. Refined Defect Detector With Deformable Transformer and Pyramid Feature Fusion for PCB Detection[J]. IEEE Transactions on Instrumentation and Measurement, 2024, 73: 1-11.
- [49] CHENG G, HAN J. A survey on object detection in optical remote sensing images[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2016, 117: 11-28.
- [50] BAI J, REN J, YANG Y, et al. Object Detection in Large-Scale Remote-Sensing Images Based on Time-Frequency Analysis and Feature Optimization[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-16.
- [51] LIN T Y, MAIRE M, BELONGIE S, et al. Microsoft COCO: Common Objects in Context[M]//Fleet D, Pajdla T, Schiele B, et al. Computer Vision – ECCV 2014: Vol. 8693. Cham: Springer International Publishing, 2014: 740-755.
- [52] BOCHKOVSKIY A, WANG C Y, LIAO H Y M. YOLOv4: Optimal Speed and Accuracy of Object Detection[J]. arXiv preprint arXiv:2004.10934, 2020.
- [53] LU H, MEHTA D, PARADIS O, et al. FICS-PCB: A Multi-Modal Image Dataset for Automated Printed Circuit Board Visual Inspection[J]. Cryptology ePrint Archive, 2020.
- [54] PRAMERDORFER C, KAMPEL M. A dataset for computer-vision-based PCB analysis[C]//2015 14th IAPR International Conference on Machine Vision Applications (MVA). 2015: 378-381.
- [55] MAHALINGAM G, GAY K M, RICANEK K. PCB-METAL: A PCB Image Dataset for Advanced Computer Vision Machine Learning Component Analysis[C]//2019 16th International Conference on Machine Vision Applications (MVA). 2019: 1-5.
- [56] TANG S, HE F, HUANG X, et al. Online PCB Defect Detector On A New PCB Defect Dataset[J]. CoRR, 2019, abs/1902.06197.
- [57] HUANG W, WEI P, ZHANG M, et al. HRIPCB: a challenging dataset for PCB defects detection and classification[J]. The Journal of Engineering, 2020, 2020(13): 303-309.
- [58] WEIBO H, PENG W. A PCB Dataset for Defects Detection and Classification.[J]. CoRR, 2019, abs/1901.08204.
- [59] YU X, LYU W, ZHOU D, et al. ES-Net: Efficient Scale-Aware Network for Tiny Defect Detection[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-14.
- [60] ZHOU G, YU L, SU Y, et al. Lightweight PCB defect detection algorithm based on MSD-YOLO[J]. Cluster Computing, 2024, 27(3): 3559-3573.
- [61] WANG H, XIE J, XU X, et al. Few-Shot PCB Surface Defect Detection Based on Feature Enhancement and Multi-Scale Fusion[J]. IEEE Access, 2022, 10: 129911-129924.
- [62] ZHANG L, CHEN J, CHEN J, et al. LDD-Net: Lightweight printed circuit board defect detection network fusing multi-scale features[J]. Engineering Applications of Artificial Intelligence, 2024, 129: 107628.
- [63] LI C J, QU Z, WANG S Y, et al. A Method of Defect Detection for Focal Hard Samples PCB Based on Extended FPN Model[J]. IEEE Transactions on Components, Packaging and Manufacturing Technology, 2022, 12(2): 217-227.
- [64] LIU Q, LIU M, JONATHAN Q M, et al. A real-time anchor-free defect detector with global and local feature enhancement for surface defect detection[J]. Expert Systems with Applications, 2024, 246: 123199.
- [65] 朱红艳, 李泽平, 赵勇, 等. 基于多尺度融合和可变形卷积 PCB 缺陷检测算法[J]. 计算机工程与设计, 2022, 43(8): 2188-2196.
- ZHU H Y, LI Z P, ZHAO Y, et al. PCB defect detection algorithm based on multi-scale fusion and deformable convolution[J]. Computer Engineering and Design, 2022, 43(8): 2188-2196.
- [66] XIA K, LV Z, LIU K, et al. Global contextual attention augmented YOLO with ConvMixer prediction heads for PCB surface defect detection[J]. Scientific Reports, 2023,

- 13(1): 9805.
- [67] CHEN G, XU F, LIU G, et al. ESDDNet: efficient small defect detection network of workpiece surface[J]. Measurement Science and Technology, 2022, 33(10): 105007.
- [68] YE M, WANG H, XIAO H. Light-YOLOv5: A Lightweight Algorithm for Improved YOLOv5 in PCB Defect Detection[C]//2023 IEEE 2nd International Conference on Electrical Engineering, Big Data and Algorithms (EEBDA). 2023: 523-528.
- [69] ZHU P, CAI Y, LI F, et al. A Deep Learning Method for PCB Defect Detection Based on Improved Yolov8[C]//Proceedings of the International Conference on Computer Vision and Deep Learning. New York, NY, USA: Association for Computing Machinery, 2024: 1-7.
- [70] LI G, LIAO X, SU X, et al. PCB Defect Detection Based on Improved YOLOX Algorithm[C]//2023 5th International Conference on Electrical Engineering and Control Technologies (CEECT). 2023: 380-384.
- [71] SHAO R, ZHOU M, LI M, et al. TD-Net: tiny defect detection network for industrial products[J]. Complex & Intelligent Systems, 2024, 10(3): 3943-3954.
- [72] XU Y, HUO H. DSASPP: Depthwise Separable Atrous Spatial Pyramid Pooling for PCB Surface Defect Detection[J]. Electronics, 2024, 13(8): 1490.
- [73] WU Y, ZHENG L, CHEN E. EEMNet: an end-to-end efficient model for PCB surface tiny defect detection[J]. International Journal of Machine Learning and Cybernetics, 2024: 1-16.
- [74] 陈俊英, 李朝阳, 席月芸, 等. ViT 和注意力融合的不均衡 PCB 缺陷检测方法[J]. 仪器仪表学报, 2024, 45(4): 294-306.
- CHEN J Y, LI Z Y, XI Y Y, et al. ViT and attention fusion for class-imbalanced PCB defect detection[J]. Chinese Journal of Scientific Instrument, 2024, 45(4): 294-306.
- [75] ZHOU W, LI C, YE Z, et al. An Efficient Tiny Defect Detection Method for PCB With Improved YOLO Through a Compression Training Strategy[J]. IEEE Transactions on Instrumentation and Measurement, 2024, 73: 1-14.
- [76] XIAO G, HOU S, ZHOU H. PCB defect detection algorithm based on CDI-YOLO[J]. Scientific Reports, 2024, 14(1): 7351.
- [77] XUAN W, JIAN-SHE G, BO-JIE H, et al. A Lightweight Modified YOLOX Network Using Coordinate Attention Mechanism for PCB Surface Defect Detection[J]. IEEE Sensors Journal, 2022, 22(21): 20910-20920.
- [78] TANG J, LIU S, ZHAO D, et al. PCB-YOLO: An Improved Detection Algorithm of PCB Surface Defects Based on YOLOv5[J]. Sustainability, 2023, 15(7): 5963.
- [79] YUAN Z, TANG X, NING H, et al. LW-YOLO: Lightweight Deep Learning Model for Fast and Precise Defect Detection in Printed Circuit Boards[J]. Symmetry, 2024, 16(4): 418.
- [80] YU Z, WU Y, WEI B, et al. A lightweight and efficient model for surface tiny defect detection[J]. Applied Intelligence, 2023, 53(6): 6344-6353.
- [81] WAN Y, GAO L, LI X, et al. Semi-Supervised Defect Detection Method with Data-Expanding Strategy for PCB Quality Inspection[J]. Sensors, 2022, 22(20): 7971.
- [82] DU B, WAN F, LEI G, et al. YOLO-MBBi: PCB Surface Defect Detection Method Based on Enhanced YOLOv5[J]. Electronics, 2023, 12(13): 2821.
- [83] FENG B, CAI J. PCB Defect Detection via Local Detail and Global Dependency Information[J]. Sensors, 2023, 23(18): 7755.
- [84] XIE Y, HU W, XIE S, et al. Surface Defect Detection Algorithm Based on Feature-Enhanced YOLO[J]. Cognitive Computation, 2023, 15(2): 565-579.
- [85] YU H, LIN Q, LIU C. Design and implementation of embedded PCB defect detection system based on FPGA[C]//2023 IEEE 7th Information Technology and Mechatronics Engineering Conference (ITOEC): Vol. 7. 2023: 530-535.
- [86] CHEN C, WU Q, ZHANG J, et al. U2D2PCB: Uncertainty-Aware Unsupervised Defect Detection on PCB Images Using Reconstructive and Discriminative Models[J]. IEEE Transactions on Instrumentation and Measurement, 2024, 73: 1-10.
- [87] 张莹, 邓华宣, 王耀南, 等. 基于多通道特征融合学习的印制电路板小目标缺陷检测[J]. 仪器仪表学报, 2024: 10.
- ZHANG Y, DENG H X, WANG Y N, et al. Small defects detection of PCB based on multi-channel feature fusion learning[J]. Chinese Journal of Scientific Instrument, 2024: 10.
- [88] 王健, 肖迪, 冯李航, 等. 基于改进 YOLOv8s 的 PCB 小目标缺陷检测模型[J]. 计算机工程与应用, 2024: 1-11.
- WANG J, XIAO D, FENG L H, et al. A PCB Small Object Defect Detection Model Based on Improved YOLOv8s [J]. Computer Engineering and Applications, 2024: 1-11.
- [89] BHATTACHARYA A, CLOUTIER S G. End-to-end deep learning framework for printed circuit board manufacturing defect classification[J]. Scientific Reports, 2022, 12(1): 12559.
- [90] LEI L, LI H X, YANG H D. Multiscale Convolution- Based Probabilistic Classification for Detecting Bare PCB Defects[J]. IEEE Transactions on Instrumentation and Measurement, 2023, 72: 1-8.
- [91] LIM J, LIM J, BASKARAN V M, et al. A deep context learning based PCB defect detection model with anomalous trend alarming system[J]. Results in Engineering, 2023, 17: 100968.
- [92] CHEN W, MENG S, WANG X. Local and Global Context-Enhanced Lightweight CenterNet for PCB Surface Defect

- Detection[J]. Sensors, 2024, 24(14): 4729.
- [93] VAKILI E, KARIMIAN G, SHOARAN M, et al. Valid-IoU: an improved IoU-based loss function and its application to detection of defects on printed circuit boards[J]. Multimedia Tools and Applications, 2024: 1-24.
- [94] LIU L J, ZHANG Y, KARIMIC H R. Defect detection of Printed circuit board Surface based on an improved YOLOv8 with FasterNet backbone algorithms[M/OL]. (2024-08-30)[2024-09-14].<https://www.researchsquare.com/article/rs-4823049/v1>.
- [95] LI Z, LI A, ZHANG Y, et al. BEW-YOLO: An Improved Method for PCB Defect Detection Based on YOLOv7[C]//2023 IEEE 29th International Conference on Parallel and Distributed Systems (ICPADS). 2023: 268-274.
- [96] LING Q, ISAN A M. TD-YOLO: A Lightweight Detection Algorithm for Tiny Defects in High-Resolution PCBs[J]. Advanced Theory and Simulations, 2024, 7(4): 2300971.
- [97] YUAN M, ZHOU Y, REN X, et al. YOLO-HMC: An Improved Method for PCB Surface Defect Detection[J]. IEEE Transactions on Instrumentation and Measurement, 2024, 73: 1-11.



杨思念（2001—），女，硕士研究生，主要研究方向为目标识别。  
YANG Siniang, born in 2001, M.S.candidate, Her research interests include target recognition.



曹立佳（1982—），男，博士，副教授，硕士生导师，主要研究方向为目标识别、无人机系统导航与控制等。  
CAO Lijia, born in 1982, Ph.D., associate professor, Ph.D. supervisor. His research interests include target recognition, UAV system navigation and control, etc.



杨洋（1998—），男，硕士研究生，CCF 会员，主要研究方向为目标定位及跟踪。  
YANG Yang, born in 1998, M.S.candidate, CCF member. His research interests include target localization and tracking.



郭川东（1995—），男，博士，讲师，硕士生导师，主要研究方向为机器视觉、复杂系统建模与控制等。  
GUO Chuandong, born in 1995, Ph.D., lecturer, Ph.D. supervisor. His research interests include machine vision, modeling and control of complex systems, etc.