

分类号 \_\_\_\_\_  
学校代码 10488

学号 202104703078  
密级 \_\_\_\_\_

武汉科技大学

硕士学位论文

全日制学术学位

少量样本下的 PCB 缺陷检测  
方法研究

学位申请人： 胡思颖

学科专业： 控制科学与工程

指导教师： 伍世虔

答辩日期： 2024 年 5 月 8 日

**A Dissertation Submitted in Partial Fulfillment of the Requirements  
for the Degree of Master in Engineering**

**Research on PCB defect detection method  
based on a small number of samples**

**Master Candidate:**

**Siying Hu**

---

**Major:**

**Control Science and Engineering**

---

**Supervisor:**

**Shiqian Wu**

---

**Wuhan University of Science and Technology**

**Wuhan, Hubei 430081, China**

**May, 2024**

## 摘 要

印刷电路板（PCB）需求日益增加，机器视觉技术因其可靠性在 PCB 自动缺陷检测中得到了广泛应用。常用的 PCB 自动缺陷检测方法主要包括：基于传统的有参考检测和基于学习的检测。本学位论文以保持检测精度的同时减少对样本图像的依赖为目标，重点解决传统有参检测法受限于模板图像质量和基于学习方法受限于大量带标记数据两个问题。论文的主要工作如下：

（1）针对有参检测在低质量模板图像条件下表现差，且其表现高度依赖于图像对齐质量的问题，提出一种不依赖模板图像的基于两阶段分割与规则校验的 PCB 裸板无参考检测法。首先基于直方图的自动初始化聚类中心以及局部信息增强的模糊聚类分割算法，实现了 PCB 裸板图像的粗分割；然后利用基于先验信息的快速水平集方法，实现了 PCB 裸板图像的精分割；最后以前景区域的连通域为基本单位，利用连通域分析、面积特征和圆的几何特性，实现了图像中线路和导孔完整性缺陷检测。实验结果表明所提方法检测精度满足工业要求。

（2）针对深度学习进行缺陷检测需依赖大量高质量标记数据集的问题，提出一种基于教师学生网络与伪标签的半监督学习的 PCB 板检测方法。首先采用以 YOLOv5 为检测网络的基于教师、学生两种模型联合学习的半监督方法，利用少量标记样本，从无标记样本中学习类别模式；然后对高置信度和高不确定性伪标签采取不同处理策略，提高模型鲁棒性和泛化能力，对高不确定性伪标签，利用软损失挖掘类间丰富的相关关系，解决了次优分配导致伪标签不一致性的问题；最后指数移动平均（EMA）方法用于学生模型对教师模型进行更新，提高了模型检测性能。实验结果表明在少量标记 PCB 板数据情况下具有可行性。

（3）基于所提出的方法，设计并实现了一套 PCB 自动缺陷检测系统，为无参考数据和少量有标记训练样本两种实际应用场景下的 PCB 自动缺陷检测提供了可靠解决方案。

**关键词：**缺陷检测；无参考；图像分割；半监督学习

## Abstract

The demand for Printed Circuit Board (PCBs) is increasing, and machine vision technology has been widely studied for its reliability in automatic PCB defect detection. Commonly used methods for automatic defect detection in PCBs are traditionally categorized into reference-based and learning-based detection. This dissertation focuses on reducing sample image while maintaining detection accuracy, delving into two key aspects: the limitations of traditional reference-based detection due to template image quality, and the challenges of learning methods requiring large amounts of labeled data. The primary contributions of this dissertation are outlined as follows:

1. Addressing the limitations of reference-based detection under low-quality template images and its reliance on image alignment quality, a two-stage segmentation and rule verification PCB Bare Board reference-free detection method is proposed. Initially, coarse segmentation of the PCB Bare Board image is achieved through an algorithm utilizing automatic initialization of histogram clustering centers and fuzzy clustering segmentation with local information enhancement. Subsequently, fine segmentation is attained using the fast level set method based on a priori information. Finally, defect detection, including integrity defects of circles, lines, and guide holes, is realized through connectivity domain analysis and geometric properties extraction. Experimental results demonstrate that the proposed method meets the requirements for defect detection accuracy on PCB Bare Board images.

2. In response to the need for deep learning-based defect detection, which typically relies on extensive high-quality labeled datasets, a semi-supervised learning method for PCB detection is proposed. Leveraging a teacher-student network with pseudo labeling, this approach requires only a small amount of labeled data. Initially, a semi-supervised method involving joint learning of teacher and student models, with YOLOv5 as the detection network, learns category patterns from unlabeled samples with a small number of labeled samples. Subsequently, different strategies are applied to high-confidence and high-uncertainty pseudo-labels to enhance the model's robustness and generalization ability. For high-uncertainty pseudo-labels, soft loss is

used to mine the rich inter-class relationships, addressing inconsistencies in pseudo-labels due to sub-optimal allocation and enhancing model detection accuracy. Finally, Exponential Moving Average (EMA) is utilized for weight updating of the teacher model by the student model, thereby improving model detection performance. Experimental results demonstrate feasibility with a limited amount of labeled PCB data.

3. The dissertation also entails the design and implementation of an automatic defect detection system integrating the aforementioned methods. This system offers a reliable solution for automatic PCB defect detection in two practical application scenarios: scenarios lacking training samples and scenarios with a limited number of labeled training samples.

**Keywords:** Defect detection; Reference-free; Image segmentation; Semi-supervised learning

## 主要符号对照表

符号	对照含义
$N$	图像中总像素数
$M$	直方图的像素级数
$C$	聚类的数量
$x_i$	第 $i$ 个像素的灰度值
$\delta_i$	第 $i$ 个灰度级对应的灰度值
$\gamma_i$	第 $i$ 个灰度级对应的总像素数
$v_j$	第 $j$ 个聚类中心
$u_{ij}$	第 $i$ 个像素属于第 $j$ 个聚类中心的模糊隶属度
$Z$	调控因子
$X_i$	第 $i$ 个像素对应的像素坐标
$C_0$	轮廓内部平均灰度值
$C_B$	轮廓外部平均灰度值
$L_s$	标记数据的损失
$L_u$	未标记数据的损失
$CE$	二值交叉熵损失函数
$\mathbb{I}_{\{\cdot\}}$	满足条件 $\{\cdot\}$ 时为 1, 否则为 0

## 插图索引

图 1.1 PCB 表面缺陷检测方法.....	2
图 1.2 典型机器视觉检测系统基本构成 .....	3
图 1.3 本文拟解决的难点及研究内容 .....	5
图 1.4 本文 PCB 缺陷检测系统组成.....	6
图 2.1 PCB 表面缺陷实例图.....	10
图 2.2 本文 PCB 图像 .....	11
图 2.3 FCM 隶属矩阵.....	14
图 2.4 缺陷检测任务流程 .....	16
图 2.5 STAC 算法示意图 .....	17
图 2.6 Unbiased Teacher 算法示意图 .....	18
图 2.7 Softteacher 算法示意图.....	18
图 3.1 缺陷检测整体结构框架示意图 .....	21
图 3.2 调控因子 $Z$ 作用于隶属度矩阵 .....	25
图 3.3 PCB 图像分割结果 .....	28
图 3.4 PCB 裸板线路缺陷样本.....	29
图 3.5 缺陷示意图 .....	29
图 3.6 PCB 裸板连通域-面积序列统计图 .....	30
图 3.7 连通域分析示意图 .....	31
图 3.8 连通域标记结果 .....	32
图 3.9 短路原理 .....	32
图 3.10 开路原理 .....	34
图 3.11 凸起原理 .....	34
图 3.12 标准图像二值分割结果 .....	36
图 3.13 复杂图像二值分割结果 .....	37
图 3.14 PCB 裸板图像二值分割结果.....	39
图 3.15 PCB 裸板图像线路检测实例图.....	40
图 3.16 PCB 裸板图像导孔检测实例图.....	41
图 4.1 基于教师学生网络与伪标签的 PCB 半监督缺陷检测网络整体框架图 .....	45
图 4.2 不同伪标签选择策略 .....	48
图 4.3 基于伪标签分配器的 PCB 板表面缺陷半监督检测算法概览 .....	51
图 4.4 未标记图像数据增强 .....	53

图 4.5 PCB 板图像部分缺陷检测结果对比图.....	54
图 4.6 不同比例标记数据在不同算法中的结果对比图 .....	55
图 5.1 检测设备示意图 .....	57
图 5.2 光照不均的 PCB 示意图.....	58
图 5.3 两种照明方式示意图 .....	58
图 5.4 PCB 缺陷检测软件系统主界面示意图.....	60
图 5.5 软件系统对 PCB 裸板检测结果示意图.....	61
图 5.6 软件系统对 PCB 板检测结果示意图.....	62



## 表格索引

表 3.1 PCB 裸板缺陷分类表.....	30
表 3.2 本文算法对“标准图像”的分割性能.....	37
表 3.3 本文算法对“复杂图像”的分割性能.....	38
表 3.4 本文算法对“PCB 裸板图像”的分割性能 .....	39
表 3.5 PCB 裸板线路缺陷检测算法方案检测性能.....	40
表 3.6 本文算法对“PCB 裸板图像”的检测时间 .....	41
表 4.1 实验环境配置 .....	52
表 4.2 不同方法在 PCB 数据集上检测效果.....	56
表 5.1 基于两阶段分割与规则校验的 PCB 裸板缺陷检测算法系统测试结果 .....	63
表 5.2 基于师生网络与伪标签的半监督 PCB 板缺陷检测算法系统测试结果 .....	63

# 目 录

第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	1
1.3 本文研究内容.....	5
1.4 本文章节安排.....	7
第 2 章 相关理论概述 .....	8
2.1 PCB 缺陷概述 .....	8
2.2 图像分割算法介绍.....	11
2.2.1 常见的图像分割算法.....	11
2.2.2 基于模糊 C 均值聚类的图像分割算法.....	13
2.3 基于深度学习的目标检测算法概述 .....	14
2.3.1 目标检测器.....	15
2.3.2 目标检测在缺陷检测任务中的应用.....	15
2.4 半监督目标检测算法基本理论 .....	16
2.5 本章小结.....	19
第 3 章 基于两阶段分割与规则校验的 PCB 裸板缺陷检测算法 .....	20
3.1 基于两阶段分割与规则校验的 PCB 裸板缺陷检测算法总体设计 .....	20
3.2 基于改进 FCM 的 PCB 裸板图像的粗分割 .....	21
3.2.1 目标函数定义.....	21
3.2.2 调控因子定义.....	24
3.2.3 初始聚类中心自动选取.....	25
3.3 基于先验信息的快速水平集 PCB 裸板图像的精分割.....	26
3.4 PCB 裸板图像线路区域检测与识别.....	29
3.4.1 PCB 裸板线路缺陷检测方案概述 .....	29
3.4.2 连通域分析.....	30
3.4.3 短路缺陷识别.....	32
3.4.4 开路缺陷识别.....	33
3.4.5 凸起缺陷识别.....	34
3.5 PCB 裸板导孔完整性缺陷识别 .....	35
3.6 实验结果及分析.....	35
3.6.1 图像分割.....	35
3.6.2 线路缺陷检测.....	39
3.6.3 导孔完整性缺陷检测.....	41

3.7 本章小结.....	42
第4章 基于师生网络与伪标签的半监督PCB板缺陷检测方法 .....	43
4.1 基于师生网络与伪标签的半监督缺陷检测算法设计 .....	43
4.1.1 问题描述与分析.....	43
4.1.2 总体框架.....	44
4.2 基于伪标签分配器的半监督缺陷检测方法 .....	46
4.2.1 基于伪标签的半监督缺陷检测方法的问题 .....	46
4.2.2 伪标签分配器设计 .....	47
4.2.3 损失函数.....	48
4.3 PCB板表面缺陷检测模型 .....	50
4.4 实验结果及分析.....	51
4.4.1 实验说明.....	51
4.4.2 PCB板实例检测 .....	52
4.4.3 模型对比实验.....	55
4.5 本章小结.....	56
第5章 缺陷检测系统设计与实现 .....	57
5.1 系统硬件设计.....	57
5.1.1 光源系统.....	58
5.1.2 成像系统.....	59
5.2 系统软件设计.....	60
5.2.1 系统界面设计及功能模块划分.....	60
5.2.2 软件系统结果展示.....	61
5.3 系统测试.....	62
5.4 本章小结.....	63
第6章 总结与展望 .....	64
6.1 总结.....	64
6.2 展望.....	65
参考文献.....	66

## 第 1 章 绪论

### 1.1 研究背景及意义

制造业作为国家经济的核心构成，直接映射出一个国家的实力。随着制造业规模的不断扩大，为了适应市场需求，工业产品的数量和种类与日俱增。产品除了需要满足正常使用需求外，还需要确保表面质量达到一定标准，其表面缺陷不仅会影响产品的销量，甚至会损害产品的安全性和使用价值。因此，目前对产品表面质量的控制已成为市场竞争中的关键指标之一<sup>[1]</sup>。

以印刷电路板（Printed Circuit Board, PCB）为例。PCB 作为现代电子制造业的重要组成部分，是电子制造业中最重要的单元之一<sup>[2]</sup>，广泛应用于各类电子设备。然而在其制造过程中，由于操作不当或技术故障，不可避免地会出现各种表面缺陷。如果不能快速准确地检测出 PCB 缺陷，会导致带缺陷的 PCB 继续进行后续加工工序，最终造成大量电路板被报废，这既浪费生产成本，又降低了生产效率。反之，部分存在缺陷的 PCB 可以被及时检测，并通过 PCB 修补设备修复 PCB 上的缺陷，将其转变为合格的产品，重新进入制造流程，进行后续加工工序，从而降低了产品报废率。因此，对 PCB 进行表面缺陷检测至关重要。

随着 PCB 产量的大幅度增长，传统的人工目视检测由于效率低且缺乏固定的判别准则，已不利于 PCB 的有效检测。目前，随着科学技术水平的提高，机器视觉技术已成为实现 PCB 表面缺陷检测的一种有效技术手段。用机器视觉技术代替传统的人工目视技术，可以减少人工参与度，能长时间稳定、可靠、快速地工作，有效降低检测误差，提高检测结果的客观性与可靠性。

基于机器视觉的检测方法通过图像处理算法检测与判断缺陷类别。随着深度学习的诞生，检测精度达到了一个新的级别，为 PCB 表面缺陷检测提供了强有力的技术保证<sup>[3]</sup>。然而这两类方法仍然存在一些问题：传统图像处理大多采用有参法进行检测，受模板图像质量的影响，且要求待测图像与模板图像严格对齐，涉及多张图像，降低了检测结果的可靠性和准确率；基于深度学习的方法需要依赖大量高质量的标记数据，但在实际工业生产中，获取大量带标记的缺陷数据十分困难，缺乏足够的标记数据将导致模型的检测精度随之下落。针对这些问题，本文以 PCB 为对象，针对两种方法体系分别研究了无参检测法以及半监督学习检测法。

### 1.2 国内外研究现状

经过多年的研究与发展，利用机器视觉技术通过图像分析与算法处理，已能

有效地检测 PCB 表面缺陷，并在国内外已经实现了产业化。本节首先简述了 PCB 缺陷检测的方式，包括传统人工目视检测、电器检测与自动光学检测（Automatic Optical Inspection, AOI），然后对 AOI 检测方式中机器视觉系统的组成要素进行了概述，最后重点介绍了 PCB 缺陷检测算法的研究现状。

### （1）PCB 缺陷检测方式

人工目视检测法是传统的缺陷检测方法之一，如图 1.1（a）所示，该方式除了适用于 PCB 外，还适用于半导体以及显示器等多种工业产品<sup>[4]</sup>，但人工目视检测主要通过放大镜或显微镜观察产品的细节，由主观进行判断，效率低、精度差、主观因素影响大，经常出现错检、漏检等问题。电气检测法基于设计的电路图，对电路板中关键点处的阻抗特性进行逐一测试，如图 1.1（b）所示，该方法虽然检测速度快，但必须通过将检测探针与板体发生物理接触来实现，可能会对板体造成不可逆的损害。此外，基于机器视觉的 AOI 缺陷检测技术，如图 1.1（c）所示，是一种利用光学系统与图像处理技术对 PCB 表面缺陷进行自动检测的方法，除此之外，还能在实际工业生产过程中执行分析与测量等多种任务<sup>[5]</sup>。作为一种高效实用的技术，AOI 在现代电子制造业中得到广泛的应用。综上所述，目前 PCB 检测的主要发展方向是能稳定、快速且对 PCB 无损害的 AOI 检测技术。




图 1.1 PCB 表面缺陷检测方法：（a）人工目视；（b）电气检测；（c）AOI 检测

### （2）机器视觉技术

AOI 系统是在工业场景中应用机器视觉技术的典型代表之一，通常由硬件系统和软件系统两个部分组成<sup>[6]</sup>。其中，硬件系统主要通过图像采集装置完成图像的采集工作，软件系统主要负责对采集到的图像，通过图像处理算法进行特征信息提取、分析以及检测等操作，以实现相应缺陷的检测。此外，为了适应不同的产品检测需求，系统被细分为四个主要类别：表面检测（针对产品可观察的表面信息）、维度检测（需要提取三维空间内的产品信息）、结构检测（主要关注产品内部各组件的装配关系）以及运行质量检测（主要关注产品在实际运行中的精度与操作的正确性）<sup>[7]</sup>。本文旨在检测产品表面可观察的缺陷，属于上述表面检测类别，也是目前主要的缺陷检测方式<sup>[1]</sup>。

在实际工业应用中，一套完整的机器视觉检测系统通常由计算机、光源、相机、运动装置等设备组成，这些设备协调工作，以实现系统的完整功能，如图 1.2 所示为一个典型机器视觉检测系统的基本构成。目前，机器视觉系统可以根据工业生产流水线的需求，实现半自动或全自动化生产，即该系统可以独立存在，由工人将待检测产品送至该系统中进行检测；也可以作为整个自动化生产设备的一部分，嵌入到工业生产流水线中。




图 1.2 典型机器视觉检测系统基本构成

### （3）PCB 缺陷检测算法

基于机器视觉的 PCB 缺陷检测系统虽然由硬件系统与软件系统构成，但是系统的核心部分仍然是软件系统中的检测算法。近年来，国内外研究者们提出了很多 PCB 缺陷检测算法，具体可以分为参考法、无参考法和混合算法这三类<sup>[8]</sup>。

1) 参考法。该方法通过将目标 PCB 图像与一个无缺陷的标准 PCB 图像（参考图像）进行逐像素的比较分析（图像差分），以识别出两者之间的差异，这些差异区域通常被认定为缺陷。其中，逐像素分析比较法通常将两幅图像进行异或（XOR）运算来实现。算法实现简单直观，但易受光照影响，且在图像差分处理前需要将目标图像与标准图像进行严格对齐等操作，否则会导致误检与漏检。

2) 无参考法。无参考法在检测 PCB 缺陷时不依赖于参考图像，仅根据 PCB 的预设规则（如一些特定的几何形状或图像编码方式）来进行检测。若待测图像不符合规则，则视为存在缺陷。这种方法仅需单张图像参与，避免了苛刻的光照要求，降低了计算复杂度，但是对于复杂 PCB 检测效果不佳。

3) 混合算法。结合了参考法和无参考法各自优点的混合算法，虽然能够充分应用两种方法的长处，但是结合了多种算法，计算量大，鲁棒性差，且该算法

不够成熟，目前并没有一种合适的混合算法可以较好对 PCB 缺陷进行检测。

针对现有 PCB 缺陷检测算法存在的不足，近年来国内外众多研究者提出了很多相关算法。刘尚军等人<sup>[9]</sup>通过提取待测图像特征，使用多个模板进行比对，实现了对 PCB 缺陷的检测，同时提高了检测的准确率；Ibrahim 等人<sup>[10]</sup>提出一种基于小波变换的去噪算法，并针对图像差分法，将差分图像拆分为正负两个模板分别应用该去噪算法，有效减少了 PCB 缺陷检测中因配准精度不足而产生的噪声；李志敏等人<sup>[11]</sup>提出一种在 Harr 小波对灰度直方图进行平滑后，再利用 PCB 标准图像的先验信息实现分割阈值快速计算的图像分割方法，该方法有效减少了图像分割中存在的噪声；Ibrahim 等人<sup>[12]</sup>通过将待测图像与标准图的正负作差结果分别进行去噪处理，以缓解差分法存在的噪声问题；熊邦书等人<sup>[13]</sup>采用形态学处理方法，去除了差分法中由于伪影而产生的虚假缺陷；Kaur 等人<sup>[14]</sup>基于图像差分的结果，实现了 PCB 缺陷的分类；Raj 等人<sup>[15]</sup>提出在使用待测图像与标准图像正负作差检测缺陷之前，先将图像转换到 YUV 空间进行滤波处理，提高了检测算法的准确率；朱寒等人<sup>[16]</sup>提出了一种基于图像差分的多级二值化检测算法，降低了 PCB 缺陷检测的漏检率。由于参考法相对直观，近些年的研究均是围绕参考法中的部分进行改进，但这种方法对于 PCB 标准图像的质量要求极高，而实际生产过程中包含的不确定因素对制造结果影响大，使得参考图像难以有明确标准。此外，在后续检测中还需要参考图像与待检测图像的严格对齐与高精度的图像配准，易受光照影响，导致漏检与误检。因此，为了避免这些问题，如何有效利用单张图像进行无参检测值得研究。

随着深度学习的飞速发展，国内外研究者们开始认识到 PCB 缺陷检测问题本质上是一种特殊的目标检测问题，并开始关注利用深度学习的方法检测 PCB 缺陷。如 Shi 等人<sup>[17]</sup>针对 PCB 图像中微小缺陷难以有效检测的问题，提出了一种引入语义提升模块融合不同级别特征，并使用注意力机制学习跨通道融合特征关系的单阶段目标检测器 SSDT，实验表明该方法可以快速检测微小缺陷；耿振羽等人<sup>[18]</sup>利用残差网络代替 VGG 成为 Faster R-CNN 的主干网络，改进 Faster R-CNN 模型，实验表明在 PCB 缺陷检测中检测性能良好；李澄非等人<sup>[19]</sup>采用单特征层结构和改进 CSP 结构的残差单元设计了针对 PCB 缺陷检测的 YOLOv4 算法，并以 K-means++ 对先验框重新聚类，利用该算法进行 PCB 缺陷检测，同时提升了检测的精度与定位的精度；Mamidi 等人<sup>[20]</sup>为了快速地识别与分类 PCB 图像中的缺陷，提出了一种基于 YOLO V4 TINY 网络的 PCB 检测算法，实现了对 PCB 缺陷快速准确的检测。相比传统基于图像处理算法的 PCB 缺陷检测技术，基于深度学习的 PCB 缺陷检测技术更受研究者们青睐，然而，这类技术往往需要大量带标记缺陷数据集的支撑，这在实际工业场景中可能会面临数据集不足或标记数据集成

本高的问题。因此，基于半监督学习的缺陷检测成为一个备受关注的研究方向，并已取得了一定的成果，如 Gao 等人<sup>[21]</sup>提出了一种使用卷积神经网络的半监督学习方法，用于钢材表面缺陷识别，所提出的方法仅需要少量的标记样本，并利用未标记的数据来帮助训练。此外，通过引入伪标签对 CNN 进行了改进，实验结果表明，所提出的方法可以在少量的标记数据下取得较好的检测效果。因此，如何有效利用少量标记 PCB 图像进行缺陷检测的研究具有实际意义。

### 1.3 本文研究内容

本文主要以 PCB 缺陷检测为研究对象，基于机器视觉的相关理论，从传统图像处理与深度学习的两个角度研究 PCB 表面缺陷检测方法，并且最终针对这两个角度分别提出两种完整的 PCB 表面缺陷检测算法。如图 1.3 所示为本文拟解决的难点问题以及对应的具体研究内容：

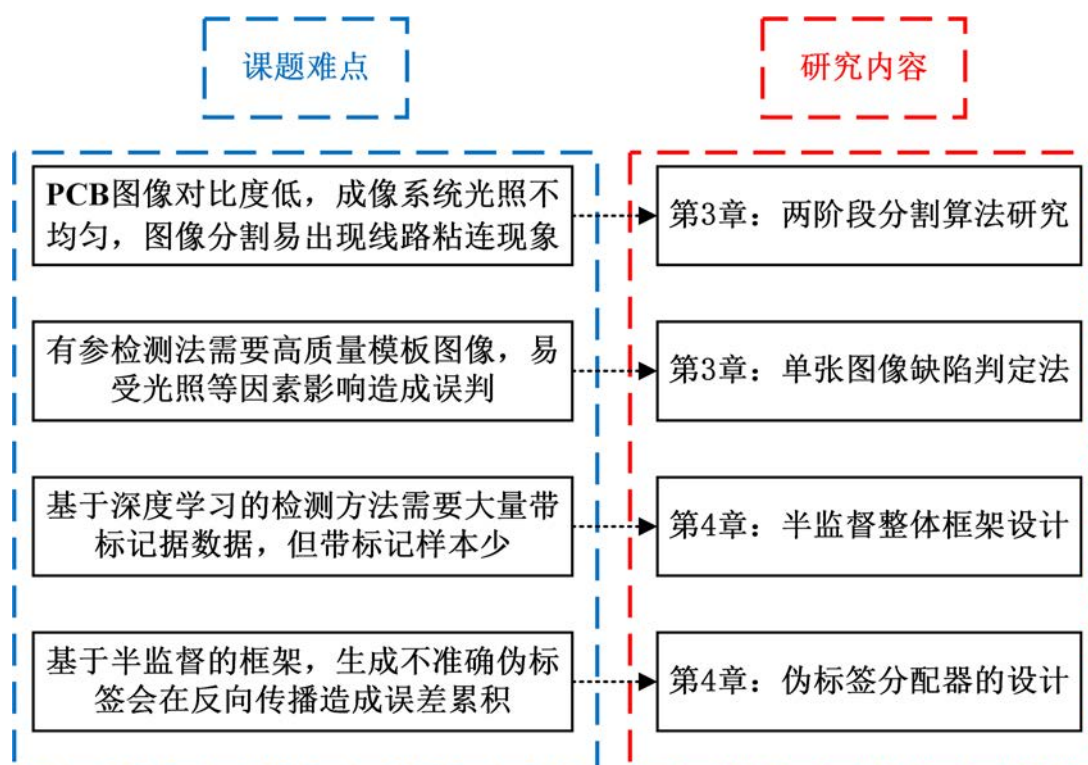


图 1.3 本文拟解决的难点及研究内容

(1) 基于两阶段分割与规则校验的 PCB 裸板图像缺陷检测算法。大多数基于传统图像处理的 PCB 裸板缺陷检测方法都是有参检测，该方法虽然思路简单，但对配准要求很高，轻微偏移都会造成误判，且需要多张图像参与。因此针对该问题，本文提出一种基于两阶段分割与规则校验的无参考缺陷检测法。该方法中主要检测对象为 PCB 裸板图像的前景区域，故首先需要解决对光照不均的 PCB



裸板图像进行图像分割所存在的线路粘连、断线等问题，在分析常见图像分割算法后，本文针对模糊聚类方法鲁棒性不强，以及初始聚类中心随机选取影响分割效果的问题，提出了一种基于局部信息增强与基于直方图的自动初始化聚类中心的模糊聚类算法。此外，为了确保图像前景区域的特征完整性，在此基础上，针对水平集对初始轮廓敏感以及计算量大的问题，提出了一种基于先验信息的快速水平集方法，实现了对 PCB 图像前景区域的精分割。通过上述分割方法处理后，以前景区域的连通域为基本单位，利用 PCB 设计规则和导孔的区域组合特征，针对 PCB 裸板图像上的短路、开路、凸起和导孔完整性等缺陷提出一套缺陷识别方法，该方法避免了图像对齐与配准等操作，从而确保了 PCB 缺陷检测的准确性和鲁棒性。

(2) 基于师生网络与伪标签的半监督 PCB 板缺陷检测方法。大多数基于学习的方法均是以大量带标记的缺陷数据集作为支撑，以大规模数据作为驱动，检测精度高。但实际工业场景中，难以收集大规模带标记的缺陷数据集，因此本文设计了一个半监督学习算法来缓解对标记数据的依赖，达到只用少量标记数据训练的目的。然而目前半监督的学习方法中，多是基于两阶段检测网络，其实时性难以达到工业生产的要求。因此，本文提出了一种基于单阶段目标检测模型 YOLOv5 的半监督检测方法，提高了在实际检测任务中的实时性。此外，半监督学习中，重点需要解决伪标签分配的问题，因为伪标签的质量会对训练和检测效果产生很大影响。针对此问题，本文提出了一种新的伪标签分配器，减少了伪标签对半监督检测方法中训练和检测效果的影响，提高了最终的检测效果。

(3) PCB 缺陷检测系统的设计与实现。本文针对所提出的两套 PCB 缺陷检测方法，设计并实现一套 PCB 自动缺陷检测系统，包含硬件与软件两部分。硬件部主要在 PCB 的图像采集以及后续传输任务中发挥作用；软件部分集成了本文所提出的两套检测算法，主要负责 PCB 图像的检测。其整体结构如图 1.4 所示。

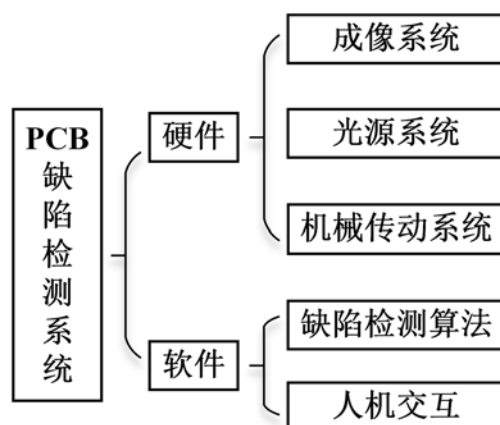


图 1.4 本文 PCB 缺陷检测系统组成

## 1.4 本文章节安排

本论文共六章，各章节内容安排如下：

第1章：绪论。首先介绍本文的研究背景及意义，其次概述了PCB缺陷检测方式与机器视觉技术，并介绍了当前PCB缺陷检测算法的国内外研究现状，然后阐述了本文的具体研究内容，最后简述了本文各章节的内容安排。

第2章：相关理论概述。首先介绍常见的PCB缺陷以及本文所检测的目标缺陷，然后围绕传统图像处理方法中PCB缺陷检测所涉及到的图像分割技术展开，重点介绍了模糊聚类分割算法，为本文所提两阶段分割方法奠定了理论基础，最后围绕深度学习中表面缺陷检测所涉及到的理论与方法进行概述，包括基本的目标检测算法的介绍，以及半监督学习的相关知识介绍，为本文构建PCB表面缺陷半监督检测方法奠定了理论基础。

第3章：基于两阶段分割与规则校验的PCB裸板缺陷检测算法。首先介绍本章所提方法的总体设计，其次重点介绍了本章提出的两阶段图像分割算法：第一阶段采用基于局部信息增强和直方图自动初始化聚类中心的模糊聚类算法对图像进行粗分割；第二阶段则采用基于先验信息的快速水平集算法对图像进行精分割，然后介绍了所提的基于线路区域规则特征的缺陷判定方法，最后通过实验验证了该方法的有效性。

第4章：基于师生网络与伪标签的半监督PCB板缺陷检测方法。首先介绍本章所提基于单阶段检测网络的半监督方法总体框架设计，然后重点介绍了本章所提出的半监督学习中关于伪标签分配器的设计细节，最后通过实验对本章所提出的方法进行验证。

第5章：PCB缺陷检测系统设计与实现。首先根据PCB生产过程中的自动化和智能化需求，介绍了系统的硬件部分，然后对整合了本文提出的两种PCB缺陷检测算法的软件部分阐述了其总体设计，最后对系统的两套核心算法进行了测试，并对测试结果进行了分析。

第6章：总结与展望。该部分总结了本文的工作，指出了其中的不足，并对后续的改进方向进行了展望。

## 第 2 章 相关理论概述

### 2.1 PCB 缺陷概述

国内外针对 PCB 缺陷所制定的标准多种多样,不同的标准在侧重的方向上略有差异。其中,电子行业最广泛认可涵盖了 PCB 制造过程各个方面,由国际电子工业联接协会制定的 IPC (Institute of Printed Circuit) 标准,该标准根据不同程度的质量检测要求,具体细分为三种检测等级。其中,1 级为产品的最低等级,其外观瑕疵存在与否并不重要,只需能正常发挥功能即可;3 级为产品的最高等级,要求产品除了保证外观质量与功能的正常发挥外,还需要具备高可靠性与高耐用性。此外,IPC-A-600 标准作为 IPC 中最为重要的标准之一,对 PCB 的外观接受条件和拒收条件进行了详细的描述。

根据 IPC 标准,PCB 的特征被划分为外部可观察特征和内部可观察特征两个类别。具体而言,前者包括所有可以直接从 PCB 表面观察到的特征,同时也包括那些虽然位于 PCB 表面之下,但仍能从外部(表面)观察到的特征。这类特征根据 PCB 的各个组件,具体可分为以印制板边缘、基材表面、基材表面下以及图形精确度为主的共 11 个子类。而每个子类中又包含了多种具体的缺陷类型,以基材表面下为例,其指的是基材表面下方区域附着的杂质所造成的划痕或开路等缺陷。内部可观察特征则主要指需要对 PCB 进行切片或其它形式处理才能观察到的内部特征,包括介质材料、导电图形、镀覆孔(钻孔)与镀覆孔(冲孔)等四个特征子类。

本文主要目的为检测 PCB 的表面缺陷,而 PCB 的内部可观察特征通常需要借助显微镜、X 射线检测以及热应力测试等专业工具才能评估相关指标是否满足 PCB 的生产要求,无法直接从所采集的 PCB 图像中提取到相关内部特征信息进行评估。因此,本文只研究部分外部可观察特征,以实现 PCB 表面缺陷的检测。进一步而言,PCB 的核心结构是基板,其表面蚀刻有导电路径(即电路图形),并包含一定数量的孔洞。这些导电路径和孔洞的布局以及形态对 PCB 的电气性能起着决定性作用,除此之外的其它区域则主要负责确保电气隔离的功能。需要说明的是,本文的关注点在于线路蚀刻异常和孔洞分布异常对 PCB 电气特性的影响,因此,类似于印制板边缘处未接触到电路图形的缺陷,并不包含在本文的检测范围内。

综上所述,本文主要关注以下几种 PCB 特征,并依据这些特征与 PCB 图像中异常区域的形状、大小和位置等信息,将缺陷分类为短路、开路、凸起、凹陷、

孔洞以及残铜这六种类型。

### （1）印制板边缘缺陷

PCB 中基板边缘的平滑度与完整性对于电子元件的可靠性至关重要。边缘的任何缺口，一旦与导电路径接触，则被视为缺陷。该缺陷的具体类型取决于缺口对导电路径的侵蚀程度。侵蚀严重可能会导致导体断开，从而引起开路，使整个电路无法正常工作；轻微的侵蚀可能导致凹陷，进而影响整体电路性能。

### （2）基材表面

基材表面的光滑平整对于电路板的质量和可靠性至关重要。根据 IPC 标准，基材表面应保持无瑕疵，即不能存在麻点或空洞。若存在，则不能跨接导体，且其尺寸必须小于 0.8mm。在实际采集到的 PCB 图像中，这些麻点或空洞的灰度值虽然与基材的灰度值会有所偏离，但与线路区域的灰度值非常接近，从而会导致 PCB 出现残铜现象，而当麻点或空洞等异常区域跨接导体路径时则可能导致电路短路。

### （3）基材表面下

基材表面下是指的是位于 PCB 基材表面下方的内部区域。在实际 PCB 生产过程中，该区域会附着杂质即外来夹杂物，通常是金属或非金属微粒，主要夹裹或埋在绝缘材料内。由于 PCB 具有一定的透明度，所采集到的 PCB 图像仍然可以观测到部分杂质，具体表现为 PCB 图像的线路或非线路区域出现类似于划痕的深色区域。当夹杂物的面积与位置跨接导体时，可能导致开路。

### （4）图像精确度

在实际 PCB 的制造中，线路、孔洞切口等要素的尺寸必须符合具体型号 PCB 设计文件中的规定，并且根据 IPC 标准，用于验证 PCB 相关特性的设备必须具有足够高的测量精度，以确保对 PCB 尺寸验证的准确性。同时验证设备还必须具备高度的可靠性以及可重复利用性，以确保对 PCB 相关特性的验证能够准确可靠地进行。

在评估图像精确度这一类特征时，导体的宽度和间距均需要严格遵循设计文件中的规格。就导体的宽度而言，根据 IPC 标准，对于 1 级板，任何孤立导体的边缘缺陷导致宽度减少的部分不得超过该导体最小宽度的 30%，同时缺陷的总长度不得超过导体总长的 10%，或不超过 25mm，具体则根据实际情况选取两者中的较小值。相较于 1 级板，2 级板和 3 级板虽然对于最小宽度的要求与 1 级板一致，但在缺陷总长度的标准上有所提升，分别设定为不超过导体总长的 20% 和 13mm。若 PCB 未能达到这些规定标准，则会导致线路出现凹陷或者开路缺陷。

就导体的间距而言，根据 IPC 标准，对于 3 级板，规定指出在任何孤立区域内，导体边缘的缺陷不应导致导体间距的减小超过导体最小间距的 20%。而对于

2 级板和 1 级板，这一要求相对宽松，允许导体间距因边缘缺陷而减少的比例达到导体最小间距的 30%。若 PCB 未能达到上述间距标准，则会导致线路出现凸起或者短路缺陷。

图 2.1 呈现了几种典型 PCB 缺陷的实物样例：




图 2.1 PCB 表面缺陷实例图：(a) 印制板边缘凹口；(b) 基材表面瑕疵；(c) 基材表面下杂质；(d) 导体宽度不一致-凹陷；(e) 导体宽度不一致-凸起；(f) 导体间距异常-短路

由于 PCB 缺陷成因的多样性，这些缺陷表现出多种不同的特征。再根据众多 PCB 制造商的生产需求，研究发现，在实际生产中，更重要的是确认缺陷是否对 PCB 的电气特性产生显著影响，而非某个缺陷的具体成因。因此，在评估 PCB 质量时，缺陷的成因并不是主要的评价标准，同样也不作为 PCB 验收的依据。相反，这些成因信息主要用于优化 PCB 的制造工艺。

综上所述，本文将所研究的缺陷具体分为短路、开路、孔洞、凸起、凹陷以及残铜这六种。其中，短路是指电流不通过电器，造成电流异常，可能引发电路过载，损坏电路板，甚至发生安全隐患；开路是指电路断开，电流无法在电路中流通，而导致电路无法正常工作。孔洞是指在打孔过程中机器误打或漏打，所造成的超出设计数量或不满足设计数量的孔洞。凸起或凹陷是在制造过程中因为某处材料不均匀或加工工艺问题，使其在某处发生形状上的变化。残铜则是指在 PCB 制造过程中由于参杂了部分杂质或蚀刻不均所导致的。需要说明的是，本文两种方案所检测的缺陷类型不同，但两种方案涵盖的缺陷类型总共为上述六种缺陷。此外，需要说明的是，PCB 上导体宽度和间距虽然在 IPC 标准中有明确的定量判定指标。但在实际生产中，众多 PCB 制造商需要根据自身生产的实际需求重

新设置合适的判定指标。本文所采用的完整 PCB 图像以及所对应的几种典型缺陷的 PCB 局部图像分别如图 2.2 所示：

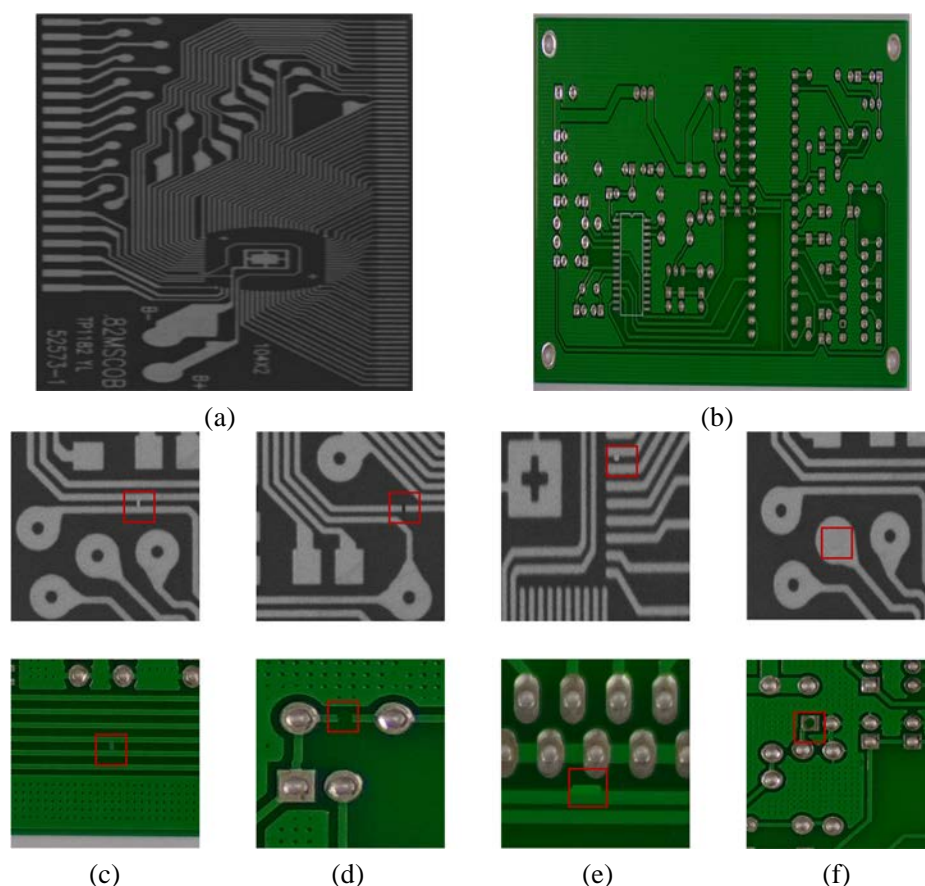


图 2.2 本文 PCB 图像：(a) PCB 裸板图像；(b) PCB 板图像；(c) 短路；(d) 开路；  
(e) 凸起；(f) 漏孔

## 2.2 图像分割算法介绍

基于传统图像处理的 PCB 缺陷检测算法中，重点关注图像的前景区域即线路区域，故图像分割<sup>[22]</sup>是该检测方法中必不可少的一项技术。本节主要讨论图像分割算法。

### 2.2.1 常见的图像分割算法

在图像分割算法中，主要分为以下几类方法：基于阈值的分割方法、基于边缘的分割方法、基于区域的分割方法和基于特定理论的分割方法等<sup>[23]</sup>。这些方法，的共同目标均是简化图像信息、消除干扰以突出特定的目标特征，其主要区别在于算法处理过程中所使用的图像信息不同：

- (1) 基于阈值的分割方法。这类方法利用图像的灰度分布信息来确定阈值，

并依据这些阈值对图像中所有像素进行分类。该方法的关键在于如何选取恰当的阈值，通常分为全局阈值和局部阈值两种。全局阈值即一幅图像只利用一个阈值来进行分割，通过分析整个图像的灰度统计得出；而局部阈值则通过将图像分为多个区域，并对每个区域进行阈值计算来进行分割。这种方法实现简单，效率高，对直方图呈现单峰分布的图像，分割效果理想。但面对具有复杂灰度分布的图像时，找到合适的分割阈值较为困难，分割效果较差。此外，由于仅考虑了图像灰度特性，易受噪声影响，因此不适合处理对比度较低的 PCB 裸板图像。

(2) 基于边缘的分割方法。这类方法的基本原理是通过图像中的边缘信息，将图像中的像素进行分类，其中边缘是指图像中灰度发生显著变化的区域，标志着一个区域的结束和另一个区域的开始，包含了丰富的语义信息。因此边缘检测是这类方法的关键步骤。常见的边缘检测方法主要有微分法、边界曲面拟合法以及边界查找法等。其中，微分法通常使用 Canny 以及 Roberts 等算子，通过检测图像中梯度和幅值的变化来定位边缘；边界曲面拟合法利用图像的梯度信息，通过预设的曲线模板，对边缘进行拟合，可以直接生成连续的边缘曲线；边界查找法则通过识别图像中的显著梯度变化来确定边缘像素，并通过连接这些像素形成边缘轮廓。由于这类方法主要依赖于图像的梯度信息，因此对噪声敏感。对于光照不均的 PCB 裸板图像，这类方法分割效果不佳。

(3) 基于区域的分割方法。这类方法依据纹理的相似性来实现图像的分割。根据生成方式的不同，可分为区域增长法和分裂合并法两类。其中，区域增长法的基本原理为从某一个像素点（种子点）开始，根据其与相邻像素之间的相似性，将相邻像素合并到对应的区域中，然后更新种子点位置，并不断重复上述过程，直至满足终止条件，得到最终的分割图像；分裂合并法首先将图像划分为多个子区域，然后根据预定的准则对这些子区域进行合并或分裂，逐步细化分割结果，以获得最终的分割图像。这类方法适用于前景与背景对比度高的图像，因此对于带有噪声的低对比度 PCB 裸板图像，分割结果中可能会存在诸如空洞等不连续的区域。

除了上述的几类算法，聚类相关方法也被广泛应用于图像分割的任务中。作为一种无监督的图像像素分类方法，聚类方法依据特定的准则对图像的像素进行分类，将具有相似特征的像素划分至相同的聚类簇，使得相同的类别具有同种属性，不同类别之间的差异明显。根据不同的划分标准，这类方法可被进一步划分为“硬聚类”和“软聚类”两种实现方式：前者将像素严格划分到具体类别，后者则为每个像素计算其属于各个类别的概率值，从而实现更精细的分割，更适合图像分割任务，但在处理噪声较多或背景复杂的图像时，其分割性能下降。

如上所述，本节介绍了多种常见的图像分割算法，每种算法都有各自的优势



与局限性，只有在特定的应用场景下才能发挥其最大的效用，并不存在一种能普遍适用于所有图像分割任务的通用方法。本文则主要关注模糊 C 均值聚类（Fuzzy C-Means, FCM）算法在 PCB 裸板图像分割中的应用。

### 2.2.2 基于模糊 C 均值聚类的图像分割算法

FCM 聚类算法最早由 Bezdek 等人<sup>[24]</sup>提出。该算法的核心思想是对于给定的样本，通过迭代更新，不断优化每个样本的隶属度向量，使得每个样本的类内间隶属度距离尽可能大，类外间隶属度距离尽可能小。具体而言，这类方法首先根据特定的规则从原始数据中提取特征，然后在构建的特征空间内，定义一个目标函数用于量化聚类的效果，并通过迭代计算优化目标函数，从而对每个元素进行隶属度划分，即利用计算目标函数的极小值得到对样本集的模糊聚类，这一特性使得其在描述图像的不确定性方面表现优异。FCM 的目标函数记为：

$$J_m = \sum_{i=1}^N \sum_{j=1}^C u_{ij}^m \|x_i - v_j\|^2 \quad (2-1)$$

$J_m$  服从如下约束关系：

$$\sum_{j=1}^C u_{ij} = 1, i = 1, 2, \dots, N \quad (2-2)$$

其中， $N$  是图像中的总像素数， $C$  是聚类的数量， $u_{ij}$  表示第  $i$  个像素属于第  $j$  个聚类中心的模糊隶属度， $m$  表示模糊隶属度指数，通常取  $m = 2$ ， $x_i$  表示第  $i$  个像素的灰度值， $v_j$  表示第  $j$  个聚类中心， $\|x_i - v_j\|^2$  表示像素  $x_i$  和聚类中心  $v_j$  的欧氏距离。

FCM 算法是将目标函数式（2-1）求最小化的过程，对于该凸优化问题，应使用拉格朗日乘子法，通过引入拉格朗日乘子来处理约束条件，并通过优化拉格朗日函数来最小化式（2-1），可得如下迭代公式：

$$u_{ij} = \frac{\|x_i - v_j\|^{-\frac{2}{m-1}}}{\sum_{l=1}^C \|x_i - v_l\|^{-\frac{2}{m-1}}} \quad (2-3)$$



$$v_j = \frac{\sum_{i=1}^N u_{ij}^m x_i}{\sum_{i=1}^N u_{ij}^m} \quad (2-4)$$

迭代过程中,通过式(2-3)和(2-4)对 $u_{ij}$ 和 $v_j$ 进行更新,最终得到每个像素的隶属度向量 $u_i = \{u_{i1}, \dots, u_{iC}\}$ 。依据最大化隶属度原则,遍历各个像素的所有隶属度向量 $u_i$ ,并与预设阈值比较,满足条件的最大值即为当前像素的隶属分类。

FCM 算法的优点在于其对分割判定的灵活性,相较于 K 均值聚类算法<sup>[25]</sup> (K-Means clustering algorithm, K-Means),它将分割的判定区间由 0 或 1 划分扩展为 0 到 1 之间的连续值范围,增强了分割结果的精细度,在图像分割领域被广泛采用。该算法虽然具有较好的分割性能,但仍然存在一些局限性:以合成图像二值分割为例,如图 2.3 (a) 所示,左侧显示了不含噪声的原始合成图像  $I$ ,右侧显示了图像  $I$  中标记处局部区域(以红点为中心的 8 邻域)的像素值。如图 2.3 (b) 所示,为向图像  $I$  中添加随机分布的高斯噪声后的图像以及对应局部区域的像素值,该区域的像素值发生了显著变化。在隶属度划分阈值为 0.5 (大于 0.5 则视为前景,小于 0.5 则视为背景)的条件下,对噪声图像应用于 FCM 聚类算法进行 30 次迭代计算,得到该图像中标记处局部区域的隶属度矩阵,如图 2.3 (c) 所示。根据设定的阈值,粗体部分像素被归类为背景,其余部分被归类为前景,但实际这 9 个像素应归属于同一分割区域。故 FCM 算法对噪声较为敏感,不利于处理被噪声污染的图像。此外,FCM 算法初始聚类中心的选取也会对分割结果产生影响。基于以上问题,本文在第三章中对 FCM 算法进行了研究。




图 2.3 FCM 隶属矩阵 ( $C=2$ , 迭代次数为 30): (a) 原始图像红点处灰度值; (b) 高斯噪声图像红点处灰度值; (c) 高斯噪声图像红点处 FCM 隶属矩阵

## 2.3 基于深度学习的目标检测算法概述

目标检测作为机器视觉领域的基本问题之一,构成了许多其它机器视觉任务

的基础。近年来,深度学习技术的快速发展<sup>[26]</sup>为目标检测带来了新鲜血液,各式各样的检测网络逐渐进入人们的视野中。其中,以 RCNN<sup>[27]</sup>、SPPNet<sup>[28]</sup>和 Faster RCNN<sup>[29]</sup>等为代表的两阶段目标检测器,以及以 YOLO<sup>[30]-[32]</sup>和 SSD<sup>[33]</sup>等为代表的单阶段目标检测器,是当前主流的两类目标检测框架,它们各有独特的优势。

### 2.3.1 目标检测器

两阶段目标检测算法即通过对图像进行两阶段的处理来实现图像的目标检测,最经典的即由 Girshick 等人<sup>[27]</sup>提出的一种基于区域的卷积神经网络算法(Region-based Convolutional Neural Network, RCNN): RCNN 目标检测器,是整个 RCNN 系列的开山之作。该方法首先通过选择性搜索<sup>[34]</sup>生成一组候选区域,然后使用卷积神经网络提取每个区域的特征,并通过支持向量机对其分类以确定是否包含目标。若检测到目标,则边界框回归模型用于精确定位。最终,采用非极大值抑制技术去除重叠的边界框,输出包括对象的检测结果、类标签以及坐标信息。该算法最大的缺点在于会产生大量重叠的提议,导致进行重复的特征计算,显著降低了检测效率。

针对 RCNN 所存在的问题,该系列的后续工作提出了改进方案,以达到提高检测速度的同时保持其检测精度的目的。其中一项改进是 Faster RCNN 算法,它通过用与检测网络共享卷积特征的区域提议网络(Region Proposal Network, RPN)代替选择性搜索来进一步提高速度。RPN 直接从特征图生成区域建议,无需外部建议生成方法,也不需要手动设置候选框的大小与位置,使得检测过程更加高效、准确。此外, Faster RCNN 可以很容易地与其它深度学习算法结合,从而在实际应用中取得更好的效果。RCNN 系列中的各种改进展示了通过不断创新来开发更快、更准确的目标检测算法的潜力。

不同于传统的两阶段目标检测,由 Joseph 提出的 YOLO (You Only Look Once),只需要一个单阶段网络就可以完成所有操作,实现了端到端的检测和分类,大大提高了检测速度。然而,由于 YOLO 采用单阶段检测器的方式,相较于传统的两阶段检测器,在小目标定位准确性上可能存在一些问题。近年来,为了提高 YOLO 的检测性能,在该模型上进行改进,如锚点框和多尺度预测。虽然在某些特定情况下, YOLO 可能不如其它检测器,但它仍然是深度学习中一个非常重要的目标检测模型,对于目标检测技术的发展做出了重要贡献。

### 2.3.2 目标检测在缺陷检测任务中的应用

缺陷检测是一项复合任务,要求准确地定位图像中的每个缺陷,并识别其实际类别。尽管现代计算机视觉技术已经取得了许多进展,但这项任务仍然具有挑战性。这主要由于缺陷检测涉及两个关键方面:位置定位和类别识别。在实践中,

这两个方面往往会相互影响，使得相关方法很难同时兼顾两者的准确性。一般来说，缺陷定位需要提供准确而精细的目标检测，以便能够在图像中准确地定位缺陷并确定其外部边界。同时，缺陷类别识别需要更高级别的特征提取和分类技术，以区分不同类型的缺陷。在实践中，大多数缺陷检测方法往往只能集中于其中一个方面，而无法实现两者的完美结合。为了解决这个问题，研究人员正在开发创新性的方法，包括利用深度学习网络，引入新的损失函数和模型结构等，以改善缺陷检测的准确性和检测效率。如图 2.4 所示，根据缺陷检测任务的具体流程，可以将整个任务划分为模型训练与模型部署两个阶段。具体来说可以分为：



图 2.4 缺陷检测任务流程

（1）从实际工业场景中采集缺陷图像，对缺陷边界框进行注释，即缺陷数据的收集、标注阶段；

（2）将采集到的数据集拆分为训练集与验证集，在训练集上利用缺陷检测模型（单阶段检测器或两阶段检测器）对其进行训练，并在验证集上验证模型以确保模型不会出现过度拟合的情况；

（3）将缺陷检测模型部署在工业环境的边缘计算设备上，采集实时场景图像数据作为模型的输入；

（4）将缺陷检测的结果进行输出，包括缺陷的精确位置以及缺陷的所属类别，为生产质量监测提供支持。

目前单独将目标检测网络直接应用在缺陷检测领域上可能达不到预期的结果，需要添加额外手段来适应具体任务。以数据增强为例，通过对现有数据集应用各种变换（旋转，翻转以及缩放等），有助于增加训练集的多样性，从而达到提高模型鲁棒性与泛化能力的目的。

## 2.4 半监督目标检测算法基本理论

半监督学习（Semi-Supervised Learning, SSL）主要利用少量标记数据与大量未标记数据共同参与学习，来减少深度学习对大量标记数据的依赖。目前，半监督学习在图像分类领域已取得了不错的进展，由于目标检测任务具有复杂的架构设计和多任务学习（分类与回归）的特点，因此将 SSL 方法迁移到目标检测任务并不是一项简单的工作。而目标检测任务的下游实际应用“缺陷检测”，是一种

分类和定位的复合任务，主要方法还是基于目标检测器。目标检测器的性能决定检测任务性能的好坏，因此需要在特定环节对任务进行适配才可以取得最佳的检测效果。本节将对半监督缺陷检测任务中常用的半监督目标检测算法进行介绍。

### （1）基于 STAC 的半监督目标检测方法

STAC<sup>[35]</sup>方法是一种基于教师学生框架的检测算法，其结构如图 2.5 所示。STAC 具有两个阶段，首先利用所有标记数据在教师网络上进行训练，然后用训练好的教师模型在无标签数据上生成目标对象的预测框和类别，再利用非极大值抑制（Non-Maximum Suppression, NMS）筛选出高置信度的伪标签，之后利用强数据增强对未标记数据进行数据强增强处理，主要包括图像的全局色彩变换、全局或框级别（box-level）的几何变换和遮挡，最后将强增强处理后的未标记数据集输入学生网络，将学生网络的输出与伪标签的无监督损失和标记数据的监督损失来指导检测器进行训练。

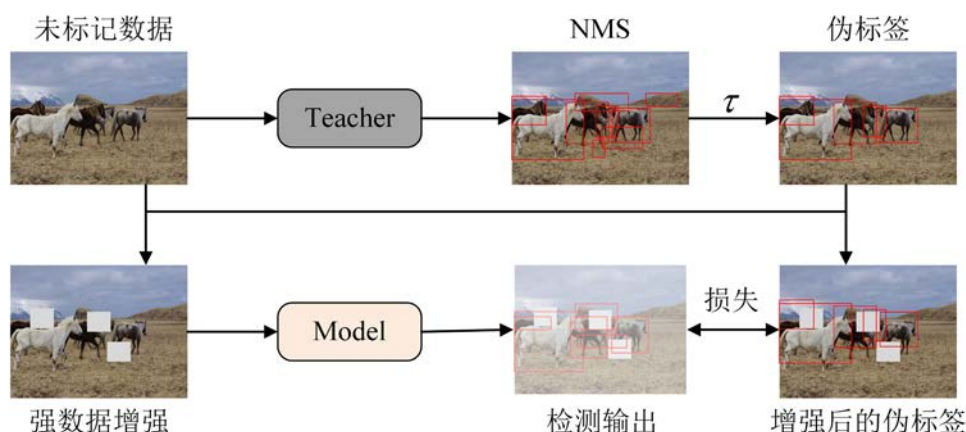


图 2.5 STAC 算法示意图

STAC 在 COCO 和 VOC 数据集上均取得了当时先进的结果，但是该方法离线生成伪标签，也就是只生成一次伪标签，且在后续训练过程中不会进行更新。这会导致当训练的模型精度逐步提升超过原始模型时，继续使用原始模型生成的伪标签会限制模型精度的提升。但是 STAC 为后续半监督检测领域提供了一个很好的研究思路，即基于伪标签的半监督检测方式。

### （2）基于 Unbiased Teacher 的半监督目标检测方法

Unbiased Teacher<sup>[36]</sup>主要解决了目标检测中由于类别不平衡，所导致半监督目标检测算法中伪标签存在的类别偏差问题。其具体结构如图 2.6 所示，检测网络包括 RPN 前景和背景的分类，ROIHead（Region of Interest Head）的多类别分类。整体分为预热阶段与师生互学阶段。预热阶段即用所有的标记数据训练模型，通过预热阶段所训练的模型权重，复制给教师和学生模型，然后利用 Mean Teacher



的结构，使用教师模型生成的伪标签作为后续学生模型的标签。而为了改善上述的不平衡问题，Unbiased Teacher 分离了学生模型和教师模型。具体地，在从教师模型那获得伪标签后，通过反向传播只更新学生模型的可学习权重，然后通过滑动指数平均(Exponential Moving Average, EMA)更新教师模型参数。

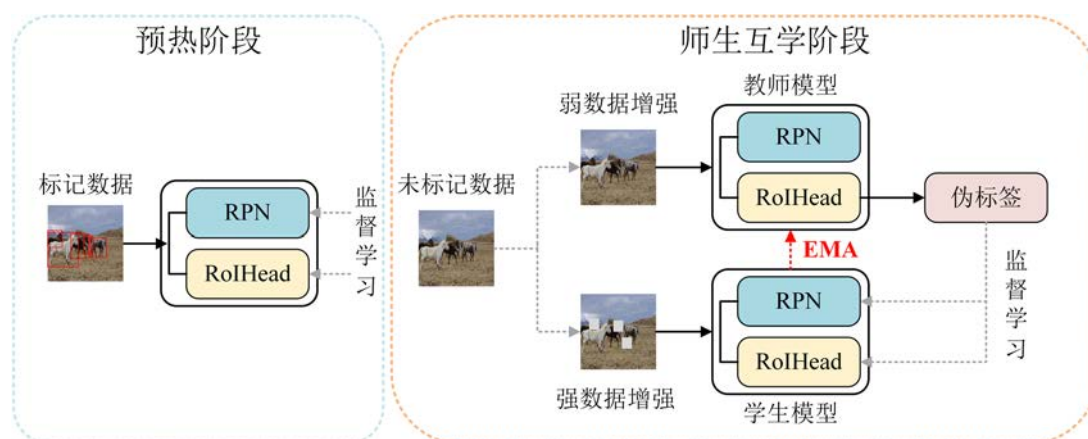


图 2.6 Unbiased Teacher 算法示意图

### （3）基于 Softteacher 的半监督目标检测方法

现有的半监督学习方法中，常采用多阶段训练方式：首先利用标记数据对初始检测器进行训练，然后该检测器被用于对大量未标记数据预测并生成伪标签，最后在预测的伪标签数据上再次训练模型。这样做的缺陷是初始检测器的准确性直接关系到伪标签的可靠性，同时这种固定的伪标签生成方式缺乏灵活性，不能适应训练过程中的动态变化，从而会限制检测器最终性能的提升。

Softteacher<sup>[37]</sup>是一种端到端的半监督目标检测框架，是上述问题的一种有效解决方法，其具体结构如图 2.7 所示。与常见的半监督学习方法不同，Softteacher 会在训练的每次迭代中，给未标记的数据生成伪标签，并将这些伪标签数据和少量的标记数据同时训练模型。

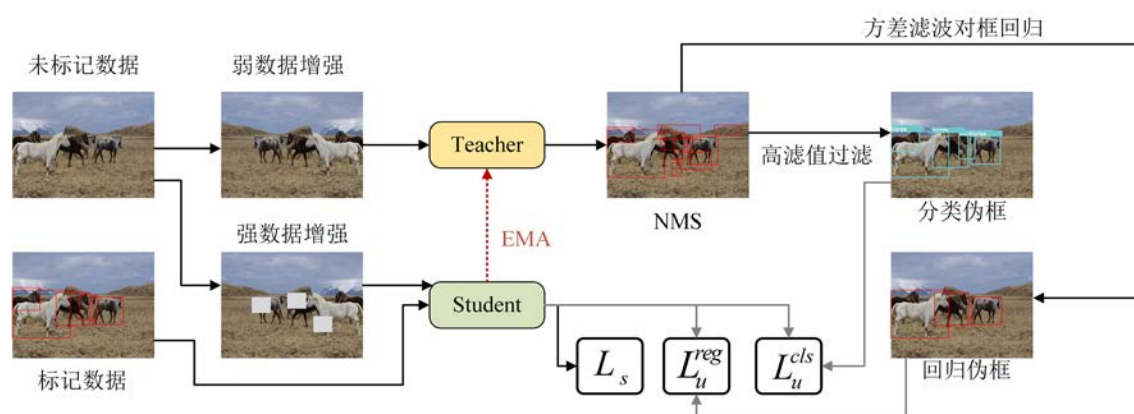


图 2.7 Softteacher 算法示意图

## 2.5 本章小结

本章主要介绍了相关理论概述，包括 PCB 缺陷和本文所检测的目标缺陷、基于传统图像处理的图像分割技术、基于深度学习的目标检测算法以及半监督学习算法的基本理论。重点介绍了图像分割算法中的模糊聚类分割算法，然后介绍了目标检测算法中常用的两阶段与单阶段目标检测器，最后阐述了针对目标检测领域的先进半监督算法。在接下来的研究中，本文将分别从传统图像处理与深度学习角度介绍所提出的两套 PCB 缺陷检测算法，并通过详细的实验证明本文所提方法的有效性。

## 第3章 基于两阶段分割与规则校验的 PCB 裸板缺陷检测算法

目前主流的基于传统图像处理的 PCB 缺陷检测多为参考法，优点在于直观，实现简单，但参考法中标准图像缺乏固定标准，要求待检测图像和参考图像的严格对齐，且光照等因素也会影响后续差分的结果，漏检与误检率高。而非参考法无需参考图像，只需单张图像进行检测，但对复杂线路 PCB 图像检测精度不高，其主要原因在于复杂线路 PCB 图像前景区域（线路区域）难以提取。故本章针对参考法需要多张图像进行检测以及上述非参考法的缺点，结合 PCB 裸板的制造工艺和成像特点，提出一种只需单张图像进行检测的方法。

### 3.1 基于两阶段分割与规则校验的 PCB 裸板缺陷检测算法总体设计

本章所提方法中，主要检测对象为 PCB 裸板图像的前景线路区域（即图像中待检测对象的某些物理属性，例如轮廓，纹理信息等图像中形成的闭合区域，除此之外的部分则被定义为背景区域），包含了 PCB 裸板上的线路和导孔等特征，检测目标为 PCB 裸板图像中的短路、开路、凸起以及导孔完整性缺陷。短路和开路缺陷主要是指 PCB 裸板在布线过程中出现的多余或缺失线路段的线路连接错误；凸起缺陷则主要是指 PCB 裸板中布线不规则所导致的线路间距异常；导孔完整性是指根据 PCB 裸板的设计规则，相同类型的 PCB 裸板上导孔数量应保持不变，因此同类 PCB 裸板上导孔数量的增加或减少均表示存在导孔完整性缺陷。对于这四类缺陷，都需要精确分割出 PCB 裸板图像的线路区域，并确保前景区域的特征完整性，以便进行后续缺陷的分析与判断。这一步骤的准确性将直接决定后续缺陷检测的效果和准确率。因此，如何利用图像分割算法对 PCB 裸板图像的前景区域进行精确分割对后续识别工作来说至关重要。

然而，PCB 裸板的制造工艺决定了其具有与一般物体不同的特殊光学特性。典型的 PCB 裸板图像通常呈现较深的颜色，这主要受 PCB 表面材料以及其反射特性的影响，导致图像的对比度较低，图像中前景与背景灰度值接近，给分割工作带来困难，需要采用合适的算法以确保准确分割出所需要的前景区域。

为此，本章提出一种基于两阶段分割的检测方法，利用局部信息增强和基于直方图自动初始化聚类中心的 FCM 算法，对 PCB 裸板图像进行初步处理，以获取目标区域的粗略分割结果。为进一步提高检测的准确性，我们在初步结果的基础上，采用了基于先验信息的快速水平集分割方法，以获取 PCB 裸板图像中更精

确的目标形状信息。在实现 PCB 裸板图像的前背景分割后，结合 PCB 设计规则和导孔的区域组合特征，考虑到短路、开路等缺陷与设计规则的差异，运用连通域分析结合基于面积的规则，对 PCB 裸板图像上的短路、开路、凸起和导孔完整性缺陷进行检测。图 3.1 显示了本章方法实现 PCB 裸板缺陷检测的整体结构框架，包括图像分割与图像检测两部分。

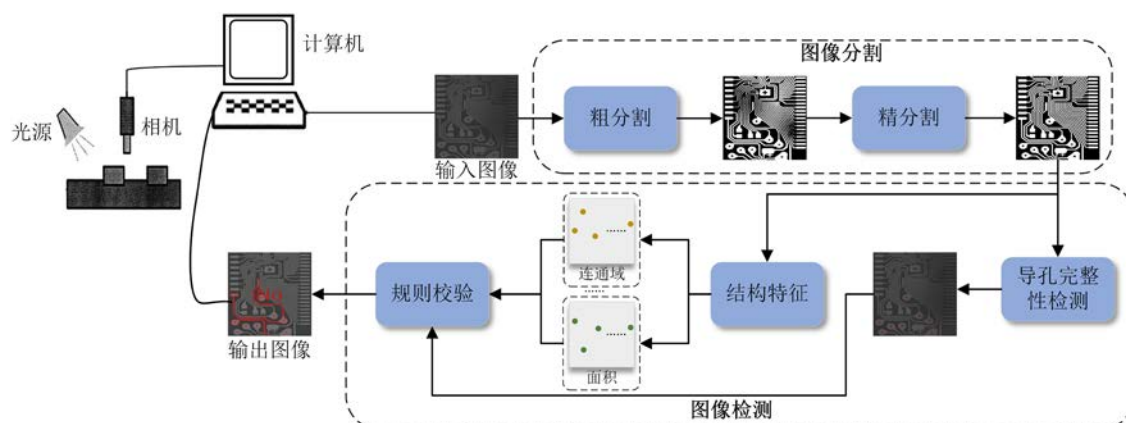


图 3.1 缺陷检测整体结构框架示意图

## 3.2 基于改进 FCM 的 PCB 裸板图像的粗分割

本节主要讨论两阶段分割中的粗分割算法。（本章所提的图像分割均指图像二值分割，图像二值分割的目标即将图像中的像素准确地分为黑色和白色。）针对 PCB 裸板图像成像特点以及 FCM 算法的不足，本节提出了一种新的 FCM 算法，该算法在基于直方图自动生成初始聚类中心的基础上，引入空间上下文信息进行局部信息增强。具体地，首先通过直方图计算与分析获取初始聚类中心，其次通过对图像在直方图空间内进行迭代聚类，生成模糊隶属度矩阵，然后利用局部空间信息和灰度信息相结合的调控因子对隶属度划分矩阵进行调整，在平衡抗噪性与保持细节信息的同时也加快了图像分割的速度。此外，根据提出的聚类中心选取方法，自动选取初始聚类中心，避免了随机生成初始聚类中心对分割结果产生的影响，提高了分割的鲁棒性。实验结果表明该方法不仅具有抗噪性，而且可以较好地保留图像的纹理细节信息。

### 3.2.1 目标函数定义

Krinidis<sup>[38]</sup>等人在 FCM 算法的目标函数中通过模糊因子  $G_{ij}$  引入局部空间信息，使得算法对噪声不敏感，且在图像分割方面表现出更好的性能，其目标函数如下：



$$J_m = \sum_{i=1}^N \sum_{j=1}^C u_{ij}^m \|x_i - v_j\|^2 + \sum_{i=1}^N \sum_{j=1}^C G_{ij} \quad (3-1)$$

上式中,  $N$  是图像中的总像素数,  $C$  是聚类的数量,  $u_{ij}$  表示第  $i$  个像素相对于第  $j$  个聚类中心的模糊隶属度,  $m$  表示模糊隶属度指数, 通常取  $m=2$ ,  $x_i$  表示第  $i$  个像素的灰度值,  $v_j$  表示第  $j$  个聚类中心,  $\|x_i - v_j\|^2$  表示像素  $x_i$  和聚类中心  $v_j$  的欧氏距离,  $G_{ij}$  为模糊因子, 用于控制邻域像素对中心像素的影响, 其定义为:

$$G_{ij} = \sum_{\substack{r \in N_i \\ i \neq r}} \frac{1}{d_{ir} + 1} (1 - u_{rj})^2 \|x_r - v_j\|^2 \quad (3-2)$$

上式中,  $N_i$  表示当前像素  $x_i$  所在的邻域集合,  $d_{ir}$  表示像素  $x_i$  与邻域像素  $x_r$  之间的欧氏距离,  $u_{rj}$  表示  $u_{ij}$  的邻域内像素,  $x_r$  表示当前像素  $x_i$  的邻域内像素,  $v_j$  表示第  $j$  个聚类中心,  $\|x_r - v_j\|^2$  表示像素  $x_r$  和聚类中心  $v_j$  的欧氏距离, 根据拉格朗日乘子法最小化式 (3-1) 所得参数  $u_{ij}$  和  $v_j$  的迭代表达式为:

$$u_{ij} = \frac{\left( \|x_i - v_j\|^2 + G_{ij} \right)^{\frac{-1}{m-1}}}{\sum_{l=1}^C \left( \|x_i - v_l\|^2 + G_{il} \right)^{\frac{-1}{m-1}}} \quad (3-3)$$

$$v_j = \frac{\sum_{i=1}^N u_{ij}^m x_i}{\sum_{i=1}^N u_{ij}^m} \quad (3-4)$$

$G_{ij}$  的引入旨在充分利用像素间信息, 但根据式 (3-2) 可知, 在迭代更新过程中,  $G_{ij}$  需要大量重复计算邻域内所有像素与聚类中心之间的距离, 大大提高了计算复杂度, 不利于算法的实时性。为此, Lei<sup>[39]</sup>等人证明了邻域内隶属矩阵  $u_{rj}$  与中心像素隶属矩阵  $u_{ij}$  之间存在线性关系, 通过引入隶属度滤波可以等效实现模糊因子  $G_{ij}$  的效果, 从而不需要在每次迭代中都重复计算邻域内像素与聚类中心的距

离，减少计算复杂度。另外，众所周知，数据的分布特征可用直方图来描述。在图像处理中，像素的分布特征可以通过直方图较好展示，而且直方图有助于降低计算复杂度。因此，本文所提方法在灰度直方图的基础上，结合模糊聚类理论进行模型构建，所定义的目标函数为：

$$J_m = \sum_{i=1}^M \sum_{j=1}^2 \gamma_i u_{ij}^m \|\delta_i - v_j\|^p \quad (3-5)$$

其中， $M$  是直方图的像素级数量（ $M < N$ ）， $u_{ij}$  表示第  $i$  个像素相对于第  $j$  个聚类中心的模糊隶属度， $m$  表示模糊系数，本文取  $m=2$ ， $v_j$  表示第  $j$  个聚类中心， $\|\delta_i - v_j\|^p$  为灰度级  $\delta_i$  与聚类中心  $v_j$  的闵氏距离，相较于欧氏距离反映空间各点的绝对间距，闵氏距离根据图像三通道数据分布的特点去计算距离，用于此更恰当，故本文取  $p=3$ 。 $\delta_i$  是第  $i$  个灰度级对应的灰度值， $\gamma_i$  是灰度级  $i$  对应的像素数量（ $1 \leq i \leq M$ ），其灰度图像直方图  $h$  的定义为：

$$h(\delta_i) = \gamma_i \quad (3-6)$$

$$\sum_{i=1}^M \gamma_i = N \quad (3-7)$$

上式中  $N$  即图像中的总像素数。

最终，根据拉格朗日乘子法最小化式（3-5），得到参数  $u_{ij}$  和  $v_j$  的迭代表达式为：

$$u_{ij} = \frac{\|\delta_i - v_j\|^{-\frac{2}{m-1}}}{\sum_{l=1}^2 \|\delta_i - v_l\|^{-\frac{2}{m-1}}} \quad (3-8)$$

$$v_j = \frac{\sum_{i=1}^N \gamma_i u_{ij}^m \delta_i}{\sum_{i=1}^N \gamma_i u_{ij}^m} \quad (3-9)$$

### 3.2.2 调控因子定义

通过引入隶属度滤波<sup>[39]</sup>替代引入局部空间信息的模糊因子，虽然不需要重复计算邻域内像素与聚类中心之间的距离，降低了计算复杂度，但是采用中值滤波器用于进一步修正隶属度划分矩阵<sup>[39]</sup>，仅对脉冲噪声干扰下的效果会比较好，容易丢失图像细节信息且具有局限性。对于在实际工业生产中采集到的 PCB 裸板图像，其前景线路区域通常包含较多的噪声干扰，这些噪声也并非仅由脉冲噪声引起。针对这一现象，本文所提方法旨在保证抗噪性的同时，最大限度地保留图像的细节信息，常用的中值滤波并不能满足实际要求。因此，本文设计并引入了一个新的调控因子来调整最终的隶属度划分矩阵。

$$Z = \exp\left(-\frac{\|\varepsilon_i - \varepsilon_r\|^2}{2\sigma_c^2} - \frac{\|X_i - X_r\|^2}{2\sigma_s^2}\right) \quad (3-10)$$

上式中， $\varepsilon_i$  和  $\varepsilon_r$  分别代表中心像素和其邻域像素的灰度值， $X_i$  和  $X_r$  表示它们对应的像素坐标。 $\sigma_c$  和  $\sigma_s$  是一个可调整的控制参数， $\|\cdot\|^2$  表示设定的距离度量。此外，上式可拆分为下面两式之和：

$$Z_c = \exp\left(-\frac{\|\varepsilon_i - \varepsilon_r\|^2}{2\sigma_c^2}\right) \quad (3-11)$$

$$Z_s = \exp\left(-\frac{\|X_i - X_r\|^2}{2\sigma_s^2}\right) \quad (3-12)$$

其中， $Z_s$  与  $X_i$ 、 $X_r$  两者之间的欧氏距离成反比，二者距离越远则  $Z_s$  越小， $Z_c$  则用于衡量像素点  $\varepsilon_i$  与  $\varepsilon_r$  之间的相似度。引入的调控因子通过式 (3-13)，调整通过迭代式 (3-8)、(3-9) 得到的最终隶属度划分矩阵  $U = [u_{ij}]^{2 \times M}$ 。

$$U' = U * Z \quad (3-13)$$

具体而言，其意义为：对于具体的图像，当其中某一区域的像素值变化比较平滑时，表明该区域相邻像素之间的差异较小， $Z_c$  接近于 1， $Z_s$  起主导作用，实质上等同于利用高斯滤波器以当前像素为中心进行平滑处理；当区域中像素值变化明显时（例如边缘等），由于像素值差异大， $Z_c$  接近于 0，此时对应像素保持原

状，从而达到保留原始图像梯度信息的效果。图 3.2 展示了调控因子  $Z$  对隶属度划分矩阵的影响：在图 2.3 (b) 中，中心像素由于高斯噪声原因所导致的误分类，通过调控因子  $Z$  调整后，图 2.3 (c) 中误分类的中心像素对应的隶属度已被修正。

83	95	83	0.695	0.613	0.729	0.565	0.523	0.583
81	55	109	0.713	<b>0.475</b>	0.561	0.545	<b>0.555</b>	0.571
96	99	82	0.513	0.557	0.631	0.573	0.561	0.570

(a)
(b)
(c)

图 3.2 调控因子  $Z$  作用于隶属度矩阵：(a) 噪声图像标记点处像素灰度值；(b) 噪声图像标记点处所对应的 FCM 隶属度矩阵；(c) 本文处理后的隶属度矩阵

### 3.2.3 初始聚类中心自动选取

在使用 FCM 这类聚类算法时，首先需要确定初始的聚类中心，常采用随机初始化聚类中心的方法<sup>[40][41]</sup>，但实验中发现，初始聚类中心的选取方式会对聚类结果产生较大影响。随机初始化的聚类中心，会导致算法陷入局部最优解，从而导致该聚类产生不稳定的结果。特别是针对不同类别具有高相似度的图像时，对同一张图片应用相同的分割算法，可能产生显著不同的结果。除此之外，若采用初始聚类中心随机初始化策略，直方图中占比较小的类别难以被有效检测。

鉴于随机初始化聚类中心所导致的不稳定结果，本文提出一种基于直方图的自动初始化聚类中心策略。首先计算图像的直方图，其次为了降低噪声的干扰，对直方图进行平滑处理，然后，在平滑后的直方图中识别出所有显著的波峰区域，并将其中心作为潜在的聚类中心，最后根据预设的聚类中心数量，对这些潜在的聚类中心进行增加或合并操作，以确定最终的初始聚类中心。具体实施步骤如下：

(1) 对直方图进行平滑处理。在计算图像的直方图后，为消除直方图中的毛刺和噪声，选取宽度为 5 的均值滤波器对直方图数据进行平滑处理。若直方图中灰度值为  $l$  的像素数量为  $n(l)$ ，则可由式 (3-14) 计算平滑处理后直方图在灰度值为  $l$  处的数量：

$$\eta_l = \frac{n(l-2) + n(l-1) + n(l) + n(l+1) + n(l+2)}{5} \quad (3-14)$$

(2) 确定直方图的波峰区域。在本文中，波峰被定义为包括上坡段和下坡

段的连续变化区域。为判定波峰区域，本文直接通过直方图的连续增长和下降来判定上坡段还是下坡段：规定当连续发生 8 次增长时，判定为上坡段，并将其增长起始位置指定为波峰区域的起始位置；反之，当有连续下坡超过 8 次时，则判定为下坡段，并以下坡终止点作为波峰区域的结束位置。（直方图开始时，若只检测到了下坡段，则认定其为波峰区域，起始位置为直方图的起始位置，终止位置为下坡段的终止位置。同理，在直方图结束时，只有上坡段，则认定其为波峰区域，起始位置为上坡段的起始位置，终止位置为直方图的终点）

（3）以每个波峰区域的中心作为预选的聚类中心。根据步骤（1），则第  $n$  个初始聚类中心  $v_n$  的可由式（3-15）进行计算：

$$v_n = \frac{\sum_{l \in \text{area}_n} l \eta(l)}{\sum_{l \in \text{area}_n} \eta(l)} \quad (3-15)$$

上式中， $\eta(l)$  表示灰度值  $l$  的像素值数量， $\text{area}_n$  表示第  $n$  个波峰区域。

（4）确定初始聚类中心。在选取初始聚类中心时，遵循一个原则：确保不同聚类中心之间的差异性最大化，同时保证同类像素之间的相似性最大化。基于此，对初始聚类中心进行修正与调整，通过比较预设聚类中心数  $p$  与搜索所得波峰区域数  $q$ ，得到最终初始聚类中心。若  $q = p$ ，则所得波峰区域即初始聚类中心；若  $q > p$ ，则逐一合并最近的预选聚类中心，直到  $q = p$ ；若  $q < p$ ，则在直方图中距离已确定的预选聚类中心最远处，逐一添加聚类中心，直到  $q = p$ 。

### 3.3 基于先验信息的快速水平集 PCB 裸板图像的精分割

实际工业生产中，采集到的 PCB 裸板图像，成像质量差，经上述改进 FCM 算法分割所得结果依旧会存在一定毛刺，影响后续的缺陷判定。而郭贝贝等人<sup>[42]</sup>在利用阈值处理与区域生长法结合的方法对肝脏 CT 图像进行分割的基础上，使用水平集分割方法对其进行二次分割，取得了更准确的分割效果；王振华等人<sup>[43]</sup>在利用 K 均值算法实现海岛边界的粗分割后，使用水平集方法对图像进行二次分割，提升了分割图像的质量。基于此，为进一步优化分割结果，减少 PCB 裸板图像线路区域中的毛刺，本节采用水平集方法对分割结果进行精分割（二次分割）处理，利用粗分割结果作为 PCB 裸板图像前景区域的初始轮廓区域，克服水平集算法对初始轮廓区域敏感的问题，以进一步实现 PCB 裸板图像的保边分割。

水平集算法通常对图像的区域有如下定义：

$$\phi_0(x, y) = \begin{cases} -\rho & (x, y) \in \Omega_0 - \partial\Omega_0 \\ 0 & (x, y) \in \partial\Omega_0 \\ \rho & (x, y) \in \Omega - \Omega_0 \end{cases} \quad (3-16)$$

上式中,  $\rho$  是常量, 通常取  $\rho=1$ ,  $\Omega$  为图像整体区域,  $\Omega_0$  为含边缘的水平集内部区域,  $\partial\Omega_0$  为水平集的轮廓。

经典的 C-V (Chan-Vese) 模型由 Chan<sup>[44]</sup>等改进 Mumford-Shah<sup>[45]</sup>模型 (M-S) 而来, 利用水平集方法解决了 M-S 模型最小化能量泛函的难题。该模型的水平集的演化方程式如下:

$$\frac{\partial\Phi}{\partial t} = \delta_\varepsilon(\Phi) \left[ \mu \operatorname{div} \left( \frac{\nabla\Phi}{|\nabla\Phi|} \right) - v - \lambda_1 (I(x, y) - C_0)^2 + \lambda_2 (I(x, y) - C_B)^2 \right] \quad (3-17)$$

上式中,  $\delta_\varepsilon(\Phi)$  为近似 Dirac 函数<sup>[46]</sup>,  $\operatorname{div} \left( \frac{\nabla\Phi}{|\nabla\Phi|} \right)$  为曲线的曲率,  $\mu$ 、 $v$ 、 $\lambda_1$ 、 $\lambda_2$  为加权系数,  $C_0$  和  $C_B$  是轮廓内、外的平均灰度值,  $I(x, y)$  为图像内的像素点。

上述 C-V 模型在水平集演化过程中,  $\delta_\varepsilon(\Phi) \operatorname{div} \left( \frac{\nabla\Phi}{|\nabla\Phi|} \right)$  项作为保持演化水平集轮廓线的平滑与规则的正则项,  $v\delta_\varepsilon(\Phi)$  项作为去除演化过程中一些虚假对象的面积正则项。这两个正则项通常在实际应用中会导致计算复杂度高, 不利于 PCB 缺陷的实时检测, 在此基础上本节提出一种快速水平集算法, 提高分割效率。

事实上, 水平集轮廓的长度与其自身形成的面积类似<sup>[44]</sup>。因此, 本节方法仅保留保持演化水平集轮廓平滑与规则的正则化项, 不管去除演化过程中虚假对象的面积正则项。而为了提高检测的实时性, 即水平集算法的计算效率, 本节用高斯核代替上述正则化项, 可以平滑演化的水平集轮廓, 故本节所提水平集的演化方程为:

$$\frac{\partial\Phi}{\partial t} = \delta_\varepsilon(\Phi) \left[ -\lambda_1 (I(x, y) - C_0)^2 + \lambda_2 (I(x, y) - C_B)^2 \right] \quad (3-18)$$

上式中,  $C_0$  和  $C_B$  是轮廓内、外的平均灰度值,  $\lambda_1$ 、 $\lambda_2$  为加权系数, 为了较少的参数调整, 我们类似于文献<sup>[44][47]</sup>, 取  $\lambda_1 = \lambda_2 = 1$ 。因此, 上式可被写为:

$$\frac{\partial \Phi}{\partial t} = \delta_{\varepsilon}(\Phi) [(C_0 - C_B)(2I(x, y) - C_0 - C_B)] \quad (3-19)$$

为了获得更稳定的结果，将上式中  $(C_0 - C_B)(2I(x, y) - C_0 - C_B)$  进行归一化<sup>[48]</sup>，则上式进一步写为：

$$\frac{\partial \Phi}{\partial t} = \delta_{\varepsilon}(\Phi) \left[ \frac{(C_0 - C_B)(2I(x, y) - C_0 - C_B)}{\max(|(C_0 - C_B)(2I(x, y) - C_0 - C_B)|)} \right] \quad (3-20)$$

其具体实现过程如下：

(1) 初始化水平集函数如式 (3-16)，确定初始水平集轮廓内外的符号；

(2) 水平集演化：根据近似 Dirac 函数  $\delta_{\varepsilon}(\Phi)$  与上述式 (3-20) 中的  $\frac{(C_0 - C_B)(2I(x, y) - C_0 - C_B)}{\max(|(C_0 - C_B)(2I(x, y) - C_0 - C_B)|)}$ ，以  $\Phi_{i,j}^{n+1} = \Phi_{i,j}^n + \Delta t R(\Phi_{i,j}^n)$  这一差分格式更新水平集函数<sup>[44]</sup>（其中， $(i, j)$  表示空间位置， $n$  是迭代次数， $\Delta t$  指时间步长， $R(*)$  表示根据式 (3-20) 所计算出来的水平集轮廓内部区域）；

(3) 重复步骤 (1)，再次初始化已更新的水平集函数；

(4) 使用高斯核正则化更新水平集函数  $\Phi = G_{\sigma} * \Phi$ （其中， $G_{\sigma}$  表示标准偏差为  $\sigma$  的高斯核）；

(5) 若没有收敛，则重复步骤 (2)，直至收敛。

如图 3.3 所示，为截取的部分 PCB 裸板图像，将其进行分割处理的结果。其中，图 3.3 (a) 为 PCB 原始图像及其真值图，图 3.3 (b) 为采用原始 C-V 算法分割的结果，图 3.3 (c) 为采用本节算法的分割结果。




图 3.3 PCB 图像分割结果：(a) 原始图像与真值图；(b) C-V 算法分割结果图；(c) 本节算法分割结果图

可以看出图 3.3 (b) 分割结果, 在左侧较为密集的线路部分明显存在较多毛刺, 而本节算法由于引入先验信息与高斯核平滑, 更具有抗噪性, 对线路区域的分割更精准。此外, 由于本文水平集算法采用高斯核替代正则化项, 以图 3.3 为例, 统计分割过程所用时间, 图 3.3 (c) 处理时间仅需 0.1s, 而图 3.3 (b) 处理时间需要 13s, 即验证本节算法的快速性。

### 3.4 PCB 裸板图像线路区域检测与识别

通过上一节介绍的方法, PCB 裸板图像已经实现了线路区域的提取, 接下来对所提取的线路区域进行分析, 针对 PCB 裸板图像短路、开路以及凸起这三类线路缺陷本身的特点, 设定相应的规则以完成对缺陷的识别。本节所提出无参考的规则校验法, 对于 PCB 裸板图像中的线路缺陷, 通过其线路布线的设计规则标准, 对线路是否存在缺陷进行判别。如图 3.4 所示为存在线路缺陷的 PCB 裸板实例图。




图 3.4 PCB 裸板线路缺陷样本

#### 3.4.1 PCB 裸板线路缺陷检测方案概述

本文针对 PCB 电路板上的线路层, 检测短路、开路以及凸起这三类缺陷。PCB 图像中线路之间相互独立, 通过图像分割处理后, 线路缺陷均存在于 PCB 裸板图像的前景区域, 即 PCB 裸板图像中的线路区域。如图 3.5 显示了短路、开路以及凸起这三类缺陷的简化版示意图, 其中包括两类信息: 基板区与线路区, 分别在二值图上表现为白色与黑色。(假设在二值图像中, PCB 裸板图像基板背景为白色, 像素值为 255; 线路区域为黑色, 像素值为 0)。




图 3.5 缺陷示意图: (a) 短路; (b) 开路; (c) 凸起



要根据图像上特征的不同对线路区域中各种不同缺陷进行识别，明显地，图中连通域和面积（面积即区域的像素个数）是基板区（背景区域）与线路区（前景区域）中变化最明显的两个特征。通过比对图 3.5 中的各个缺陷图像，得到连通域和面积的变化规律如表 3.1 所示。

表 3.1 PCB 裸板缺陷分类表

缺陷类型	连通域变化	面积变化	材料不足	材料多余
短路	减少	增加	否	是
开路	增加	减少	是	否
凸起	不变	增加	否	是

从表 3.1 可知，三类缺陷所对应的连通域以及面积特征的变化均不相同，则结合这两个特征可以对线路区域不同缺陷进行判别。具体地，首先通过连通域分析，对图像中的连通域进行标记对比，然后再通过各个连通域的面积进一步判定线路中的缺陷类型。如图 3.6 所示为正常 PCB 裸板和存在线路缺陷的 PCB 裸板所对应的连通域-面积序列图。尽管连通域数目不变，但通过比对各个连通域所对应的面积，可以明显看出短路与开路处连通域所存在的面积异常。

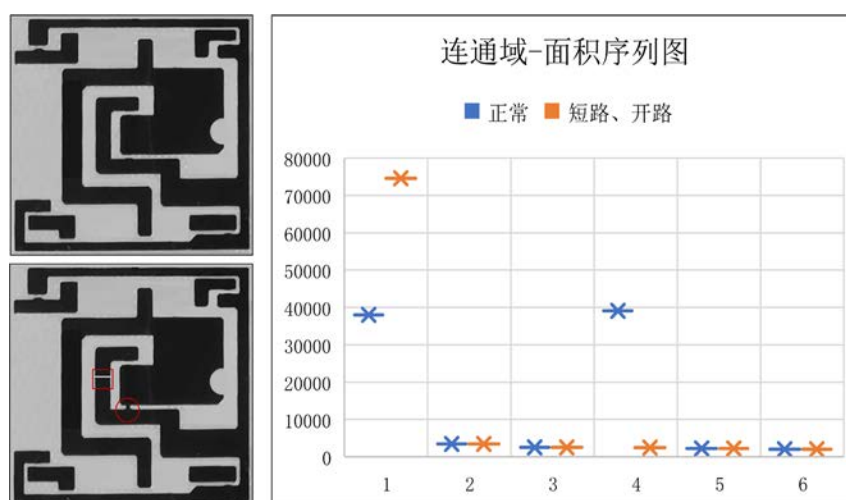


图 3.6 PCB 裸板连通域-面积序列统计图

### 3.4.2 连通域分析

由于涉及到连通域的变化，因此在缺陷判定之前，需要对连通域进行分析与标记，才能进行后续的连通域统计。故我们此节主要对 PCB 裸板图像的前景区域进行连通域分析，对不同区域的像素进行特征标记。所谓像素的特征标记即连通

域标记，需要将二值图中前景区域的像素进行标记（经二值分割后，前景区域通常为白色像素区域），属于同一个连通域的白色像素赋予统一的标记，属于不同连通域的白色像素则分别赋予不同的标记，以提取出图像中各个独立的连通域。

常用的连通域标记法主要为基于种子填充（Seed-Filling）的标记算法和基于两遍扫描（Two-Pass）的标记算法。基于 Seed-Filling 的标记算法只需对目标图像遍历一次，而基于 Two-Pass 的标记算法需要对目标图像进行两次遍历。相比之下，前者运行时间比后者少。对于缺陷检测这类工业任务而言，尽可能要求做到实时检测，故本文采用只需遍历一次的 Seed-Filling 方法，具体地，采用此类方法中的基于 8 邻域的行程编码算法对 PCB 裸板图像进行连通域分析。该算法不仅处理速度快，而且内存占用小，如图 3.7 所示，其计算过程如下：




图 3.7 连通域分析示意图：(a) 8 邻域示意图；(b) 行程编码原理

(1) 对第  $i$  行和第  $i+1$  行像素的前景区块进行独立统计，记录各个区块左右端点处对应的坐标，并对此依次进行标记；

(2) 对上述坐标进行比较，如果未发生重叠则保持标记不变；如果发生单次重叠则将第  $i+1$  行中的区块标记更换为第  $i$  行中的标记；如果发生多次重叠则将标记更新为当前重叠区域标记的最小值；

(3) 删除第  $i$  行标记，并对第  $i+1$  行和第  $i+2$  行进行 (1)、(2) 步骤中的操作；

(4) 重复步骤 (3)，直到遍历完所有行。

在对 PCB 裸板图像进行图像分割处理后，图像中背景像素的值被统一设定为 0，前景区域则按上述步骤进行连通域的分析与标记，即对前景区域分别用连通域编号进行标记（从 1 到  $n$ ， $n$  为连通域数量）。如图 3.8 所示为 PCB 裸板图像进行连通域分析的结果。




图 3.8 连通域标记结果

### 3.4.3 短路缺陷识别

PCB 裸板出现短路时，典型的线路层出现的短路情况如图 3.9 所示。由于短路缺陷会导致图像中对应连通域计数减少，以及面积计数增加，故本文结合这两个特征来对其进行检测。其中，通过连通域分析可以得到图像中线路区域的连通域数量，若存在短路，连通域计数减少。对于面积的计算，本文则采用基于区域生长的思想。




图 3.9 短路原理

具体地，图 3.9 呈现了短路原理图。假设图像线路区总面积为  $area$ ， $a$  为左边导线面积， $b$  为右边导线面积， $c$  为短路处面积，则有：

$$area = a + b \quad (3-21)$$

而通过计算，发生短路时，计算出来的实际面积大小为  $area'$ ：

$$area' = a + b + c \quad (3-22)$$

$$area' > area \quad (3-23)$$

而当待测 PCB 裸板图像面积增加时，存在两种情况：短路与凸起。因此，在此基础上，结合连通域分析的结果，若连通域计数发生变化，则可以判断 PCB 裸板出现了短路。

需要说明的是，在求图像面积时，实际上计算的是图像中前景区域像素的个数。而本文图像分割后所得结果图为二值图，即背景像素值设为 0 前景像素值设为 255，故计算图像面积即计算图像中像素值为 255 的像素点数。具体实现方法采用了基于区域生长算法的核心思想，首先定义一个计数器，其初始值设为 0，再根据连通域分析所得到的连通域数量，以各个连通域中的任何一个像素点作为种子点，开始区域生长，在生长过程中有像素值为 255 的像素点则计数器加 1，从而得到最终的面积数量。具体步骤如下：

- (1) 定义一个计数器 *cout*，并将其初始值设为 0；
- (2) 遍历整幅图像（图像前景区域中的各个连通域），寻找各个连通域中像素值为 255 的点，找到后，以该点作为种子点进行区域生长；
- (3) 遍历种子点周围 8 邻域内的所有像素点，合并满足属于目标点的像素，当有一个点被合并时，计数器就加 1；
- (4) 遍历该连通域中的全部邻接点，并把满足条件的邻接点并入目标区域；
- (5) 重复步骤（3）和（4），直到没有邻接点满足条件为止，该连通域生长结束。
- (6) 从没有处理过的目标连通域重新选择新的种子点，再次通过区域生长计算面积，直至计算出目标区域的全部面积；
- (7) 将上述步骤中每个生长过程得到的计数器中的值相加，所得结果即为目标区域的面积，也即目标区域中像素值为 255 的个数。

#### 3.4.4 开路缺陷识别

开路的识别方式和短路一样，只是与短路相比，发生开路时，图像线路区域面积增加。如图 3.10 所示，是典型的开路原理图。假设图像线路区总面积为 *area*，*a* 为左边导线面积，*b* 为右边导线中间开路处的面积，则有：

$$area = a \quad (3-24)$$

而通过计算，发生开路时，计算出来的实际面积大小为 *area'*：

$$area' = a - b \quad (3-25)$$

$$area' < area \quad (3-26)$$

由此，结合连通域计数的变化，可以判断 PCB 裸板出现了开路。计算面积的方法与短路相同，这里不再赘述。




图 3.10 开路原理

### 3.4.5 凸起缺陷识别

凸起缺陷通常是由于在 PCB 制造过程中，对基材上所覆铜箔进行蚀刻处理时，某处材料的不均匀或加工工艺问题所引起的。凸起会造成导线与导线之间、导线与焊盘之间或者其它导体之间的距离变窄。如图 3.11 所示为典型的凸起原理图。




图 3.11 凸起原理

其面积计算方式与短路类似，假设图像线路区总面积为  $area$ ， $a$  为左侧导线面积， $b$  为右侧突起处的面积，则：

$$area = a \quad (3-27)$$

而通过计算，产生凸起缺陷时，计算出来的实际面积大小为  $area'$ ：

$$area' = a + b \quad (3-28)$$

$$area' > area \quad (3-29)$$

由此，可以判断 PCB 裸板出现了凸起。但如 3.4.3 节所述，当面积增加时，存在两种情况，需要结合连通域的变化进一步判断，这里不再赘述。

### 3.5 PCB 裸板导孔完整性缺陷识别

PCB 裸板上导孔数目的完整性是判断其合格性的检测要求之一。如果能准确检测 PCB 线路层连通域内部的导孔特征，则可以识别 PCB 有无堵孔（缺孔）缺陷。一般求解连通域内部导孔是否存在的一个方法是首先对原始图像进行边缘检测，然后通过霍夫圆检测，得到导孔信息。但由于 PCB 图像干扰多，霍夫圆检测容易误检且计算量大。因此，本文根据 PCB 裸板的制造工艺与导孔特性，提出一种基于区域组合特征的检测方法，利用圆的几何特征，通过统计连通域内像素数量与轮廓长度比来识别导孔，并统计识别出的导孔数量，优势在于可以有效降低噪声干扰，计算复杂度低，具体实现过程如下：

（1）对图像中连通域进行标记（上一节中的连通域分析算法，这里不再赘述）；

（2）对标记好的各个连通域，分别计算其面积  $A$ （上一节中的面积计算方法，这里不再赘述）以及轮廓长度  $C$ ；

（3）根据圆的几何特征，若满足  $\frac{C^2}{4\pi} \approx A$ ，则可判断该处为一个导孔。

### 3.6 实验结果及分析

为了评估本章所提算法的性能，本节对采集到的 PCB 裸板图像进行实验分析，所有实验结果均借助 Windows10 系统下的 VSCODE 平台验证。

#### 3.6.1 图像分割

为了验证本文方法对图像的二值分割性能，本节以标准图像（标准二值化数据集 PHIBD<sup>[49]</sup>）、复杂图像（数据集 USC-SIP<sup>[50]</sup>）和 PCB 裸板图像为基准，将本文方法与其他经典的分割算法进行比较，包括 OTSU<sup>[51]</sup>，Bradley<sup>[52]</sup>，LU<sup>[53]</sup>，FCM<sup>[24]</sup>，ENFCM<sup>[54]</sup> 以及 FRFCM<sup>[55]</sup>。此外，本节还使用了包括错分类误差（Misclassification Error, ME）<sup>[56]</sup>、精准度（Precision, PR）、召回率（Recall, RC）以及 F 度量指标（F1）在内的四种评价标准，这些评价指标均在 0 到 1 之间，

ME 与测量结果成反比, 其余则均与测量结果成正比。

### (1) 标准图像二值分割

为了评估本文所提方法对在图像二值分割方面的有效性, 本节选取标准二值化数据集 PHIBD 中带有“暗影污渍”的噪声图像(如图 3.12 (a) 所示)进行测试, 其对应的标准分割图像(参考图像)如图 3.12 (b) 所示。图 3.12 (c) 至图 3.12 (i) 分别为上述几种二值分割算法对图像进行处理的分割结果。由于暗影和污渍的存在, 图像中某些背景区域的图像灰度与文字灰度十分相似, OTSU、LU、ENFCM 以及 FRFCM 算法对暗影污渍均存在一定程度的误分; Bradley 与 FCM 算法虽不受污渍的影响, 但不能将前景区域分割成连续的块状, 且分割后前景区域不均匀; 虽然使用本文方法对图像没有达到 100% 精确分割, 但与其它算法相比, 由于本文方法在精分割阶段对边缘信息的精处理, 故所分割的结果误分类区域更少, 前景区域的细节也得到了较好的保留, 最接近标准参考图像。



图 3.12 标准图像二值分割结果: (a) 输入图像; (b) 参考图像; (c) OTSU; (d) Bradley; (e) LU; (f) FCM; (g) ENFCM; (h) FRFCM; (i) 本文方法

另外, 表 3.2 显示了对所有方法应用上述 4 个评价指标的结果, 本文算法未能在所有评价中都获得最佳分数, 但综合四个评价指标而言, 本文算法取得了不错的效果。其原因在于, 评价指标 PR 指一幅图像中正确分割前景占该图像中所有分割前景的比例, 而 RC 则指一幅图像中正确分割前景占该图像中真实前景的比例, 一般情况下两者存在一定制约关系, 需要结合实际图像进行取舍哪个得分更接近实际效果图。

表 3.2 本文算法对“标准图像”的分割性能

算法名称	OTSU	Bra-dley	LU	FCM	EN-FCM	FR-FCM	本文方法
ME	0.3467	0.2925	0.2399	0.2775	0.3257	0.2592	0.2077
PR	0.3971	0.5009	0.4936	0.5576	0.6719	0.5349	0.6745
RC	0.9351	0.8581	0.9794	0.8205	0.9538	0.9351	0.9182
F1	0.5677	0.6082	0.6564	0.6536	0.7238	0.6492	0.7473

## (2) 复杂图像二值分割

为进一步验证本文所提算法在处理复杂纹理图像时的分割性能,从 USC-SIPI 数据集中选取“房屋”图像(如图 3.13 (a)所示)进行实验验证,其对应的标准分割图像(参考图像)如图 3.13 (b)所示。图 3.13 (c)至图 3.13 (i)分别为上述几种二值分割算法对图像处理的分割结果。从图 3.13 所示分割效果来看,Bradley 与 FCM 等算法未能分割出成块状的前景区域;LU 算法虽然分割出了块状连续的前景区域,但所分割出前景区域占比小,大部分前景区域被误分为背景;ENFCM 算法保留了大部分高对比度的信息,但受光照影响,房屋阴影区域全被误判;OTSU、FRFCM 与本文算法分割效果大致相同且最为接近标准参考图像,但前两者均丢失了许多低对比度的纹理细节。

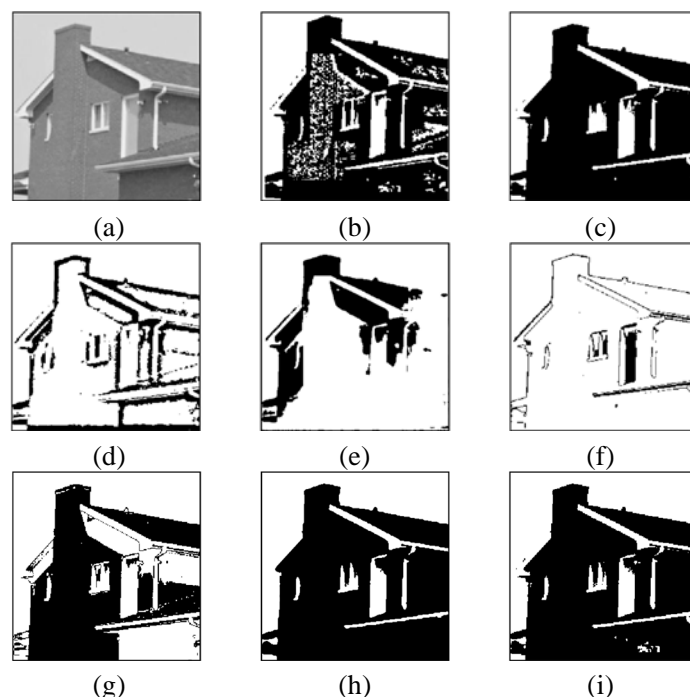


图 3.13 复杂图像二值分割结果: (a) 输入图像; (b) 参考图像; (c) OTSU; (d) Bradley; (e) LU; (f) FCM; (g) ENFCM; (h) FRFCM; (i) 本文方法



另外,表 3.3 显示了对所有方法应用上述 4 个评价指标的结果。从该角度来看:表中所示分割性能情况与表 3.2 中“标准图像”的分割性能情况类似,综合四个评价指标以及最终的分割图像视觉效果而言,本文算法取得了不错的效果,这里不再赘述。

表 3.3 本文算法对“复杂图像”的分割性能

算法名称	OTSU	Bra-dley	LU	FCM	EN-FCM	FR-FCM	本文方法
ME	0.3065	0.4684	0.4837	0.5904	0.3369	0.2063	0.2046
PR	0.7923	0.4686	0.4585	0.4081	0.5734	0.7953	0.7987
RC	0.6851	0.9109	0.8756	0.9196	0.7543	0.6823	0.6931
F1	0.5574	0.6188	0.6018	0.5653	0.6515	0.7345	0.7423

### (3) PCB 裸板图像

为测试算法在 PCB 裸板中的实际表现,使用 PCB 裸板图像(如图 3.14 (a)所示)进行了二值分割测试,鉴于 PCB 裸板的线路密集,本文希望分割后的图像可以保证线路边缘清晰,防止出现粘连与断线现象,以满足后续缺陷判定的高标准要求。图 3.14 (a)展示了在光照条件不均匀的情况下拍摄所得的 PCB 裸板图像。该图像不仅对比度低,而且还伴随着大量噪声区域的存在(右侧区域相对左侧更加模糊)。图 3.14 (c)至图 3.14 (i)分别为上述几种算法对图像处理的分割结果。从图像的分割效果角度来看,图 3.14 (d)中所显示的分割结果未能保留图像的细节信息,同时未能形成所需的闭合区域,即前景区域不连续、存在空洞;图 3.14 (f)由于没有考虑图像中邻域像素的相互关系,导致对图像中右侧低对比度区域的分割性能不佳;而图 3.14 (h)虽然有效抑制了图像中的噪声,但产生了过分割,导致分割后的线路发生了粘连现象;图 3.14 (e)与图 3.14 (g)虽然分割出了部分前景区域,但均存在大量的断线问题;图 3.14 (c)虽然较好地保留了图像的细节信息,但其对噪声的高敏感性导致图像中线路提取不完整且存在粘连等问题;尽管本文所提的图像二值分割算法未能完全达到标准图像的处理效果,但能保留更多的图像细节信息,且分割出了更为完整的图像线路区域。

如表 3.4 所示,对 PCB 裸板图像进行二值分割的性能评估结果表明:鉴于 PCB 裸板图像分割的高精度要求,通过 ME 与 F1 分数两个指标的评估,本文所提方法展现出了接近理想分割结果的性能。对于其它评价指标,本文方法虽然并没有取得最好的得分,但其性能与最优算法相比也相差无几。综合考虑,本文方法提升了 PCB 裸板图像二值分割中对光照条件的鲁棒性、抗干扰性和细节保持能力。




图 3.14 PCB 裸板图像二值分割结果: (a) 输入图像; (b) 参考图像; (c) OTSU; (d) Bradley; (e) LU; (f) FCM; (g) ENFCM; (h) FRFCM; (i) 本文方法

表 3.4 本文算法对“PCB 裸板图像”的分割性能

算法名称	OTSU	Bra-dley	LU	FCM	EN-FCM	FR-FCM	本文方法
ME	0.1783	0.3674	0.4357	0.2763	0.2477	0.1983	0.1369
PR	0.8045	0.9684	0.3008	0.8398	0.7724	0.7203	0.8769
RC	0.6349	0.4543	0.6891	0.6031	0.5808	0.7073	0.7724
F1	0.7097	0.6185	0.4189	0.7020	0.6630	0.7137	0.8213

### 3.6.2 线路缺陷检测

为验证本章所提算法方案的有效性,我们从东莞黔兴机械公司提供的 PCB 裸板样本中,选取其中一种型号的 PCB 裸板进行检测,结果如图 3.15 所示。其中图 3.15 (a) 为待检测的 PCB 裸板,红色矩形框标识出了其中的缺陷;图 3.15 (b) 为经本文分割算法处理后的二值图像;图 3.15 (c) 展示了经连通域分析和编码处理后的图像,其中不同的灰度等级(明暗灰度)代表图像中各个独立连通域的编号;图 3.15 (d) 为最终的检测效果,用蓝色掩膜进行标识。




图 3.15 PCB 裸板图像线路检测实例图：(a) 输入图像；(b) 图像分割；(c) 连通域编码；(d) 短路

此外，为了验证所提出算法在缺陷检测方面的有效性和可靠性，本文从东莞黔兴机械公司提供的 PCB 裸板样本中，选取了 5 种不同型号的 PCB 裸板进行实验。对于每种型号，我们针对各种不同缺陷均选取了 30 个样本。包括缺陷检测方案的性能和准确率的实验结果详细展示在表 3.5 中。

表 3.5 PCB 裸板线路缺陷检测算法方案检测性能

PCB 裸板 类型	短路缺陷 数量 真实/检测	开路缺陷 数量 真实/检测	凸起缺陷 数量 真实/检测	混合缺陷 数量 真实/检测	正确率 (%)	误检测数量 短路/开路/凸起
PCB1	30/30	30/29	30/28	30/29	96.6%	0/1/2
PCB2	30/28	30/29	30/26	30/28	92.5%	2/1/4
PCB3	30/29	30/30	30/29	30/30	98.3%	1/0/1
PCB4	30/30	30/30	30/28	30/26	95.0%	0/0/2
PCB5	30/29	30/28	30/30	30/30	97.5%	1/2/0
小计	150/146	150/146	150/141	150/143	600/576	4/4/9
综合性能	97.3%	97.3%	94.0%	95.3%	96.0%	/

从表中可看出本章算法对短路与开路缺陷检测效果较好，而针对凸起缺陷检测准确率相对较低。凸起缺陷的检测准确率低于其它类型缺陷的原因可能是凸起缺陷形状种类多，大小不一，且多出现在边缘处，在图像分割阶段易丢失信息，导致检测失败。另外，不同规格 PCB 裸板缺陷的检测准确率也不同，如 2 号板检测的准确率低于其它板，可能原因为 2 号板自身形态较复杂，线路过于密集，导致其检测的准确率低于其它类型的 PCB 裸板。从表 3.5 综合看来，本章所提出的缺陷检测算法方案，达到了检测要求的准确率（超过 90%），因此说明本章所提方案可靠。

### 3.6.3 导孔完整性缺陷检测

本节依旧从上述公司所提供的一系列 PCB 裸板样本中,选取 3 种不同型号的 PCB 裸板进行测试。为了验证本文检测算法的可行性,在同样的系统环境下,将本文检测算法与霍夫圆检测对三幅 PCB 裸板图像进行检测,测试图像与检测结果如图 3.16 所示。




图 3.16 PCB 裸板图像导孔检测实例图: (a) PCB1 输入图像; (b) PCB1 霍夫; (c) PCB1 本文方法; (d) PCB2 输入图像; (e) PCB2 霍夫; (f) PCB2 本文方法; (g) PCB3 输入图像; (h) PCB3 霍夫; (i) PCB3 本文方法

上图所示,传统基于霍夫的检测在线路复杂的 PCB 裸板图像上检测效果差,从图 3.16 (b) 可以看出,霍夫变换将导线转角区域误判为导孔,霍夫变换检测基本失效,而本文方法除了不需要像霍夫变换需要预先设定参数外,能有效地排除这些干扰,漏检误检少。将这两种算法统计运行 30 次的平均时间结果如表 3.6 所示。

表 3.6 本文算法对“PCB 裸板图像”的检测时间

算法	PCB1 (ms)	PCB2 (ms)	PCB3 (ms)
霍夫	178	139	166
本文算法	139	120	143

### 3.7 本章小结

本章主要讨论针对传统图像处理方法，所提出的基于两阶段分割与规则校验的 PCB 裸板缺陷检测方法。首先使用基于局部信息增强和直方图自动初始化聚类中心的 FCM 算法对图像进行粗分割，再在粗分割基础上使用基于先验信息的快速水平集方法进行精分割，把 PCB 裸板图像的线路区域从背景中提取出来，转化为二值图。然后，采用了基于 8 邻域的行程编码技术，对二值分割后的图像进行连通域分析与标记，统计二值图像中的连通域数量，最后通过计算得到各个连通域的边缘以及面积等参数，对 PCB 裸板线路以及导孔进行检测。通过实验验证了本章所提方案的可行性与可靠性。

## 第4章 基于师生网络与伪标签的半监督 PCB 板缺陷检测方法

在上一章中,本文提出了一种基于传统图像处理的方法进行 PCB 裸板的缺陷检测,而近年来,除了传统图像处理的方法,基于深度学习的方法在实际工业场景中也已经有实际案例取得不错的成果,但也有很多不足之处。本章主要采用基于深度学习的目标检测方法,而其最大的缺点在于对标记数据的强依赖性,需要大量且标注质量较高的数据支撑其训练。针对此问题,本章则重点讨论仅利用少量标记数据的方法实现对 PCB 板的表面缺陷检测。

### 4.1 基于师生网络与伪标签的半监督缺陷检测算法设计

目前,目标检测算法在物体表面的缺陷识别任务中能取得较好的检测效果,这种通常建立在拥有大量高质量标记数据的基础之上。然而,在 PCB 工业生产的实际应用中,面临的挑战是数据量巨大且缺陷多样。这要求众多经验丰富的标记人员对 PCB 缺陷图像进行分类与标记,这一过程不仅耗时而且成本高昂。因此在有限的时间内获取足够数量且标记精确的训练数据是相当具有挑战性的。相比之下,收集大量无标签数据比较容易。因此,本文提出一种采用半监督训练的方式完成缺陷检测任务,充分利用未标记数据,同时避免了目标检测算法需要依赖大量高质量标记数据的问题,达到以少量标记数据进行检测的目的。本节先介绍所提算法的整体设计,再在后续小节介绍具体细节实现。

#### 4.1.1 问题描述与分析

本文采用了基于伪标签的半监督检测策略。这种方法适用于需要同时进行分类和定位的复杂检测任务。而传统的半监督检测任务通常采用分阶段的训练策略。具体而言,第一阶段使用有限(少量)的标记数据对初始检测器进行全监督训练;在第二阶段,该检测器被用于对未标记的数据进行伪标签标记,得到高置信度的结果作为未标记数据的伪标签;第三阶段是将有标记数据和带有伪标签的无标记数据输入检测器进行训练。这种多阶段的半监督方法在标记数据稀缺而未标记数据充足的情况下,实现了较为理想的检测效果。然而,这种多阶段半监督检测方法也存在一定的局限性,由于初始检测器模型仅用少量标记数据进行训练,导致对缺陷的检测精度较低,且伪标签是采用离线生成的方式,在训练过程中不会更新,继续使用原始检测器对无标记数据所生成的伪标签质量较低,会阻碍模型准确度的进一步提升,从而影响了多阶段半监督检测的整体性能。



端到端的半监督学习为提升初始检测器在多阶段半监督检测方法中生成的伪标签的质量,提供了一种有效的解决方案。与传统的多阶段学习相比,端到端的方法可以在训练过程中同时对未标记图像进行伪标签标记,并且伪标签的准确性可以在训练过程中得以增强,从而提升了检测模型的性能。

端到端的半监督学习虽然避免了多阶段学习的复杂流程,但目前由于两阶段目标检测方法检测精度高,大多数用于缺陷检测的半监督算法均采用该检测方法,导致模型依旧复杂且计算复杂度高。虽然满足了高精度的检测要求,但检测效率难以满足工业生产中实时性的需求,因此如何进一步提高检测速度是本章需要解决的一个问题。

此外,在传统的半监督检测中,教师模型的作用是直接对学生模型生成的候选框进行评估,依据伪标签的检测得分采用高阈值过滤(硬过滤)掉得分低的伪标签,但得分高的伪标签不一定对模型是最优的,不适合的伪标签会误导模型的更新,影响检测效果。由于 PCB 缺陷检测任务需要准确分类并定位 PCB 的缺陷位置,并且 PCB 缺陷的尺度跨越较大,形状种类多样。PCB 板的表面缺陷主要包括短路、开路、凸起、凹陷、导孔和残铜等多种类型,传统的伪标签筛选策略,容易导致学生模型许多预测值中真正的候选框被错误地分配为背景区域。此外,实验结果表明,候选框的定位精度与其对应的教师模型生成的置信度分数之间,并没有显示出明确的正相关性,模型的高置信度候选框可能无法准确提供定位信息。故如何对生成的伪标签进行合适筛选以及使用是本章重点研究的一个问题。

为解决上述问题,针对缺陷检测任务中难以收集大量带有高质量标记的缺陷数据问题,提出以教师学生网络作为半监督学习框架,达到以极少量标记数据进行检测的目的。针对目前大多数缺陷检测算法均以两阶段目标检测框架(如 RCNN、Faster RCNN 等)来实现缺陷类别与位置的检测,虽然可以取得较好的检测精度,但检测速度低,无法满足工业实时性需求的问题,提出采用目前检测精度与速度并存的单阶段目标检测框架 YOLOv5 作为核心缺陷检测框架,在满足检测精度的同时保证缺陷检测的速度。针对传统半监督生成伪标签的不一致性(即在整个训练过程中所生成的伪标签数量和质量波动很大,而采用硬过滤的方法会产生很多不合格的伪标签,而不合格的伪标签会误导模型的更新),提出改进伪标签分配法,引入一种更精细的伪标签分配器。

#### 4.1.2 总体框架

近年来,半监督学习(Semi-Supervised Learning, SSL)方法因其可以利用大量未标记数据来提高在少量标记数据上训练检测器的性能,已经在图像分类中扮演了重要的角色<sup>[57]-[60]</sup>。但是由于目标检测任务具有复杂的架构设计和多任务学习(分类和回归)的特点,因此将 SSL 方法迁移到目标检测任务并不是一项简单的

工作。目前的半监督目标检测（Semi-Supervised Object detection, SSOD）方法主要有两个方向：一致性正则化（Consistency Regularization）和伪标签（Pseudo Label）。前者采用了两个深度卷积神经网络，目的是学习同一未标记图像在经过不同数据增强（水平翻转、不同对比度、亮度等）处理后所表现出特征一致性，其核心思想是模型的输出在一些微小的扰动下保持不变。后者使用在标记数据上学习的预训练模型来推断未标记数据的伪标签，借此指导模型学习未标记数据。

本章采用一种基于教师学生网络和伪标签的半监督缺陷检测网络，如图 4.1 所示为该方法进行 PCB 板缺陷检测的整体框架图，该方法的目的是通过逐步提升 PCB 板缺陷检测模型准确度以及生成伪标签质量，来增强模型的整体检测精度。

此外，本章所提方法中含有两个训练网络，即教师网络和学生网络，它利用标记数据和未标记数据同时提高模型性能。该算法通过训练学生网络来预测标记和未标记数据的标签，然后使用教师网络的预测作为正则化形式来指导学生网络在其预测中保持一致。

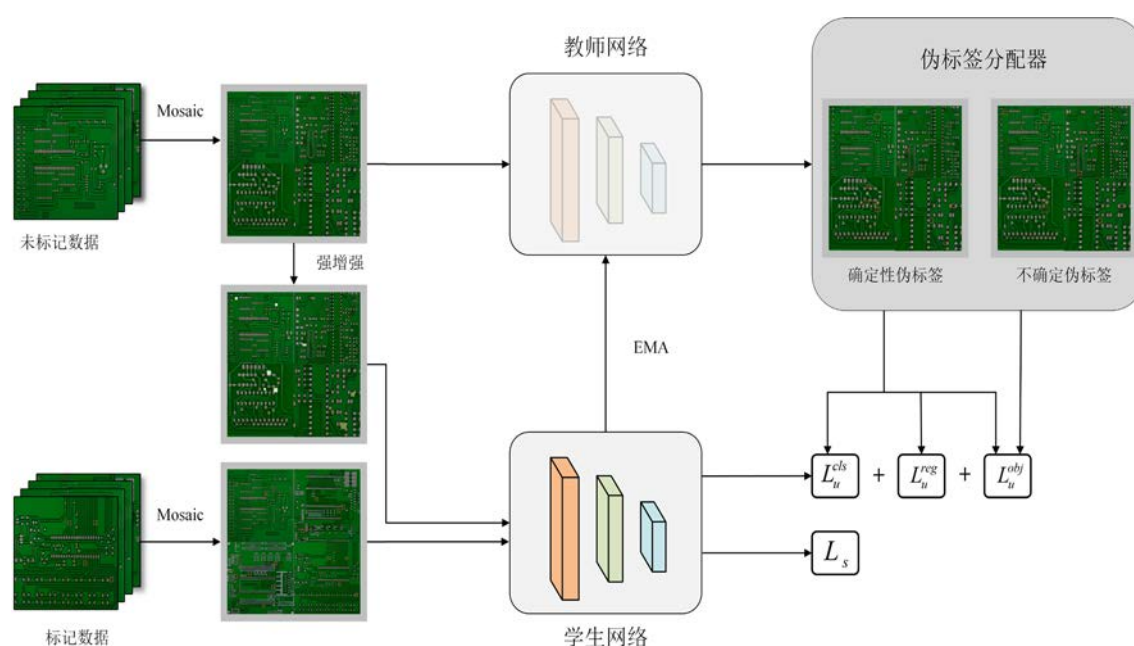


图 4.1 基于教师学生网络与伪标签的 PCB 半监督缺陷检测网络整体框架图

具体而言，本章所提出的 PCB 板半监督缺陷检测网络首先将未标记的 PCB 板图像和已标记的 PCB 板图像进行随机采样，形成训练数据批。然后，为了在后续整体网络的训练中，增加模型的鲁棒性，本文采用 Mosaic 和强增强的两种不同数据增强方式，对标记数据与未标记数据分别进行不同的处理。对有标记的 PCB 板图像仅采用 Mosaic 处理，应用于学生网络进行有监督训练，教师网络则通过滑动指数平均（Exponential Moving Average, EMA）方式由学生模型更新，在每个训



训练迭代中，对仅采用 Mosaic 处理的未标记 PCB 板图像，应用教师模型，对仅经 Mosaic 处理后的未标记 PCB 板图像检测，根据本文所提的伪标签分配器，将生成的不同得分伪标签分为确定性伪标签与不确定性伪标签两种。最后，将教师模型生成的伪标签作为未标记 PCB 板图像的标签，与采用 Mosaic 和强增强结合处理的未标记 PCB 板图像，共同训练学生模型。需要注意的是，两种伪标签分别进行不同损失计算（后续介绍实现细节），最终损失函数是监督检测损失  $L_s$  和无监督检测损失  $L_u$  之和。

需要说明的是，上述仅经过 Mosaic 处理的 PCB 板图像，输入教师网络进行推理预测，为了降低模型的运算复杂度，对教师模型生成的候选框先进行 NMS 操作，得到初始伪标签。因为伪标签质量直接影响到模型的最终性能，传统半监督检测方法通常直接设置一个较高的阈值（高置信度得分）来对生成的伪标签进行硬筛选。实际目标检测任务中，伪标签涉及分类与定位任务，而伪标签的定位精度与教师网络生成的置信度得分并没有较强的正相关性，仅采用硬筛选方法所生成的伪标签质量低，因此，本文采用基于伪标签分配器的方法，将伪标签分为确定性与不确定伪标签两种，分别进行不同的损失计算（后续介绍实现细节）。

另外，由于 PCB 缺陷形状种类跨度大、尺寸小的特点，本章提出的半监督 PCB 板缺陷检测方法采用了教师、学生模型的协同学习策略，构建了一种端到端的 PCB 板缺陷检测框架。在每一轮的训练中，根据预设采样比例对已标记图像和未标记图像进行随机采样，分批形成训练样本。教师模型负责对未标记图像生成伪标签，学生模型基于已标记 PCB 板图像和具有伪标签的未标记 PCB 板图像进行训练。在训练的初始阶段，教师模型和学生模型均以随机初始化的方式进行预训练，随着训练的进行，本文采用 EMA 策略，通过学生模型的参数来更新教师模型，EMA 能够有效增强半监督 PCB 板缺陷检测模型的鲁棒性，其具体的计算公式如下：

$$\theta_t \leftarrow \alpha \theta_t + (1 - \alpha) \theta_s \quad (4-1)$$

上式中， $\theta_t$  是教师模型参数， $\theta_s$  是学生模型参数， $\alpha$  是平滑系数超参数，通常设置为 0.999。

## 4.2 基于伪标签分配器的半监督缺陷检测方法

### 4.2.1 基于伪标签的半监督缺陷检测方法的问题

基于伪标签的半监督学习最早在 2013 年被提出，即同时使用标记数据和未

标记数据进行训练，在 MINIST 手写数据的检测及分类上取得了良好效果。在目标检测领域，可以采用伪标签方法利用置信度阈值来筛选出高质量的目标框来当作伪标签进行训练。虽然有效，但利用该方法筛选出来的伪标签（以与类预测相关联的边界框的形式）对于半监督目标检测并不是最优的。原因主要有以下几个方面：

（1）在图像分类中，预测结果的概率自然地代表了一个对象出现在图像中的可能性，因此设置一个阈值来选择高置信度的预测是合理的。然而，由于在这类检测任务中需要通过回归和分类，使用两个独立的分支对对象进行检测而实现定位和分类，导致所生成伪框的分类分数并不知道定位质量。因此，虽然在分类任务上有一定效果，但在非极大值抑制之上，仅采用基于类别预测过滤伪框的方式是不合适的；

（2）如果模型在预测未标记数据的标签时出错，将导致这些错误通过反向传播进入到训练过程中，进而会导致模型学习不正确或不相关的信息，最终降低模型的检测性能。

（3）使用伪标签时，模型对其预测的置信度可能不是其准确性的可靠指标。这会使评估伪标签的质量变得困难，并且如果模型过于相信自己的预测，则可能导致过度拟合。其次伪标签的使用通常需要为模型预测的置信度设置一个阈值，以确定使用哪些伪标签进行训练。选择合适的阈值可能具有挑战性，并且会显著影响模型的性能。

### 4.2.2 伪标签分配器设计

半监督学习在缺陷检测领域带来了许多有利之处。这种方法通过减少对大规模高质量标记数据集的依赖，降低了数据标记的需求，从而减少了专业人工标记员的培训成本和标记成本，对实际工业生产具有重要意义。然而，如上节所述，基于伪标签的半监督方法在实现过程中也存在许多问题。

具体而言，基于伪标签的半监督进行目标检测时，检测性能取决于生成的伪标签质量，故该方法的核心问题即如何分配伪标签，也即确保所使用伪标签的准确性，其次劣分配会导致伪标签的不一致性（即在整个训练过程中所生成的伪标签数量和质量波动很大，不合格的伪标签会误导模型的更新），从而降低教师学生网络互学习机制的性能。所谓次优分配，以常见的伪标签过滤器为例，它是伪标签分配的一种简单实现，也是伪标签筛选中应用最广的一种方法。该方法通过设置一个阈值来对生成的伪标签进行处理，将过滤掉低于设定阈值的伪标签，而高于阈值的伪标签则被视为可靠的伪标签，用于后续的训练。而这类方法将阈值设置太低会导致不正确的伪标签进行后续训练，过高的阈值则仅考虑了分类而未考虑定位，会排除一部分可靠的伪标签，最终都将会对网络的训练产生不利的影

响。如图 4.2 所示，分割线上方的情况，直观显示了上述伪标签过滤器的快速实现过程。

针对这个问题，本文提出一种基于伪标签分配器的半监督缺陷检测方法，该方法保留了低阈值与高阈值之间的那部分伪标签，以避免高阈值筛选所出现的前背景错分问题。如图 4.2 所示，分割线下方显示了本文所提出的一个更精细的伪标签分配器。本文所提出的伪标签将分别基于高阈值和低阈值将伪标签分为确定性伪标签和不确定伪标签两类，根据不同的类别参与不同损失函数的计算，以提高最终的检测质量。

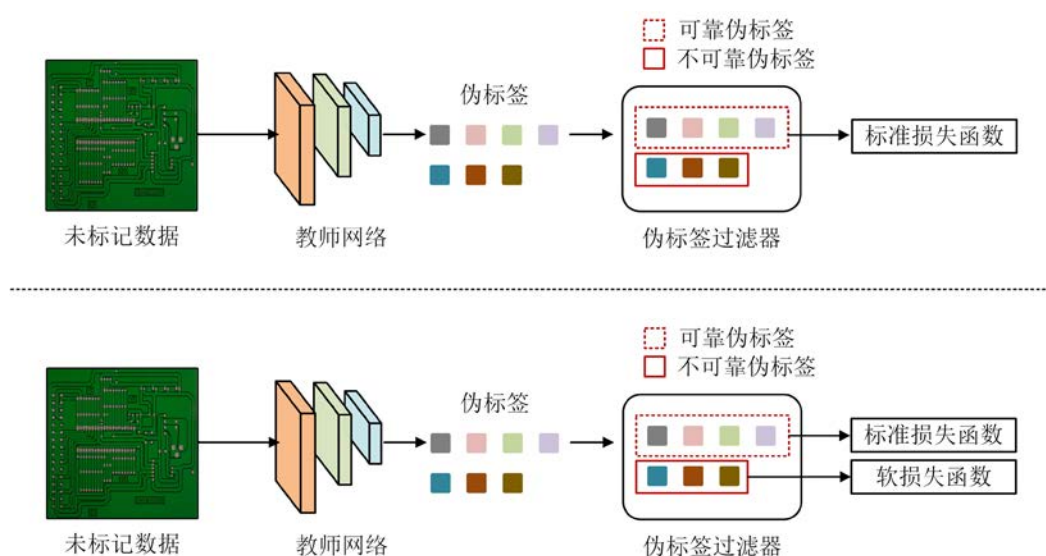


图 4.2 不同伪标签选择策略

### 4.2.3 损失函数

在上述伪标签分配器中，经非极大值抑制（NMS）后获得的伪标签，根据其分数的低阈值  $\tau_1$  与高阈值  $\tau_2$ ，将其分为两类：确定性伪标签（可靠伪标签）和不确定伪标签。其中，分数在  $\tau_1$  与  $\tau_2$  之间的伪标签被认为是不确定的，本文通过使用一个无监督的损失，有效利用不确定的伪标签。通常，半监督目标检测中检测器的损失被定义为有标记数据与未标记数据之和：

$$L = L_s + \lambda L_u \quad (4-2)$$

上式中， $L_s$  表示在标记图像上计算的损失函数， $L_u$  表示在未标记图像上计算的损失函数， $\lambda$  用于平衡有监督损失与半监督损失，本文取  $\lambda = 3$ 。其中，标记图像上

计算的损失函数  $L_s$  为标记数据的分类损失（classification loss）、回归损失（regression loss）与目标置信度损失（objectness loss）之和，为目标检测任务中的标准损失函数：

$$L_s = \sum_{h,w} (CE(X_{(h,w)}^{cls}, Y_{(h,w)}^{cls}) + CIoU(X_{(h,w)}^{reg}, Y_{(h,w)}^{reg}) + CE(X_{(h,w)}^{obj}, Y_{(h,w)}^{obj})) \quad (4-3)$$

上式中， $CE$  表示二值交叉熵损失函数， $X_{(h,w)}$  是学生模型的输出， $Y_{(h,w)}$  表示检测网络中伪标签分配器生成的结果。

在未标记图像上计算的损失函数  $L_u$  也包括分类、回归以及目标置信度损失这三个部分。损失函数  $L_u$  具体的定义如下：

$$L_u = L_u^{cls} + L_u^{reg} + L_u^{obj} \quad (4-4)$$

$$L_u^{cls} = \sum_{h,w} \left( \mathbb{I}_{\{p_{(h,w)} \geq \tau_2\}} CE(X_{(h,w)}^{cls}, \hat{Y}_{(h,w)}^{cls}) \right) \quad (4-5)$$

$$L_u^{reg} = \sum_{h,w} \left( \mathbb{I}_{\{p_{(h,w)} \geq \tau_2 \text{ or } obj_{(h,w)} > 0.99\}} CIoU(X_{(h,w)}^{reg}, \hat{Y}_{(h,w)}^{reg}) \right) \quad (4-6)$$

$$\begin{aligned} L_u^{obj} = & \sum_{h,w} \left( \mathbb{I}_{\{p_{(h,w)} \leq \tau_1\}} CE(X_{(h,w)}^{obj}, \mathbf{0}) \right. \\ & + \mathbb{I}_{\{p_{(h,w)} \geq \tau_2\}} CE(X_{(h,w)}^{obj}, \hat{Y}_{(h,w)}^{obj}) \\ & \left. + \mathbb{I}_{\{\tau_1 < p_{(h,w)} < \tau_2\}} CE(X_{(h,w)}^{obj}, obj_{(h,w)}) \right) \end{aligned} \quad (4-7)$$

上式中， $\hat{Y}_{(h,w)}^{cls}$ ， $\hat{Y}_{(h,w)}^{reg}$ ， $\hat{Y}_{(h,w)}^{obj}$  分别为图像中位置  $(h, w)$  处经过伪标签分配器得到的结果的分类得分，回归的得分以及置信度得分， $obj_{(h,w)}$  为图像中位置  $(h, w)$  处伪标签的置信度得分， $p_{(h,w)}$  为图像中位置  $(h, w)$  处的伪标签的分类得分， $\mathbb{I}_{\{\bullet\}}$  是指示函数：如果满足条件  $\{\bullet\}$  则输出 1，否则输出 0。

本章所提的伪标签分配方法不是直接通过高阈值来过滤掉分类得分低的伪标签，而是通过双阈值，保留了低阈值与高阈值之间的不确定性伪标签，将这两类伪标签分别参与不同损失的计算：

（1）当伪标签的分类得分  $\geq \tau_2$ （上述高阈值）时，即所有的确定性伪标签，计算其分类损失与标准的目标置信度损失；

(2) 当伪标签的分类得分  $\geq \tau_2$  或目标置信度得分  $> 0.99$  时, 即所有的确定性伪标签和目标置信度高的伪标签, 计算其回归损失;

(3) 当伪标签的分类得分介于  $\tau_1$  与  $\tau_2$  之间时, 也就是不确定性伪标签, 这种则按照本文引入的新的计算方法。

具体而言, 本章所提的伪标签分类器将不确定的伪标签进行两种处理: 不确定伪标签中具有高目标置信度得分的部分, 即当不确定伪标签中其目标置信度得分  $> 0.99$  时, 这些伪标签具有良好的回归结果, 但其分类得分不足以确定该伪标签的类别, 没有很好的分类结果, 故仅参与回归损失  $L_u^{reg}$  的计算。除此之外的其余不确定性伪标签, 因其分类得分不高故仅参与半监督损失中的目标置信度损失计损失  $L_u^{obj}$  的计算, 且使用  $obj_{(h,w)}$  替换标准置信度损失函数中的  $\hat{Y}_{(h,w)}^{obj}$  作为交叉熵函数的学习目标也即本文所指的软损失, 由于其不参与分类与回归的计算, 故这些伪标签不会被分为背景或前景样本。

### 4.3 PCB 板表面缺陷检测模型

图 4.3 展示了本章节所提出的基于伪标签分配器的半监督缺陷检测算法流程图。本章节的核心思路就是通过伪标签分类器提高半监督缺陷检测中伪标签筛选方案的质量, 进而提高整体缺陷检测的质量, 该方法的具体实现步骤可概括为如下几点:

(1) 数据集由标记数据和未标记数据组成。在训练的初始阶段, 对标记 PCB 板图像进行 Mosaic 处理后输入学生模型中, 进行有监督训练。随后采用 EMA 的参数更新策略, 将经过有监督训练后学生模型的权重参数传递给教师模型;

(2) 未标记的数据首先经过 Mosaic 处理, 随后输入至教师网络中。并使用更新权重参数后的教师网络, 对输入数据进行预测 (生成伪标签), 得到的预测结果进一步通过 NMS 算法进行筛选, 最后得到初步的伪标签;

(3) 模型通过双阈值对初步生成的伪标签进行筛选, 将其分为确定性伪标签与不确定伪标签 (将低于低阈值的伪标签直接过滤), 并作为步骤 (2) 中生成的候选结果的标签;

(4) 未标记数据经过 Mosaic 与强增强 (包括左右翻转、灰度化、高斯模糊、剪切以及颜色空间转换等) 处理后, 将步骤 (3) 中所生成的伪标签作为其标签, 共同输入学生网络进行训练;

(5) 对于步骤 (4) 中学生网络的训练, 将确定性伪标签计算标准损失函数 (分类、回归以及目标置信度损失), 将不确定伪标签中目标置信度得分高的计算回归损失, 剩下的部分则计算软损失 (如图 4.3 所示)。

(6) 在步骤(5)中, 基于所计算的损失函数, 通过前馈权重参数更新, 这一过程不仅促进了学生模型的进一步学习, 同时通过采用 EMA 策略, 将更新后的学生模型权重参数传递给教师模型, 从而实现了教师模型权重参数的同步更新。通过这种方式, 不仅提高了所生成伪标签的质量, 也逐渐提高了整个模型的检测准确度。




图 4.3 基于伪标签分配器的 PCB 板表面缺陷半监督检测算法概览

## 4.4 实验结果及分析

为了充分验证本文所提半监督 PCB 板缺陷检测方法的有效性, 本节设置了多组实验进行评估, 为了更加公平地对各个模型进行比较, 本文使用 PCB 板数据集进行实验。本节首先介绍实验的相关设置, 其次对本章所提出的方法应用于本文研究对象, 可视化实验结果以验证算法在 PCB 板缺陷检测上可行且有效, 最后, 使用 PCB 板数据集进行相关对比实验验证算法的整体检测性能。

### 4.4.1 实验说明

本章实验统一采用了 python 语言和 Pytorch 框架, 具体实验环境配置细节参见表 4.1。另外, 本章所提方法采用了教师学生模型的开源框架和 YOLOv5 的开源框架。

实验首先利用带标记的数据集进行预训练, 以获取一个预训练模型, 接着采用半监督学习方法, 同时利用标记数据和未标记数据进行训练。由于实验条件的限制, 超参数直接采用 YOLOv5 默认的超参数, 包括学习率的调整等。需要补充的是, 本文方法采用单阶段目标检测网络 YOLOv5 作为核心检测网络, 而目前现有的半监督框架均基于两阶段目标检测网络, 且将其替换为单阶段网络会导致检测效果差, 并不适配于单阶段目标检测检测网络, 因此替换核心检测网络进行对

比实验不具有参考意义。

表 4.1 实验环境配置

项目	具体内容
GPU	RTX3090
显存	24G
深度学习框架	Pytorch
Python 版本	Python3.9.12
CUDA	CUDA12.2

在后续的所有实验中，我们共使用了 1380 张的 PCB 板图像数据集，其中每类缺陷图像均为 230 张。需要注意的是，我们根据总数据集，按不同比例对标记数据进行随机采样，而不是直接使用全部标记数据进行训练验证。

为了充分验证本章所提的半监督 PCB 板缺陷检测方法的有效性，在 PCB 板实例检测中，本章主要将所提检测方法与目前较为先进的半监督方法 Softteacher 进行比较，作为本文方法的消融实验。在模型对比实验中，本章则主要将所提检测方法与前述常用的半监督方法 STAC、Unbiased Teacher 以及 Softteacher 进行比较。


#### 4.4.2 PCB 板实例检测

为了进一步验证本文方法在 PCB 板缺陷检测任务中的有效性，使用上述 PCB 板数据集，按不同比例随机采样，作为本实验的有标记与无标记数据集。本节将从数据集处理以及检测结果两个方面进行阐述。


##### （1）数据增强

在实验中，为了增强半监督 PCB 板缺陷检测模型的鲁棒性，对标记图像与未标记图像采取不同的数据增强策略，如图 4.4 所示为实验中截取的部分 PCB 板图像数据增强处理结果图。图 4.4（a）为对未标记图像进行 Mosaic 处理后输入到教师网络中，图 4.4（b）为对未标记图像进行强数据增强（包括颜色空间转换、高斯模糊以及剪切覆盖等）输入到学生网络中。需要说明的，本文对未标记数据处理为仅 Mosaic 处理和 Mosaic 与强增强结合的两种增强方法，此处为方便展示强数据增强结果，呈现的为仅单独使用强增强处理的效果图。






(a)



原图

颜色空间转换



模糊

覆盖

(b)

图 4.4 未标记图像数据增强: (a) Mosaic; (b) 强数据增强

## (2) PCB 实例缺陷检测结果

为了充分且直观验证本文所提的半监督 PCB 板缺陷检测方法的有效性,采用目前前沿的 Softteacher 方法与本文所提半监督方法对 PCB 板图像进行检测,并对 PCB 板的缺陷检测结果进行了可视化处理。

如图 4.5 所示,展示了 PCB 板数据集中,不同型号 PCB 板共 6 种缺陷的部分检测结果,其中图 4.5 (a) 与图 4.5 (c) 为使用 Softteacher 对 6 种缺陷检测的结果效果图,图 4.5 (b) 与图 4.5 (d) 则为本文方法对 6 种缺陷检测的结果效果图。由于 PCB 板图像尺寸较大,部分类型的 PCB 板缺陷尺寸较小,为了直观地表达 PCB 板缺陷检测效果,本文将部分 PCB 板缺陷检测结果进行了放大处理。PCB 板缺陷位置通过检测框进行标记。PCB 板缺陷内容分为两部分,一部分为 PCB 板缺陷类型,另一部分是置信度,由数字进行表示,置信度的取值范围为 0~1,数字越大表示所预测的该类型 PCB 板缺陷的真实性越高。由于本文算法引入了不



确定伪标签，对不确定伪标签中目标置信度得分高的部分，参与回归损失的计算，除此之外的不确定伪标签，参与了目标置信度损失的计算，解决了 Softteacher 算法中存在的漏检问题（如图 4.5 中短路与凹陷缺陷的检测效果），且检测框中所包含的背景信息得到有效减少（如图 4.5 中凸起缺陷检测的结果），检测框的置信度均获得了一定程度的提升（如图 4.5 中导孔、凸起以及残铜缺陷检测的结果），获得更高的检测精度。需要说明的是，图 4.5 为两种方法检测的可视化效果对比图，由于两种方法设置不同，导致相同类型缺陷的检测框在两种方法的检测结果上颜色与大小均不相同。

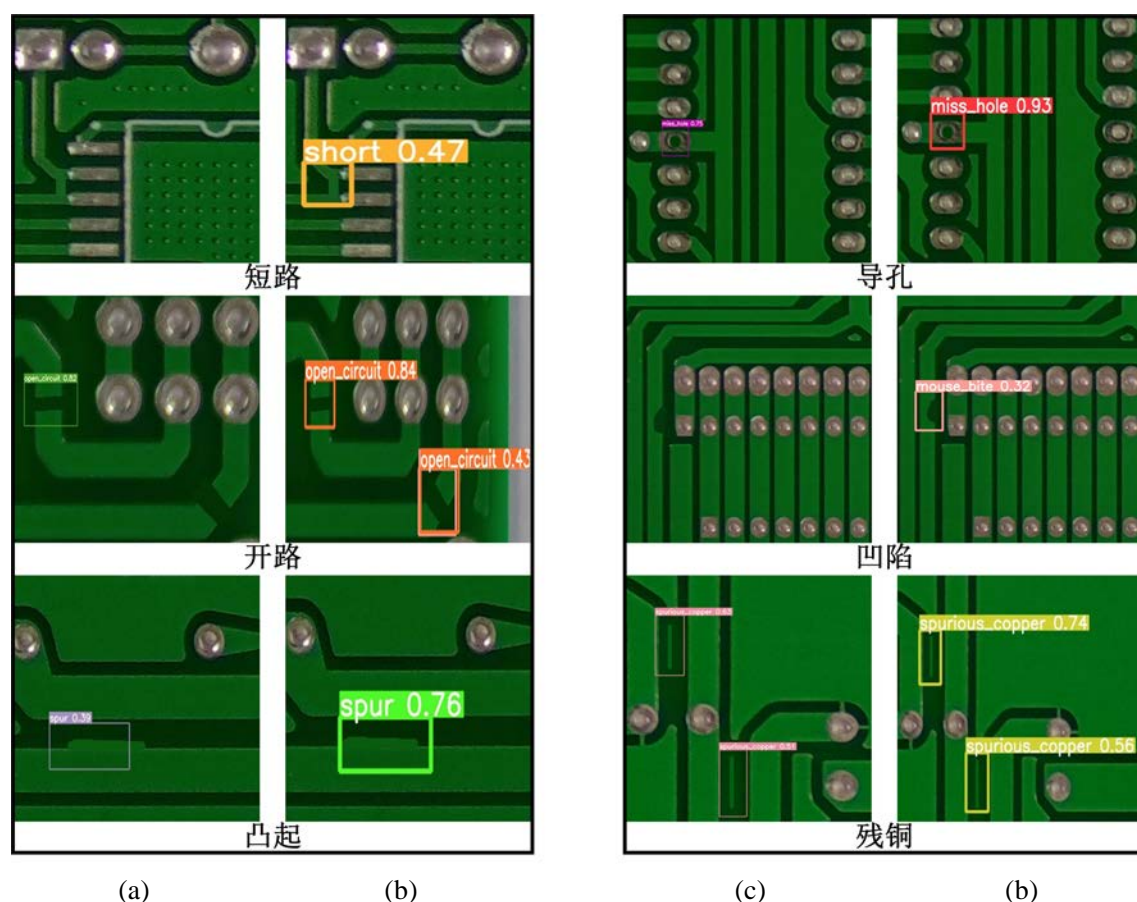


图 4.5 PCB 板图像部分缺陷检测结果对比图：(a) Softteacher 分别对短路、开路、凸起缺陷的检测效果图；(b) 本文方法分别对短路、开路、凸起缺陷的检测效果图；(c) Softteacher 分别对导孔、凹陷、残铜缺陷的检测效果图；(d) 本文方法分别对导孔、凹陷、残铜缺陷的检测效果图

根据图 4.5 所示的 Softteacher 算法与本文算法对 PCB 板检测的可视化效果图可知，本文算法检测效果优于 Softteacher 算法，得益于本文算法所提出的新的伪标签计算方式。为了更直观验证本文所提出伪标签计算方式的优点，以及本文所提半监督 PCB 板缺陷检测方法在较少标记数据中的有效性，对上述 PCB 板数据

集中的已标记数据进行随机提取,提取量分别为已标记数据集总量的 10%与 30%,其余样本则剔除标签,作为未标记的 PCB 板图像,采用 Softteacher 算法与本文算法进行对比 (Softteacher 伪标签计算方式类似于传统的伪标签硬筛选策略,本文伪标签分配器中,伪标签的计算方式引入了不确定性伪标签,而非硬筛选,故可以将 Softteacher 算法与本文算法进行对比以凸显本文伪标签计算法方式的优势),结果如图 4.6 所示。




图 4.6 不同比例标记数据在不同算法中的结果对比图

图 4.6 中,左侧为对 PCB 板数据集随机提取已标记数据的 10%作为两种半监督检测方法的已标记数据,右侧为对 PCB 板数据集随机提取已标记数据的 30%作为两种半监督检测方法的已标记数据,剩余 PCB 板缺陷数据则作为未标记数据进行实验,其中评价方式采用国际通用的 COCO 数据集评价指标 mAP 作为判断两种半监督检测方法的有效性,其中,纵坐标为 mAP 数值, mAP 取值范围为 0~1,数字越大代表算法在所有类别中的平均检测精度越高,横坐标为训练次数,训练过程总共训练 500 轮,两种算法分别在训练 325 轮左右后达到收敛状态。PCB 板数据集共有 6 种缺陷类别,缺陷尺度跨越不大,但均为小目标缺陷,在随机提取已标记数据的 10%作为两种半监督检测方法的已标记数据时, Softteacher 方法的平均 mAP 为 0.24,本文所提方法的平均 mAP 为 0.31,比 Softteacher 高 0.07,通过 mAP 指数可以得出本文所提方法在标记数据量较少时,对 6 种 PCB 缺陷检测有效;在随机提取已标记数据的 30%作为两种半监督检测方法的已标记数据时, Softteacher 方法的平均 mAP 为 0.39,本文所提方法的平均 mAP 为 0.45,比 Softteacher 高 0.06,即本文所提方法检测性能更佳。

#### 4.4.3 模型对比实验

在本章的实验设计中,采用 PCB 板数据集来对算法的性能进行验证。对 PCB

板数据集中已标记数据进行随即提取，提取量分别为已标记数据集总量的 10%、20%、30%，其余样本剔除标签，作为未标记 PCB 板图像。同时采用目前前沿的半监督目标检测方法 STAC、Unbiased Teacher 和 Softteacher 进行对比，验证本文算法的有效性，其中评价方式采用国际通用的 COCO 数据集评价指标 mAP，mAP 取值范围为 0~1，数字越大代表算法在所有类别中的平均检测精度越高，实验结果如表 4.2 所示。

表 4.2 不同方法在 PCB 数据集上检测效果

方法	Backbone	10%PCB	20%PCB	30%PCB	FLOPs (G)
STAC	Faster RCNN	0.1797	0.2838	0.3164	202.31
Unbiased Teacher	Faster RCNN	0.2475	0.3227	0.3550	204.13
Softteacher	Faster RCNN	0.2413	0.3474	0.3949	202.31
本文方法	YOLOv5	0.3147	0.4015	0.4517	109.59

由表 4.2 可知，将 PCB 数据集用于不同的半监督方法时，对于不同比例的标记数据集，均取得了较好的检测效果，特别是对于 10% 占比的标记数据集，本文方法比 STAC、Unbiased Teacher 与 Softteacher 这三种方法而言，分别提升了 0.135、0.0672 与 0.0734。此外，由于本文方法采用单阶段的目标检测网络，该网络的浮点计算数远远小于以往采用两阶段的检测方法。不仅满足了实时性的要求，同样具有一定的检测精度，充分证明所提出算法的性能。

## 4.5 本章小结

由于在实际的 PCB 生产过程中，短时间内获得大量且标记质量较高的训练样本是困难的，基于此问题，本章节提出一种基于伪标签的半监督 PCB 板缺陷检测方法，为了解决多阶段半监督检测方法生成标签质量较低的问题，采用基于可靠性度量的伪标签分配器的端到端 PCB 板缺陷检测方法，将教师、学生两种模型联合进行学习，EMA 用于学生模型对教师模型进行更新，使伪标签可以和 PCB 板缺陷检测网络互相加强，提升了检测模型的健壮性。为了解决次优分配导致伪标签不一致性的问题，通过评估学生模型生成的伪标签的分类得分与目标置信度得分，根据不同得分从而进行分类损失、回归损失与本文引入的软损失的计算，充分利用了伪标签的信息，提升了半监督检测模型的检测精度。

## 第 5 章 缺陷检测系统设计与实现

PCB 缺陷检测系统是一个集成了软件与硬件的完整系统，在本文的前述章节中，重点研究了软件部分的核心算法。本章则重点介绍系统硬件的构建，并详细阐述软件的工作流程以及设计的人机交互界面，最后对系统进行测试，验证了整个 PCB 缺陷检测系统的性能和可靠性。

### 5.1 系统硬件设计

在整个 PCB 缺陷检测系统中，硬件主要由执行算法的 PC 机，图像采集所需的光源、相机和运动装置组成。图 5.1 展示了本文所使用硬件设备的视图。其中，图 5.1 (a) 展示了设备的具体结构组成，图 5.1 (b) 则呈现了设备的实物照片。




图 5.1 检测设备示意图：(a) 设备结构组成；(b) 设备实物图

上述缺陷检测设备的基本工作流程为：首先，将待测 PCB 放置在机械传动装置之上，并利用机械夹具固定 PCB，以避免在传送过程中发生振动；当 PCB 随着传动装置移动到图像采集区域的预定位置时，触发信号控制器，该控制器随即向相机发出拍摄图像的指令；在光源系统提供的恒定光照条件下，相机以设定的帧率连续采集 PCB 图像；随后，采集到的图像数据被传输至 PC 机，并利用预设的算法对图像进行分析与检测；对于检测结果为无缺陷的 PCB，系统将使其继续沿传送路径前进至下一个生产环节，反之则将其送入指定区域等待分拣，同时系统将存储缺陷的详细信息，以便进行后续的分析处理。



### 5.1.1 光源系统

本文检测目标为 PCB 的表面缺陷，所检测的 PCB 包括蚀刻前和蚀刻后两种，其高质量的成像对检测结果至关重要。图 5.2 为 PCB 的成像示意图，图中红色矩形框内部反光较强，导致该图像出现了光照不均的问题，而光照不均会影响图像检测结果，因此需要合理设计光源系统，从物理层面尽可能减少上述问题的发生。




图 5.2 光照不均的 PCB 示意图

本文所设计的光源系统中，其照明的均匀性主要取决于所选的光源类型和照明结构的设计。在机器视觉系统中，常用的光源包括 LED 灯、荧光灯以及卤素灯等。而为了解决上述反光所导致的成像结果光照不均的问题，避免图像中出现局部区域过曝或欠曝的现象，本系统需要保证在成像范围内光照的均匀性，因此采用使用寿命长、成本低以及光线方向性好的 LED 面光源进行照明。

另外，必须选择合适的打光方式，以最大限度地降低 PCB 表面反光对图像处理算法所造成的影响。常用的打光方式可分为直接照明的明视野和利用散射光照明的暗视野两种<sup>[61]</sup>，如图 5.3 所示。其中，直接照明更加适合检测表面光滑的物体；而散射光照明则更加适合对表面的污垢和凸起进行检测。由于直接光照明的明视野技术在处理大范围内区域时难以保证光线的均匀性，从而引起局部过曝的问题。因此本文采用散射光照明的方案。




图 5.3 两种照明方式示意图：(a) 直接光照明；(b) 散射光照明

需要说明的是, 本文并未采用传统的人工目视检测法中, 所采用光线垂直透过 PCB 基板的背向打光方式。因为但该方式难以确保大尺寸 PCB 的成像质量和均匀性, 会出现亮度不均的区域, 并且在实际生产中的大多型号 PCB 板均具有较差的透光性。

为了提高系统的通用性, 本文最终选用了由 LED 灯珠构成的面阵光源, 该光源可以调节红绿蓝三基色的光强, 以适应不同材料的反光特性。因此, 本系统的光源打光方式采用散射光间接照明的方案, 光线首先从 LED 光源发射, 然后通过反射罩向周围散射, 以实现均匀照明。

### 5.1.2 成像系统

图像采集模块负责将 PCB 的物理表面特征转换为可处理的图像数据, 是 PCB 缺陷检测系统的基础。该模块除了包括上一节所叙述的光源系统外, 还包括成像系统, 通过相机将被拍摄对象的光信号转换为数字信号并上传到 PC 机中进行处理。该系统直接决定了成像质量的好坏以及检测算法的准确率, 而相机作为成像系统的核心组件, 负责图像信息的采集, 直接决定了成像结果, 故需根据实际情况进行选型。

工业相机根据其感光元件的布局方式, 主要分为线阵相机与面阵相机两种。面阵相机的感光元件呈面状排布, 而线阵相机的感光元件则呈线状分布。其中, 面阵相机通过矩形传感器在单帧中捕获图像, 所得图像的宽度和高度直接对应于传感器上的像素数量, 且要求被摄物体处于静止或低速运动状态。与面阵相机不同, 线阵相机通过“逐行扫描”方法捕捉图像, 这要求在成像过程中被摄物体需要保持连续移动。由于线阵相机仅在水平方向上产生畸变, 其成像精度优于面阵相机, 然而为了确保线阵相机的高效运作, 往往需要配备一个高精度的伺服系统, 成本较高。

除了上述所提及的因素, 在选择相机时还需要评估其是否能满足检测任务的设计指标。以本文所检测的 PCB 裸板为例, 所有型号的 PCB 裸板中, 最大尺寸为 520mm\*620mm, 而最小的物理线宽要求为 0.15mm。算法的精度要求是将单根线宽识别为至少 4 个像素, 即 0.037mm/pixel。以窄边 520mm 考虑, 相机在 X 轴的分辨率应当达到:

$$\frac{520}{0.037} = 14054 \text{ pixel} \quad (5-1)$$

根据上述分辨率的要求进行计算, 所需的相机物理像素总数超过一亿, 而具备如此高像素的相机往往价格昂贵。因此, 综合考虑处理速度和预算等因素, 本

文选取四台 BFS-U3-200S6 CMOS 相机作为成像系统相机，该相机的分辨率为 5472\*3468，可进行每秒 18 帧连续拍摄。

## 5.2 系统软件设计

### 5.2.1 系统界面设计及功能模块划分

PCB 缺陷检测系统的软件部分主要实现了 PCB 图像处理算法以及缺陷检测算法的应用。图 5.4 显示了 PCB 缺陷检测软件系统主界面的示意图，该界面被划分为四个主要区域：A 区域为数据初始化模块，B 区域为 PCB 图像处理算法模块，C 区域为用于执行 PCB 缺陷检测算法的模块，D 区域为展示 PCB 图像处理结果的模块。对于四部分具体功能模块划分，具体如下：



图 5.4 PCB 缺陷检测软件系统主界面示意图

(1) 数据初始化模块：主要包括图像读取、图像保存、参数设置和数据管理功能。图像读取是选择待测的 PCB 图像并呈现在 D1 区域。图像保存则是将处理后的结果图像（即 D2 区域中的图像）保存到指定路径。参数设置则根据算法需求对内置的预设信息进行调整。数据管理主要对 PCB 图像检测所生成的数据进行管理，确保数据的组织和可检索性。

(2) PCB 图像处理算法模块：核心功能包括图像分割与特征分析两个部分。该模块负责对 PCB 图像进行图像分割与特征分析处理，并在界面中的 D2 区域中

直观呈现所得的结果图像。

(3) **PCB 缺陷检测算法应用模块**：这部分整合了本文提出的两种检测算法：基于两阶段分割与规则校验的 PCB 裸板缺陷检测算法以及基于师生网络与伪标签的半监督 PCB 板缺陷检测方法。主要负责这两种检测算法的具体功能实现。

(4) **PCB 缺陷检测结果显示模块**：这部分主要负责输入图像的展示、图像处理的结果展示、缺陷细节的详细视图以及缺陷信息的文字化显示（交互终端）。其中 D1 区域展示输入的待测图像，D2 区域展示图像处理的结果，包括 PCB 图像处理算法的结果和 PCB 缺陷检测的结果；若图像存在缺陷，则缺陷细节将呈现在 D3 区域。此外，D4 区域主要显示一些算法运行的文字结果（例如报错信息等）以及缺陷种类。

## 5.2.2 软件系统结果展示

本节将展现 PCB 缺陷检测系统软件部分的核心功能。其中，图 5.5 为运用本文所提基于两阶段分割与规则校验的缺陷检测算法，对 PCB 裸板进行检测的结果图。用户首先在 PCB 缺陷检测算法应用模块中，选择对应的算法（传统算法），然后通过点击界面中的打开图片按钮，上传待测 PCB 裸板图像，最后点击开始检测按钮，系统根据用户所选择的算法，对待测图像进行检测，最终在界面展示检测结果。根据图 5.5（a）可知，PCB 缺陷检测系统通过使用基于两阶段分割与规则校验的缺陷检测算法，实现了系统对 PCB 裸板导孔缺陷的基本的检测功能；根据图 5.5（b）可知，PCB 缺陷检测系统通过使用基于两阶段分割与规则校验的缺陷检测算法，实现了系统对 PCB 裸板线路缺陷的基本的检测功能。另外，在图 5.5 界面右下角显示了对应缺陷的细节放大图，交互终端部分则显示了所识别的具体缺陷文字结果，其与系统的检测结果一致。

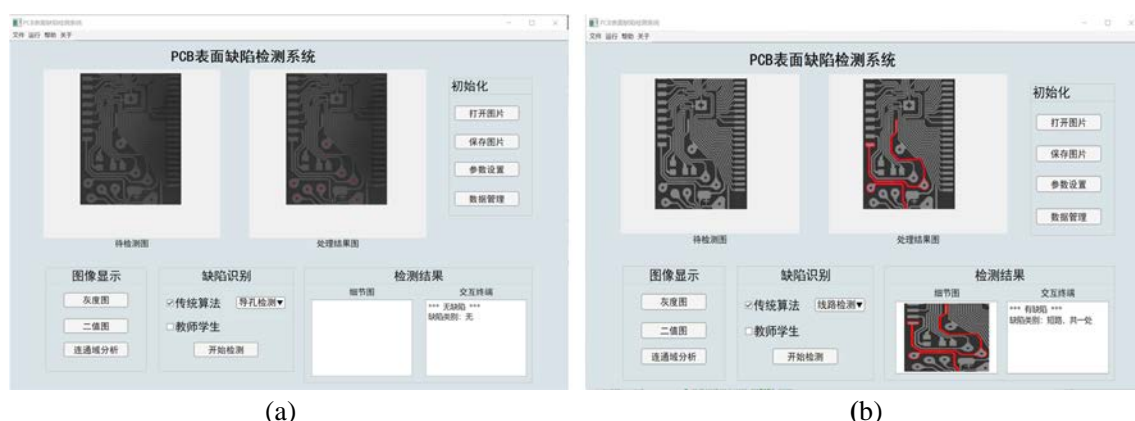


图 5.5 软件系统对 PCB 裸板检测结果示意图：(a) 基于两阶段分割与规则校验的算法导孔检测结果图；(b) 基于两阶段分割与规则校验的算法线路检测结果图



图 5.6 为运用本文所提基于师生网络与伪标签的半监督检测算法，对 PCB 板进行检测的结果图。用户首先在 PCB 缺陷检测算法应用模块中，选择对应的算法（教师学生），然后通过点击界面中的打开图片按钮，上传待测 PCB 板图像，最后点击开始检测按钮，系统根据用户所选择的算法，对待测图像进行检测，最终在界面展示检测效果。根据图 5.6（a）可知，PCB 缺陷检测系统通过使用基于师生网络与伪标签的半监督检测方法，实现了系统对 PCB 板短路缺陷的基本的检测功能；根据图 5.6（b）可知，PCB 缺陷检测系统通过使用基于师生网络与伪标签的半监督检测方法，实现了系统对 PCB 板残铜缺陷的基本的检测功能。另外，在图 5.6 界面右下角显示了对应缺陷的细节放大图，交互终端部分则显示了所识别的具体缺陷文字结果，其与系统的检测结果一致。

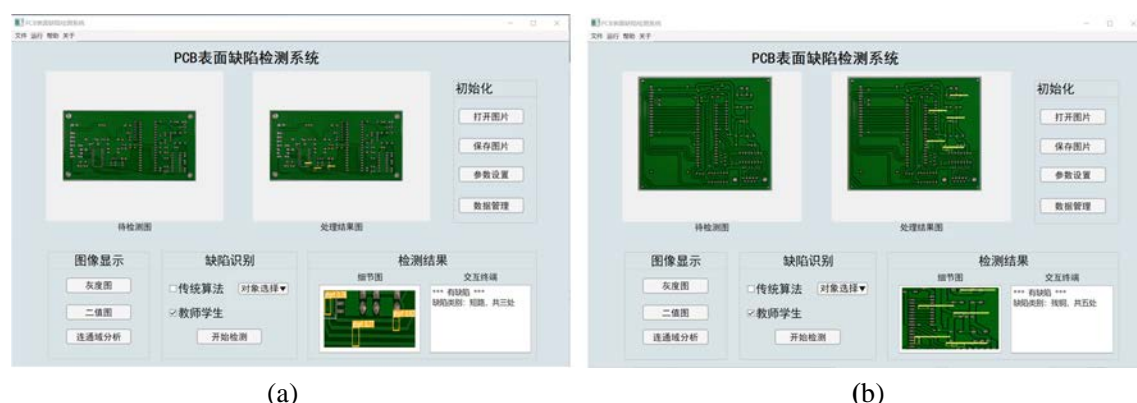


图 5.6 软件系统对 PCB 板检测结果示意图：（a）基于师生网络与伪标签的半监督检测方法短路检测结果图；（b）基于师生网络与伪标签的半监督检测方法残铜检测结果图

### 5.3 系统测试

本系统的设计目的在于确保其能够持续稳定地执行任务，同时为 PCB 图像提供有效的缺陷检测方法。为了验证系统的性能，特别是软件算法在检测方面的准确性有效性，必须进行一系列的测试。

针对本文提出的基于两阶段分割与规则校验的 PCB 裸板缺陷检测算法，本节采用由东莞黔兴机械公司所提供的 PCB 裸板样本，并从其中两种不同型号的 PCB 裸板中各随机抽取 300 张样本进行测试。针对本文提出的基于师生网络与伪标签的半监督 PCB 板检测方法，采用公开的 PCB 板数据集，并从其中两种不同型号的 PCB 板中各随机抽取 300 张样本进行了测试。最终根据 PCB 的合格情况，对每种型号 PCB 的漏检率和误检率进行了统计。其中，漏检率定义为在所有不合格的样本中，被错误地分类为合格品的比例；误检率指的是在合格的 PCB 样本中，被误判为不合格品的比例。相关检测结果如表 5.1 与表 5.2 所示：

表 5.1 基于两阶段分割与规则校验的 PCB 裸板缺陷检测算法系统测试结果

PCB 裸板类型	样本数量	标准的不合格 样本数	系统检测的不 合格样本数	漏检率 (%)	误检率 (%)
A 型	300	58	62	1.79	2.08
B 型	300	49	52	1.21	2.79
综合	600	103	112	1.50	2.44

表 5.2 基于师生网络与伪标签的半监督 PCB 板缺陷检测算法系统测试结果

PCB 板类型	样本数量	标准的不合格 样本数	系统检测的不 合格样本数	漏检率 (%)	误检率 (%)
I 型	300	63	68	1.56	2.53
II 型	300	98	104	1.02	3.23
综合	600	161	172	1.29	2.88

表 5.1 所示结果以东莞黔兴机械公司提供的 PCB 裸板的标记数据（标签）作为基准，并以此统计出漏检率和误检率；表 5.2 所示结果以 PCB 板数据集的标记数据（标签）作为基准，并以此统计出漏检率和误检率。根据表 5.1 与表 5.2 结果，本系统的漏检率低于 3%，误检率低于 5%，满足工业检测的要求。

此外，需要说明的是，一个检测系统的漏检率和误检率通常是表现为负相关的两个性能指标。即在算法确定的情况下，尽管可以通过参数调整等方法对这两个指标产生一定影响，但降低漏检率往往会不可避免地导致误检率上升，反之亦然。这种关系体现了系统整体参数对算法检测效果的影响，当检测标准设定得较为宽松，则会导致更多的非目标被检测为缺陷，从而增加了误检率，同时减少了漏检率。相反，如果提高检测标准，误检率则会降低，漏检率会相应增加。对本系统而言，当 PCB 被判定为不合格后直接由工人进行复检，而判定为合格的则直接被送到下一道工序进行加工。从实用性考虑，会更偏向于有较低的误检率，尽量保证产品的合格率，故系统检测出来的不合格样本略高于标准的结果。

## 5.4 本章小结

本章节主要是检测系统的设计，从硬件和软件两个方面叙述了本系统的实现，其中软件系统整合了本文所提的基于两阶段分割与规则校验的 PCB 裸板缺陷检测算法、基于师生网络与伪标签的半监督 PCB 板缺陷检测方法。首先介绍了系统的硬件设计；然后展示了软件系统功能模块的设计与实现；最后以漏检率和误检率为指标对系统性能进行了测试。结果表明系统操作简单，具有较好应用价值。

## 第6章 总结与展望

### 6.1 总结

本文以实现 PCB 缺陷检测为目标,从传统图像处理和深度学习两方面进行了研究。主要的工作内容以及研究成果如下:

(1) 基于两阶段分割与规则校验的 PCB 裸板缺陷检测算法。首先提出基于局部信息增强与基于直方图的自动初始化聚类中心的 FCM 算法,对 PCB 裸板图像的线路区域进行初步分割,然后提出基于先验信息的快速水平集分割算法对其进行精细分割。该两阶段分割方法中:粗分割阶段通过引入一个结合了局部空间信息与灰度信息的调控因子,对隶属度划分矩阵进行修正,同时采用基于直方图的自动初始化聚类中心的策略选取聚类中心,可在保持图像细节信息的同时压制噪声,提高了算法鲁棒性;精分割阶段通过引入粗分割阶段的先验信息,保证了 PCB 裸板图像前景区域轮廓信息的特征完整性,实现了 PCB 裸板图像线路区域的保边分割,同时在不影响分割效果的前提下大幅减少了计算复杂度,提升了整体分割算法检测效率。最后基于上述分割结果提出规则校验与区域组合特征的缺陷检测判别方法,根据连通域与面积特征识别图像中线路缺陷,根据圆的几何特性识别导孔完整性缺陷。整体方法仅需单张图像参与,在准确率与鲁棒性上均取得了较好的效果。

(2) 基于师生网络与伪标签的半监督 PCB 板缺陷检测方法。首先基于教师学生网络,本文设计了一个以单阶段目标检测方法作为核心检测网络的半监督模型,采用端到端的半监督检测策略,使教师、学生两种模型进行联合学习,在仅需少量标记数据的情况下,能够提升伪标签的标记质量以提升检测模型的检测效果,同时减少了模型的检测时间,满足工业实时性要求;然后提出了一种新的伪标签分配器,使得网络在训练的过程中除了针对确定性伪标签进行学习外,对不确定伪标签根据分类与置信度得分,进行不同的损失计算,解决了传统半监督缺陷检测网络中,伪标签的硬筛选方法导致伪标签结果质量低破坏检测性能的问题。最后,通过在 PCB 板数据集上进行实验,结果显示了本文半监督方法在 PCB 板缺陷检测上的有效性,为基于单阶段检测器的半监督缺陷检测算法提供了新的思路。

(3) 综合上述研究,本文提出一套 PCB 自动缺陷检测系统,整合了本文所提的两种缺陷检测算法。对该系统的硬件设计与选型及软件设计进行了介绍,并展示了软件检测系统对 PCB 图像进行检测的结果图,包括图像检测结果显示,以

及人机交互终端数据显示等。

## 6.2 展望

本文分别从传统图像处理与深度学习两个方面,以 PCB 缺陷检测为目标进行了研究。在传统无参考检测法的基础上设计了基于两阶段分割与规则校验的 PCB 裸板缺陷检测算法;在基于深度学习的方面设计了基于师生网络与伪标签的半监督 PCB 板缺陷检测算法,整体取得了较好的结果,但是仍有不足之处未完善,需要在后续的研究中继续改进:

(1) 基于传统图像处理的 PCB 裸板无参考检测法,由于该方法主要基于图像前景线路区域进行分析从而进行缺陷判定,对于图像的缺陷定位并不精确,因此可以设计更加完善的缺陷判定方案对检测结果进行定位。

(2) 基于半监督的 PCB 板缺陷检测算法,本文方法仅考虑了伪标签,但在实际工业场景中,缺陷数据的收集往往会存在类别分布极其不均匀的情况,因此对数据分布的不平衡条件下的缺陷检测是未来的研究方向。

## 参考文献

- [1] 汤勃, 孔建益, 伍世虔. 机器视觉表面缺陷检测综述[J]. 中国图象图形学报, 2017, 22(12): 1640-1663.
- [2] Zhang Q, Liu H. Multi-scale defect detection of printed circuit board based on feature pyramid network[C]. 2021 IEEE International Conference on Artificial Intelligence and Computer Applications, 2021: 911-914.
- [3] Bhatt P. M, Malhan R. K, Rajendran P, et al. Image-based surface defect detection using deep learning: A review[J]. Journal of Computing and Information Science in Engineering, 2021, 21(4): 1-23.
- [4] 李海霞, 张衡. 一种液晶模组自动光学检测系统的设计[J]. 液晶与显示, 2020, 35(04): 402-408.
- [5] 卢荣胜, 吴昂, 张腾达, 等. 自动光学(视觉)检测技术及其在缺陷检测中的应用综述[J]. 光学学报, 2018, 38(08): 23-58.
- [6] 韩茜茜, 耿世勇, 李恒毅. 基于机器视觉的缺陷检测应用综述[J]. 电工技术, 2021(14): 117-118.
- [7] Malams E N, Petrakis E G M, Zervakis M, et al. A survey on industrial vision systems, applications and tools[J]. Image and Vision Computing, 2003, 21(2): 171-188.
- [8] Moganti M, Ercal F. Automatic PCB inspection systems[J]. IEEE Potentials, 1995, 14(3): 6-10.
- [9] 刘尚军, 程宪平. PCB 瑕疵图像实时视觉检测方法的研究[J]. 计算机工程与应用, 2002(16): 71-74.
- [10] Ibrahim Z, Al-Attas S A R, Ono O, et al. A noise elimination procedure for wavelet-based printed circuit board inspection system[C]. 2004 5th Asian Control Conference, 2004, 2: 875-880.
- [11] 李志敏, 林越伟, 黄俊, 等. PCB 走线检测的预处理算法[J]. 光学精密工程, 2007, 15(2): 272-276.
- [12] Ibrahim Z, Khalid N K, Ibrahim I, et al. A noise elimination procedure for printed circuit board inspection system[C]. 2008 Second Asia International Conference on Modelling & Simulation(AMS), 2008: 332-337.
- [13] 熊邦书, 熊振姣, 莫燕, 等. 线路板缺陷的图像检测方法[J]. 半导体光电,

2012, 33(2): 303-306.

- [14]Kaur B, Kaur G, Kaur A. Detection and classification of printed circuit board defects using image subtraction method[C]. 2014 Recent Advances in Engineering and Computational Sciences, 2014:1-5.
- [15]Raj A, Sajeena A. Defects detection in PCB using image processing for industrial applications[C]. 2018 Second International Conference on Inventive Communication and Computational Technologies(ICICCT), 2018:1077-1079.
- [16]朱寒, 林丽, 王健华, 等. 基于改进模板匹配及图像差分法的 PCB 板缺陷多级检测方法[J]. 应用光学, 2020, 41(04): 837-843.
- [17]Shi W, Lu Z, Wu W, et al. Single-shot detector with enriched semantics for PCB tiny defect detection[J]. The Journal of Engineering, 2020, 2020(13): 366-372.
- [18]耿振宇. 基于 Faster R-CNN 的 PCB 缺陷检测模型研究[D]. 南京: 南京信息工程大学, 2021.
- [19]李澄非, 蔡嘉伦, 邱世汉, 等. 基于改进 YOLOv4 算法的 PCB 缺陷检测[J]. 电子测量技术, 2021, 44(17): 146-153.
- [20]Mamidi J S S V, Sameer S, Bayana J. A Light weight version of PCB defect detection system using YOLO V4 Tiny[C]. 2022 International Mobile and Embedded Technology Conference(MECON), 2022: 441-445.
- [21]Gao Y, Gao L, Li X, et al. A semi-supervised convolutional neural network-based method for steel surface defect recognition[J]. Robotics and Computer Integrated Manufacturing, 2020, 61: 101825.
- [22]崔屹. 数字图像处理技术与应用[M]. 北京: 电子工业出版社, 1997, 6-8.
- [23]王秀秀. 基于自适应模糊 C-均值与机会约束支持向量机的图像分割算法[D]. 大连: 大连理工大学, 2015.
- [24]Bezdek J C, Ehrlich R, Full W. FCM: The fuzzy c-means clustering algorithm[J]. Computers & Geosciences, 1984, 10(2-3): 191-203.
- [25]Hartigan J A, Wong M A. Algorithm AS 136: A k-means clustering algorithm[J]. Journal of the Royal Statistical Society, 1979, 28(1): 100-108.
- [26]LeCun Y, Bengio Y, Hinton G. Deep learning[J]. nature, 2015, 521(7553): 436-444.
- [27]Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2014: 580-587.

- [28]He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37(9): 1904-1916.
- [29]Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. Advances in Neural Information Processing Systems, 2017, 39(6): 1137-1149.
- [30]Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 779-788.
- [31]Redmon J, Farhadi A. Yolo9000: better, faster, stronger[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 7263-7271.
- [32]Redmon J, Farhadi A. Yolov3: An incremental improvement[J]. arXiv preprint arXiv: 1804.02767, 2018.
- [33]Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C]. Computer Vision ECCV 2016: 14th European Conference, 2016: 21-37.
- [34]Sande K E A, Uijlings J R, Gevers T, et al. Segmentation as selective search for object recognition[C]. 2011 International Conference on Computer Vision, 2011: 1879-1886.
- [35]Sohn K, Zhang Z, Li C.-L, et al. A simple semi-supervised learning framework for object detection[J]. arXiv preprint arXiv: 2005.04757, 2020.
- [36]Liu Y C, Ma C Y, He Z, et al. Unbiased teacher for semi-supervised object detection[J]. arXiv preprint arXiv: 2102.09480, 2021.
- [37]Xu M, Zhang Z, Hu H, et al. End-to-end semi-supervised object detection with soft teacher[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021: 3060-3069.
- [38]Krinidis S, Chatzis V. A robust fuzzy local information C-means clustering algorithm[J]. IEEE Transactions on Image Processing, 2010, 19(5): 1328-1337.
- [39]Lei T, Jia X, Zhang Y, et al. Significantly fast and robust fuzzy c-means clustering algorithm based on morphological reconstruction and membership filtering[J]. IEEE Transactions on Fuzzy Systems, 2018, 26(5): 3027-3041.
- [40]Gong M, Liang Y, Shi J, et al. Fuzzy c-means clustering with local information and kernel metric for image segmentation[J]. IEEE Transactions on Image Processing, 2012, 22(2): 573-584.

- [41]Ma J, Tian D, Gong M, et al. Fuzzy clustering with non-local information for image segmentation[J]. International Journal of Machine Learning and Cybernetics, 2014, 5(6): 845-859.
- [42]郭贝贝, 马自萍, 王兴岩, 等. 改进 DRLSE 的分布式肝脏及肿瘤分割方法[J]. 计算机工程与应用, 2022, 58(14): 200-209.
- [43]王振华, 何婉雯, 孙婧琦, 等. 改进水平集模型的海岛边界快速分割方法研究[J]. 计算机科学与探索, 2019, 13(7): 1206-1216.
- [44]Chan T F, Vese L A. Active contours without edges[J]. IEEE Transactions on Image Processing, 2001, 10(2): 266-277.
- [45]Mumford D B, Shah J. Optimal approximations by piecewise smooth functions and associated variational problems[J]. Communications on Pure and Applied Mathematics, 1989, 42(5): 577-685.
- [46]Liu S, Peng Y. A local region-based Chan-Vese model for image segmentation[J]. Pattern Recognition, 2012, 45(7): 2769-2779.
- [47]Wang L, Li C, Sun Q, et al. Active contours driven by local and global intensity fitting energy with application to brain MR image segmentation[J]. Computerized Medical Imaging and Graphics, 2009, 33(7): 520-531.
- [48]Zhang K, Zhang L, Song H, et al. Active contours with selective local or global segmentation: a new formulation and level set method[J]. Image and Vision Computing, 2010, 28(4): 668-676.
- [49]Ayatollahi S M, Nafchi H Z. Persian heritage image binarization competition (PHIBC 2012)[C]. 2013 First Iranian Conference on Pattern Recognition and Image Analysis(PRIA), 2013: 1-4.
- [50]Weber A G. The USC-SIPI image database: Version 5[J]. USC-SIPI Report, 1997, 315.
- [51]Otsu N. A threshold selection method from gray-level histograms[J]. Automatica, 1975, 11(285-296): 23-27.
- [52]Bradley D, Roth G. Adaptive thresholding using the integral image[J]. Journal of Graphics Tools, 2007, 12(2): 13-21.
- [53]Lu D, Huang X, Sui L X. Binarization of degraded document images based on contrast enhancement[J]. International Journal on Document Analysis and Recognition(IJDAR), 2018, 21: 123-135.
- [54]Szilagyi L, Benyo Z, Szilágyi S M, et al. MR brain image segmentation using an



- enhanced fuzzy c-means algorithm[C]. Proceedings of the 25th Annual International Conference of the IEEE Engineering in Medicine and Biology Society, 2003, 1: 724-726.
- [55]Lei T, Jia X, Zhang Y, et al. Significantly fast and robust fuzzy c-means clustering algorithm based on morphological reconstruction and membership filtering[J]. IEEE Transactions on Fuzzy Systems, 2018, 26(5): 3027-3041.
- [56]Sezgin M, Sankur B. Survey over image thresholding techniques and quantitative performance evaluation[J]. Journal of Electronic Imaging, 2004, 13(1): 146-165.
- [57]Miyato T, Maeda Sichi , Koyama M, et al. Virtual adversarial training: a regularization method for supervised and semi-supervised learning[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018, 41(8): 1979-1993.
- [58]Xie Q, Dai Z, Hovy E, et al. Unsupervised data augmentation for consistency training[J]. Advances in Neural Information Processing Systems, 2020, 33: 6256-6268.
- [59]Li J, Xiong C, Hoi S. C. Comatch: Semi-supervised learning with contrastive graph regularization[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021: 9475-9484.
- [60]Fan Y, Kukleva A, Dai D, et al. Revisiting consistency regularization for semi-supervised learning[J]. International Journal of Computer Vision, 2023, 131(3): 626-643.
- [61]蒙春学. 理管机机器视觉光源关键技术研究[D]. 西安: 西安工程大学, 2019.